Doğal Dil İşleme ile Finansal Haberlerin Sınıflandırılması : Makine ve Derin Öğrenme Yöntemleri

Sudenaz Özel[1], ve Mert Uğur[2], ve Gülay Çiçek[3]
[1],[2],[3]Yazılım Mühendisliği Bölümü, Mühendislik-Mimarlık Fakültesi
İstanbul Beykent Üniversitesi, Sarıyer, İstanbul, Türkiye
[1]sudenazozel0704@gmail.com, [2]ugurmert323@gmail.com
[3]gulaycicek@beykent.edu.tr

***Özet*—Son yıllarda dijital teknolojilerin gelişimiyle birlikte finansal piyasalar günlük yaşama daha fazla entegre olmuş ve küresel olaylara hızlı bir şekilde tepki verir hale gelmiştir. Ancak her gün yayımlanan büyük miktardaki finansal haberin manuel olarak işlenip yorumlanması yatırımcılar için büyük bir zorluk oluşturmaktadır. Bu çalışma, finansal haberleri pozitif veya negatif olarak sınıflandırmak için Makine Öğrenimi ve Derin Öğrenme tekniklerini kullanmaktadır. Bu çalışmada, Kaggle platformundan alınan ve finansal haberlerin duygu analizi için kullanılan "Sentiment Analysis for Financial News" veri seti analiz edilmiştir. Veri seti, kategorik duygu etiketlerini (nötr, pozitif, negatif) içeren haber başlıklarından oluşmaktadır. Toplamda 4.845 satır ve iki sütun içeren veri setinde; 2.878 nötr, 1.364 pozitif ve 604 negatif örnek bulunmaktadır. Veri setinde ön işleme için Metin temizleme , öznitelik çıkarımı için TF-IDF yöntemi ve öznitelik seçimi içinse PCA ve Varyans Eşiği Belirleme yöntemi kullanılmıştır. Naive Bayes, Destek Vektör Makinesi, Lojistik Regresyon, Rastgele Orman, K-En Yakın Komşu, Yapay Sinir Ağları, Uzun Kısa Süreli Bellek, Hiyerarşik Dikkat Ağları, Evrişimsel Sinir Ağı ve Transformer algoritmaları ile sınıflandırma modelleri oluşturulmuştur. YSA derin öğrenme modeli geliştirilerek özgün bir modelleme yaklaşımı düşünüldü. Performans değerlendirmesinde doğruluk, kesinlik, özgüllük, f-skor, duyarlılık ve AUC metrikleri ele alındı. K-Fold Çapraz Geçerleme kullanıldı. Sonuçlar özgün modelin haberlerin sınıflandırılmasında diğer modellere kıyasla üst düzey bir performans sergiledi. Özellikle PCA öncesi doğruluk değeri %91.46'ya kadar çıktı. Bu çalışma, haberlerin sınıflandırılması için bilinen makine ve derin öğrenme modellerinin yanında özgün bir model de sunmuştur. Literatürde haberlerin sınıflandırılmasında özgün bir modelin etkili olabileceğini ve veri ön işleme , veri öznitelik seçme ve çıkarma teknikleri ve sınıf dengesizliği giderici yöntemlerin sınıflandırmanın başarısını arttırdığını ortaya koymuştur. Aynı zamanda 2 farklı öznitelik çıkarma yöntemini kullanması da literatür çalışmamızda olmayan yenilikçi bir yöntemdir. Bu çalışma geliştirilmiş bir derin öğrenme algoritmasının haberlerin sınıflandırılmasında etkili olabileceğini göstermiştir. İleriye dönük çalışmalar kapsamında modelin daha geniş veri kümeleri üzerinde test edilmesi ve finans dışındaki sektörlerde, örneğin emlak, enerji, teknoloji ve tarım alanlarında uygulanabilirliğinin değerlendirilmesi planlanmaktadır. Modelin gerçek zamanlı analiz sistemlerine entegre edilmesi, yatırımcılara ve sektör profesyonellerine anlık karar alma süreçlerinde destek sağlayabilir. Ayrıca sosyal medya, haber siteleri ve sektörel raporlar gibi farklı kaynaklardan elde edilen verilerin entegrasyonu modelin doğruluğunu artırabilir. Bölgesel piyasalarda uygulanarak ekonomik ve kültürel bağlamlarda performansının test edilmesi, kapsamın genişletilmesi açısından önemlidir.**

***Anahtar Kelimeler*—Finans Piyasaları, Yatırımcı Kararları, Makine Öğrenimi, Derin Öğrenme, Haber Sınıflandırma, Doğru Bilgi Erişimi, Yapay Sinir Ağları**

I. GİRİŞ

Finans piyasaları, küresel ekonominin işleyişinde kritik bir rol oynar [1]. Küreselleşme süreci, 1970'lerin başında Bretton Woods sisteminin çökmesiyle ivme kazanmıştır [2]. Sabit kurdan esnek kura geçilmesi, döviz kurları üzerinden kazanç elde etme imkânını doğurmuş ve yüksek hacimli döviz piyasalarının oluşmasına zemin hazırlamıştır [3].

Teknolojinin ilerlemesiyle birlikte, uluslararası sermaye hareketleri hız kazanmış ve ulusal piyasalar giderek daha entegre hale gelmiştir [4]. Bu piyasalar, sermaye birikimini destekleyerek şirket büyümesi, devlet yatırımları ve ekonomik kalkınmaya katkı sağlar [5]. Ayrıca, yatırımcılara hisse senetleri, tahviller, döviz ve emtia gibi varlıklarda işlem yapma fırsatı sunar [6]. Finans piyasalarının bir diğer işlevi ise ekonomik dengeyi sağlamak, maliyetleri kontrol etmek ve riskleri azaltarak sürdürülebilir bir yatırım ortamı oluşturmaktır.

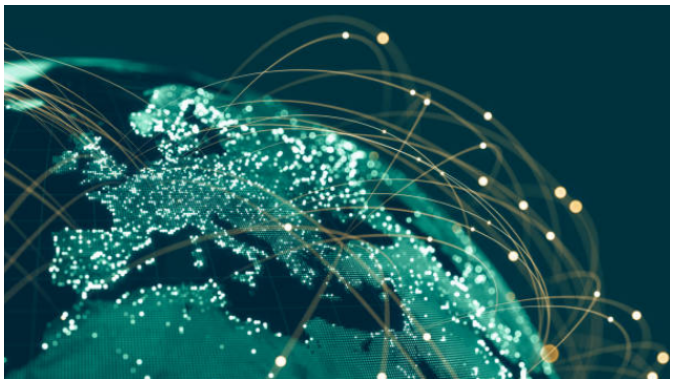


Fig. 1: Piyasalarda Küreselleşme (Şekil [7])

Gün geçtikçe gelişen dijital teknolojiler ile birlikte finansal piyasalar günlük yaşama entegre olmuş ve dünyadaki ekonomik haberlerden daha hızlı ve doğrudan etkilenir hale gelmiştir [8]. Özellikle akıllı telefonlar, tabletler ve diğer kişisel teknolojik cihazların kullanımının artması küresel olayların finans piyasalarını çok kısa süreler içinde etkilemesine neden olmuştur [9].

Dijitalleşmenin getirdiği bu hızlı ve geniş kapsamlı bilgi akışı, finansal hareketlerin daha karmaşık bir hale gelmesine neden olmuş ve hem bireysel hem de kurumsal yatırımcılar için daha fazla risk ve aynı zamanda fırsat yaratmıştır [9]. Böyle dinamik bir ortamda, haberlerin doğru analiz edilmesi ve finansal piyasalar üzerindeki etkilerinin öngörülmesi, yatırım süreçlerinin başarısı için kritik bir rol oynar. Haber akışının piyasalarla olan bu güçlü ilişkisi, yatırım kararlarının hızını ve doğruluğunu doğrudan etkiler. Bu analizlerin hızlı ve güvenilir bir şekilde yatırımcılara ulaştırılması, başarılı yatırım stratejileri oluşturmak için hayati önem taşır.Yanlış yorumlanan veya gecikmiş bir bilgi, yatırımcılar için önemli kayıplara yol açabilirken, doğru ve zamanında bir analiz ise kazançlı stratejilerin

temelini oluşturabilir [10].

Yatırımcı, birikimini kazanç sağlamak amacıyla farklı finansal sınıflara yatıran birey veya kurumlardır [11]. Finansal piyasalarda işlem yaparak risk alır ve getirilerinden faydalanmayı hedefler. Yatırımcılar; piyasa hareketlerine, ekonomik verilere ve finansal haber akışına bağlı olarak kararlarını şekillendirir. Bu kararlar genellikle alabileceği risk, yatırım süresi ve hedeflere göre değişiklik gösterir [11]. Yatırımcılar genellikle bireysel ve kurumsal olarak iki ana gruba ayrılır. Bireysel Yatırımcılar kendi birikimiyle yatırım yapan, genellikle daha sınırlı bir portföye sahip bireylerdir. Risk toleransı kişisel finansal duruma bağlıdır. Kurumsal Yatırımcılar ise bankalar, büyük şirketler, yatırım ve emeklilik fonları gibi büyük ölçekli organizasyonlardır [12]. Daha büyük sermayeleri yönetir ve genellikle uzun vadeli stratejiler izlerler. Yatırımcılar, sermaye piyasalarının temel taşlarıdır. Likiditeyi artırır, ekonomik büyümeye destek sağlar ve şirketlerin kaynak oluşturmasına yardımcı olur. Bireysel yatırımcıların artışı, sermayenin daha geniş bir tabana yayılmasını sağlarken, kurumsal yatırımcıların stratejik hamleleri, piyasa istikrarına ve derinliğine katkıda bulunur [13]. Dünya nüfusunun büyük bir kısmı yatırımcı olarak finansal piyasalarda bulunmasa da aktif olan birey ve kurumların sayısı giderek artmaktadır (Şekil 2). Dünya genelinde borsalara kayıtlı bireysel yatırımcıların oranı gelişmiş ülkelerde %50'ye kadar çıkabilirken gelişmekte olan ülkelerde bu oran genellikle %5-20 aralığında kalmaktadır. Kurumsal yatırımcılar ise toplam işlem hacminin büyük bir bölümünü oluşturarak piyasaların temel dinamiklerini belirler [13]. Bununla birlikte teknoloji ve dijitalleşmenin yaygınlaşmasıyla bireysel yatırımcıların katılım oranı hızla artmaktadır. Online yatırım platformlarının ve düşük komisyonlu işlemlerin artması ile dünyanın her köşesinden bireylerin finansal piyasalara erişimi kolaylaşmıştır.

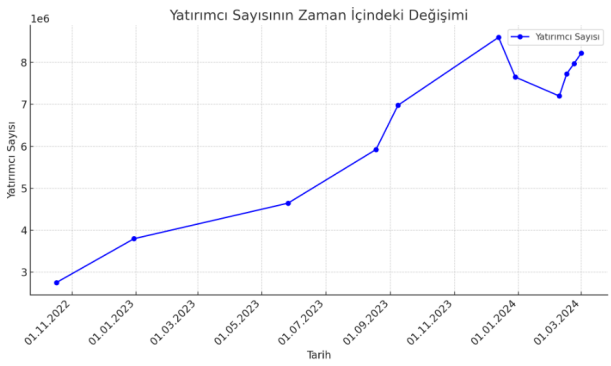


Fig. 2: Yıllara Göre Borsa İstanbul Yatırımcı Sayıları Çizgi Grafiği (Şekil [14])

Finans piyasalarında yatırım yapanlar veya yatırım planı olan bireysel yatırımcılar açısından bilginin değeri oldukça yüksektir [15]. Gerek makro gerekse de mikro düzeyde bilgiye ulaşımı olmayan ya da bilgiye ulaşıp da yorumlayamayan yatırımcılar açısından bu tip süreçler önemli bir risk aynı zamanda maliyet unsurudur [16]. 2024 yılı itibarıyla dünya nüfusu yaklaşık 8 milyar olmuş ve bunların yaklaşık 22,8 milyonu finansal piyasalarda yatırımcı olarak bulunmaktadır. Bu kadar yatırımcının finansal haberleri doğru analiz etmesi ve bunları işlemlerine uyarlaması çok zordur. Dünyada günde yüzbinlerce haber yayınlanmakta ve yatırımcılar bunların birçoğunu görmeden işlemlerini yapmaya devam etmektedir [17]. Yatırımcılar finansal haberleri okumak isteseler de bu kadar fazla sayıda haberin manuel olarak incelenmesi zaman kaybına yol açabilir [17]. Bu da kazançlarının artmasının ve kayıplarının engellenmesinin önüne geçer. Aynı zamanda tek tek inceleme yoruma dayalı olacağından güvenilirlik açısından sınırlıdır [18]. Bu nedenle haberlerin otomatik olarak sınıflandırılması piyasa hareketlerine daha hızlı tepki vermeyi kolaylaştırarak yatırımcıların daha hızlı ve doğru tepki vermesini sağlar.

Bu çalışmada yatırımcıların finansal haberleri pozitif ve negatif olarak sınıflandırabilmesi için Doğal Dil İşleme (Natural Language Processing - NLP) tekniklerinden yararlanarak oluşturulmuş sınıflandırma yöntemleri kullanılacaktır [19]. Doğal Dil İşleme (NLP); bilgisayarların insan dilini anlamasını, analiz etmesini sağlayan bir yapay zeka alanıdır [19]. İnsan dilinin karmaşıklığını anlamaya yönelik yazılımlar ve modeller kullanarak metin veya konuşma verilerinin işlenmesini sağlar [20]. NLP, dilin yapılarını, anlam ilişkileri ve bağlamını modelleyerek makinelerin doğal dilde doğru ve anlamlı sonuçlar üretmesini hedefler. NLP teknikleri, dilin farklı yönlerini analiz etmeye yönelik çeşitli yöntemler sunar. Bu teknikler arasında metin sınıflandırma, duygu analizi, adlandırılmış varlık tanıma (NER), anlamsal analiz, dil modelleme ve makine çevirisi gibi uygulamalar bulunur [21]. Metin sınıflandırma, haberlerin pozitif veya negatif olarak sınıflandırılmasını sağlar [22]. Duygu analizi, sosyal medya gönderilerinin olumlu ya da olumsuz olmasını tespit eder [23]. Dil modelleme ise metinlerin anlamlı ve tutarlı bir şekilde üretilmesini sağlar. NLP, pek çok farklı sektörde yaygın olarak kullanılmaktadır. Arama motorları, sesli asistanlar (Siri, Alexa), müşteri hizmetleri, otomatik metin özetleme ve makine çevirisi gibi uygulamalar en bilinen kullanım alanlarındandır. Ayrıca sağlık sektöründe tıbbi metinlerin analizi, finans sektöründe duygu analizi, hukuk alanında ise belgelerin otomatik analizi gibi işlevsel alanlarda da etkili bir şekilde kullanılmaktadır [24].

Çalışmanın literatüre sağladığı katkılar şu şekilde sıralanabilir:

- Detaylı Veri Ön İşleme Süreçleri: Veri ön işleme adımları titizlikle ele alınmış, metin temizleme, öznitelik çıkarımı ve boyut indirgeme süreçleri detaylı şekilde optimize edilmiştir. Bu, sınıflandırma modellerinin daha verimli çalışmasını sağlamıştır.
- Gelişmiş Öznitelik Çıkarımı ve Boyut İndirme Teknikleri: Öznitelik çıkarım ve boyut indirgeme adımları daha etkin bir şekilde uygulanarak modelin performansı ve işlem süresi optimize edilmiştir.
- Algoritma Çeşitliliği ve Performans Karşılaştırması: Çalışmada hem geleneksel makine öğrenmesi algoritmaları hem de derin öğrenme modelleri kullanılmış ve karşılaştırmalı analizler yapılarak algoritmaların güçlü ve zayıf yönleri detaylı bir şekilde ortaya konulmuştur.
- Sınıflandırma Algoritmalarının Optimizasyonu: Literatürde sıklıkla ihmal edilen algoritma optimizasyon süreçlerine odaklanılmış, hiperparametre ayarları detaylı bir şekilde ele alınarak daha yüksek performans elde edilmiştir.

İleriye dönük çalışma için NLP tekniklerden faydalanan makine öğrenimi, derin öğrenme ve veri analitiği yöntemlerini incelenerek modelin verimliliği, doğruluğu ve daha karmaşık metinlerin doğru şekilde sınıflandırılması sağlanmak istenmektedir [25] [26]. Makine öğrenmesi [27] yöntemleri olarak Naive Bayes (NB), Destek Vektör Makineleri (DVM), Lojistik Regresyon (LR), Rastgele Orman (RO) ve K-En Yakın Komşu (KEYK) ; derin öğrenme mimarileri olarak da Yapay Sinir Ağları (YSA), Uzun Kısa Süreli Bellek (UKSB)[28], Hiyerarşik Dikkat Ağları (HDA), Evrişimsel Sinir Ağı (ESA) ve Transformer Modelleri kullanılmıştır [29] [30] [31].

Özellikle metinlerin anlamlı özniteliklere dönüştürülmesi ve

sınıflandırma süreçlerinde makine öğrenimi algoritmalarından yararlanılmıştır. Derin öğrenme algoritmaları büyük veri setlerinde karmaşık ilişkileri öğrenme kapasitesi nedeniyle tercih edilmiştir. Veri analitiği ise TF-IDF, PCA ve SMOTE gibi yöntemlerle veri setinin işlenmesi ve sınıf dengesizliğinin giderilmesinde kritik bir rol oynamıştır.

Makalenin gidişatı şu şekilde planlanmıştır:

Bölüm II. Literatür İncelemesi, literatürde bu alanda yapılmış çalışmalar ele alınacak ve karşılaştırılacaktır.

Bölüm III. Metot, sistemin nasıl yapılacağı ve kullanılacak sınıflandırma algoritmalarının neler olduğu açıklanacaktır.

Bölüm IV. Deney Sonuçları, modelin performans değerlendirmesi için literatürde sıkça kullanılan metriklerden doğruluk, hassasiyet, duyarlılık, F1 skoru, ROC eğrisi ve karmaşıklık matrisi kullanılacaktır [32].

Bölüm V. Tartışma, çalışmanın eksik olduğu noktalar ve geliştirmeye yönelik hedefler tartışılacaktır.

Bölüm VI. Sonuç, makale hakkında genel bir sonuç bildirisi yer alacaktır.

II. LİTERATÜR İNCELEMESİ

Literatürde haberlerin pozitif ve negatif sınıflandırılmasına yönelik makine ve derin öğrenme metotlarını içeren birçok farklı çalışma incelenmiştir. Aynı zamanda konumuza yardımcı olması açısından yorumların sınıflandırılması, sahte haber tespiti, metin sınıflandırma gibi çalışmalarda incelenmiştir. İncelenmiş olan çalışmalar Tablo I, Tablo II ve Tablo III te makale yazarları, veri seti, örnek sayıları, yöntemler, sonuçlar, eksiklikler ve gelecek katkıları başlıkları altında toplanmıştır. İncelenen bu çalışmalar sayesinde sınıflandırma çalışmalarında yapılan eksiklikleri görmüş ve bu eksikliklere göre algoritmamız şekillendirilmiştir.

Emrah ve ark.(2021), Türkçe dilinde (online) olarak haber yapan bir internet sitesinden aldığı 8 kategoriden oluşan 2.248 veri setini kullanarak haberlerin sınıflandırılmasına yönelik bir çalışma yapmışlar. Çok Terimli Naive Bayes (ÇTNBA) ve Rastgele Orman (RO) algoritmaları kullanılmıştır. En yüksek başarı %99,6 doğruluk ile Rastgele Orman (RO) algoritmasında elde edilmiştir. Bu çalışmada, kullanılan veri setinin büyüklüğü ve çeşitliliği sınırlıdır. Sadece 2 adet sınıflandırma algoritması kullanılmıştır. Gelecek çalışmalarda, veri setinin zenginleştirilmesi ve farklı dillerdeki haber metinlerinin de eklenmesi sınıflandırma başarısını artırabilir. Farklı algoritmaların ve hibrit modellerin bu çalışmada kullanılması, elde edilen sonuçların karşılaştırılmasını sağlayarak daha verimli bir sınıflandırma yapılmasına olanak tanıyacaktır [33].

Çiğdem ve ark. (2019), Kaggle-TCC-3600 veri setinden almış oldukları 6 kategoriden oluşan 3.600 örneği kullanarak haberlerin sınıflandırılmasına yönelik bir çalışma yapmışlar. Bu çalışmada, öncelikle Word2Vec kullanarak bir veri ön işlemesi yapmışlar. Bu sayede veri kümesi zenginleşmiştir. 2 adet Konvolüsyonel Sinir Ağları (KSA) modeli kullanılmıştır. 1.KSA modeli%93,3 doğruluk değeri ile daha başarılı olmuştur. Bu çalışma, KSA'ların metin sınıflama uygulamalarında klasik makine öğrenmesi ve veri madenciliği algoritmalarına kıyasla daha iyi performans gösterebileceğini ortaya koyması açısından önemlidir. Bu çalışmada veri seti genişliği yetersizdir ve tek bir algoritmanın 2 farklı modeli kullanılmıştır. Gelecek çalışmalarda daha geniş bir veri seti kullanılabilir. Farklı algoritmalar da sınıflandırmaya dahil edilebilir ya da KSA model sayısı arttırılarak doğruluk değeri daha fazla olan bir model elde edilebilir [34].

Özer ve ark. (2021), 6 farklı haber sitesinden alınan, 6 kategorideki 12.000 haber verisini kullanarak bir sınıflandırma çalışması gerçekleştirmiştir. Çalışmada, öncelikle veri ön işleme yapılarak ham veriler gereksiz sözcüklerden ve boşluklardan arındırılmıştır. Ardından veri seti için TF-IDF, Word2Vec ve FastText yöntemleri ile vektör modelleri oluşturulmuştur. Bu vektör modelleri, Destek Vektör Makineleri (DVM), Naive Bayes (NB), Lojistik Regresyon (LR), Rastgele Orman (RO) ve Yapay Sinir Ağları (YSA) kullanılarak sınıflandırılmış ve elde edilen sonuçlar karşılaştırılmıştır. En yüksek doğruluk oranı %95,75 ile FastText yöntemi ve DVM kullanılarak elde edilmiştir. Bu çalışmanın veri seti boyutu sınırlıdır ve YSA kullanılmış olsa da derin öğrenme yöntemleri açısından yeterli değildir. Gelecekteki çalışmalarda veri seti büyütülebilir, veri ön işleme aşamasında hibrit modeller kullanılabilir ve farklı derin öğrenme modelleri ile sınıflandırma sonuçları karşılaştırılarak performans artırılabilir [35].

Hülya ve ark. (2023), Kaggle-Turkish Headlines ve BBC News Classification veri setlerinden elde ettikleri, 7 kategorideki 4.200 haber metnini sınıflandırmıştır. Bu çalışmada Evrişimsel Sinir Ağları (ESA), Uzun Kısa Süreli Bellek (UKSB) ve GloVe ile türetilen GloVe-CNN ve GloVe-LSTM yöntemleri kullanılmıştır. UKSB modelinde GloVe kelime gömme yöntemi kullanıldığında, modelin doğruluğu %81'den %91'e yükselmiştir. Ancak ESA modelinde bu tür belirgin bir iyileşme gözlenmemiştir. En yüksek doğruluk oranı, %97 ile ESA modeliyle elde edilmiştir. Çalışmada veri setinin yetersizliği dikkat çekmektedir. Gelecekteki çalışmaların daha büyük veri setleri üzerinde gerçekleştirilmesi ve modellerin farklı hiper-parametrelerle eğitilerek karşılaştırmalı analizlerin yapılması önerilmektedir [59].

Halil ve ark. (2024), Türkçe *newsTRT2023* veri setinden elde ettikleri 9 kategorideki 4.027 haber metnini sınıflandırmaya yönelik bir model geliştirmiştir. Çalışmada, verilerin vektör gösterimi için BERT tabanlı *BertTurk* modeli kullanılmıştır. Bu sayede, metinlerin yüksek boyutlu ve anlamlı temsilleri elde edilerek doğal dil anlama yetisi güçlendirilmiştir. Ardından, sınıflandırma işlemi için Graf Sinir Ağları (GSA) kullanılmış ve %97,93 oranında yüksek bir doğruluk elde edilmiştir. Bu çalışma, Türkçe metin sınıflandırma ve ilişkisel analiz alanlarına yenilikçi bir katkı sunmaktadır. Ancak, veri setindeki dengesizlik, bazı sınıflarda tahmin performansını olumsuz etkileyebilir. Gelecek çalışmalarda daha dengeli veri setleri oluşturularak sınıflandırma performansının iyileştirilmesi hedeflenmektedir [38].

Mehmet ve ark.(2023) Twitter sosyal ağından elde etmiş oldukları 5.500 örnek içinden 250 tweet kullanarak sahte haberlerin tespitinin kısa sürede ve başarı ile yapılabileceğini ortaya koymuştur. Öznitelik çıkarımı ve ağırlıklandırma için TF-IDF yöntemi uygulamışlardır. Sınıflandırma modelleri olarak Karar Ağaçları ve Naive Bayes algoritmaları kullanmışlar, sonuçları karmaşıklık matrisi ile değerlendirmişlerdir. En yüksek başarı %88,4 ile NB algoritmasında elde edilmiştir. Çalışmada kullanılan örnek sayısı azdır. Kullanılan algoritma sayısı yetersizdir. Gelecek çalışmalarda, farklı kaynaklardan haberlerin eklenmesi, veri setinin genişletilmesi ve çeşitli makine öğrenmesi yöntemlerinin kullanılması hedeflenmektedir [18].

Esra ve ark. (2021), Amazon, IMDB ve Yelp sitelerinden alınan toplam 3.000 kullanıcı yorumu ile bir sınıflandırma modeli oluşturmuştur. Bu çalışmada K-En Yakın Komşu (KNN), Naive Bayes (NB), Destek Vektör Makinesi (DVM), Karar Ağacı (KA) ve Rastgele Orman (RO) algoritmaları kullanılmıştır. İlk olarak her algoritma, veri setleri üzerinde ayrı ayrı çalıştırılmış; ardından tüm veri setlerinin birleştirilmesiyle modelin performansında artış gözlemlenmiştir. En iyi sonuç, %85 doğruluk oranı ile DVM algoritmasından elde edilmiştir. Çalışmada derin öğrenme

Makale Yazarlar (Yıl)	Veri Seti	Örnek Sayıları	Yöntemler	Sonuçlar	Eksiklikler	Gelecek Katkıları
Emrah Aydemir, Murat Işık ve Türker Tuncer (2021) [33]	Türkçe çevrimiçi haber yapan bir internet sitesi	2.248 Örnek	ÇTNBA, RO	Doğruluk: %99,86 F-Skoru:%99,9 (RO ile en yüksek sonuç)	Veri seti sınırlıdır. Az sayıda sınıflandırma algoritması kullanılmıştır.	Çalışmanın daha geniş bir veri setiyle yapılması ve kullanılan algoritmalara ek olarak farklı algoritmalar kullanılması faydalı olacaktır.
Çiğdem Acı ve Adem Çırak (2019) [34]	Kaggle- TCC-3600 veri seti	3.600 Örnek	KSA	Doğruluk:%93,3 F-Skoru: %90	Sadece bir adet sınıflandırma algoritması kullanılmış. Veri seti sınırlıdır.	Çalışmada birden fazla algoritma kullanılmalı ve veri seti genişletilerek örnek sayısı arttırılmalı.
Özer Çelik ve Burak Can Koç(2021) [35]	6 farklı haber sitesi	12.000 Örnek	DVM, NB, LR, RO, YSA	Doğruluk:% 95,75 (FastText ve DVM ile en yüksek sonuç)	Başka sınıflandırma çalışmalarıyla karşılaştırma yapılmamıştır. Veri seti sınırlıdır. F-skoru gibi ölçümler hesaplanmamıştır.	Bu alanda yapılan başka çalışmalarla karşılaştırma yapılmalı ve örnek sayısı arttırılmalı. Ölçüm hesaplanmaları eklenmeli.
Hülya Hark, Meral Karakurt, Cengiz Hark ve Ali Karcı (2023) [36]	Kaggle- Turkish Headlines veri seti ve BBC News Classification veri setleri [37]	4.200 Örnek (Her bir kategoride 600 adet olmak üzere, ekonomi, yaşam, siyaset, teknoloji, magazin, sağlık, spor)	UKSB, ESA	Doğruluk:%97 Kesinlik:%97 Duyarlılık:%99 F1-Skoru: %98 (ESA ile en yüksek sonuç)	Veri seti sınırlı.	Daha büyük veri seti kullanılmalı ve farklı modeller geliştirilmeli.
Halil İbrahim Okur, Kadir Tohma ve Ahmet Sertbaş (2024) [38]	Türkçe newsTRT2023 veri seti	4.027 Örnek (Dünya: 1.567, Türkiye: 1.442, Ekonomi: 438, Diğer: 2713)	GSA	Doğruluk:%97,93 Kesinlik:%95,08 Duyarlılık:%92,22 F1-Skoru:%93,59	Veri seti dengesiz ve sınırlı.	Veri seti dengesizliği giderilmeli ve örnek sayısı arttırılmalı.
Mehmet Karakuş ve Fatma Yiğit Açıkgöz (2023) [18]	Twitter	5.500 Örnek	KA, NB	Doğruluk:%88,4 Kesinlik:%89,3 Duyarlılık:%87,2 F1-Skoru: 88,3 (NB ile en yüksek sonuç)	Örnek ve kategori sayısı yetersiz. Kullanılan algoritmalar yetersiz. Farklı algoritmalarla karşılaştırma yapılmamıştır.	Örnek sayısı arttırılmalı ve farklı algoritmalar kullanılarak diğer çalışmalarla karşılaştırmalar sağlanmalı
Esra Çelik, Deniz Dal ve Tolga Aydın (2021) [39]	Amazon, Imdb ve Yelp	3000 Örnek (Her bir web sitesinden 500 olumlu 500 olumsuz örnek)	KEYK, NB, DVM, KA, RO	Doğruluk:%85 Geri Çağırma:%85 Hassasiyet:%85,1 F-Skoru: %85 (DVM ile en yüksek sonuç elde edilmiştir.)	Derin öğrenme kullanılmamıştır. Veri seti çeşitliliği ve sayısı az	Veri seti genişletilmeli ve derin öğrenme algoritmaları kullanılarak sınıflandırma yapılmalı.
Önder Şahinaslan, Hüseyin Dalyan, Ender Şahinaslan (2022) [23]	YouTube yorum verileri	15.082 örnek	NB	Doğruluk:%65,56	Az sayıda sınıflandırma algoritması kullanılmış. Hassasiyet, F-Skoru gibi ölçütler hesaplanmamış	Kullanılacak algoritma sayısı arttırılmalı ve ölçümler yapılmalı.
Cengiz Hark (2022) [40]	COVID-19 veri seti	10.700 Örnek	ÇKA, UKSB, TSA, ESA	Doğruluk:%91 F-Skoru: %92 (En yüksek başarı UKSB ile elde edilmiştir.)	Veri seti sınırlı	Örnek sayısı artırılmalı
Feyza Altunbey Özbay ve Bilal Alataş (2020) [41]	ISOT veri seti	44.898 Örnek (Gerçek: 21.417, Sahte: 23.481)	NB, JRip, J48, RO, SGİ, YAÖ, NBiKA, YKÖ, RiS	Doğruluk:%97,5 Hassasiyet:%97,6 Duyarlılık:%97,6 (RO ile en yüksek sonuç)	Derin öğrenme kullanılmamıştır. Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Farklı algoritmaların testi yapılmalı ve karşılaştırmaları sağlanmalı

TABLE I: Literatür Taraması Sonuçları

Makale Yazarlar (Yıl)	Veri Seti	Örnek Sayıları	Yöntemler	Sonuçlar	Eksiklikler	Gelecek Katkıları
Doğancan Kınık ve Aysun Güran (2021) [42]	1150Haber veri kümesi, Hürriyet6c-1k veri kümesi, Milliyet-9c-1k veri kümesi, AA Haber veri kümesi	36.150 Örnek	NB, KEYK, LR, KDM, KA, ÇKA	Doğruluk:%94 (LR, KDM, ÇKA ile en iyi sonuç)	Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Farklı algoritmalarla karşılaştırma sağlanmalı ve örnek sayısı artırılmalı
Süleyman Gökhan Taşkın, Ecir Uğur Küçüksille ve Kamil Topal (2021) [43]	Twitter	76.738 Örnek	KNN, DVM, RO	F1-Skoru: %86 (RO ile en yüksek sonuç)	Veri seti sınırlıdır.	Farklı kelime temsil yöntemleri kullanılmalı ve örnek sayısı artırılmalı
Yunus Santur (2020) [44]	Hepsiburada	243.000 Örnek (% 98'i pozitif,% 2'si ise negatif)	ESA, UKSB, GTB	Doğruluk:%95.9 (GTB ile en yüksek sonuç)	Veri seti denge-sizdir	Kullanılan algoritma sayısı arttırılmalı ve dengeli bir veri seti oluşturulmalı
Gözde Nergiz ve Erdinç Avaroğlu (2021) [45]	Twitter, Instagram, Youtube	180.000 Örnek	UKSB	Doğruluk:%93,15	Makine öğrenmesi yöntemleri kullanılmamış. Farklı algoritmalarla karşılaştırma yapılmamış.	Farklı algoritmaların test edilmesi ve karşılaştırma sağlanmalı
Ali Dayan ve Atınç Yılmaz (2022) [46]	Kaggle-Audio Cats and Dogs veri seti	277 Örnek (Köpek sesi: 113, Kedi sesi: 164)	UKSB, ESA	Doğruluk:%91 (UKSB ile en yüksek sonuç)	Veri seti sınırlıdır.	Sınıflandırma algoritması sayısı ve örnek sayısı artırılmalı
Mustafa Özkan ve Görkem Kar (2022) [47]	Yükseköğretim Kurulu Ulusal Tez Merkezi Veri Tabanı	1.560 Örnek	BERT	Doğruluk:%97 Kesinlik:%100 Duyarlılık:%98, F1-Skoru: %99	Makine öğrenmesi kullanılmamıştır. Veri seti sınırlıdır.	Farklı algoritmaların test edilmesi sağlanmalı ve örnek sayısı artırılmalı
Ahmet Albayrak ve Adham Jolosı Jolosı Zada (2023) [48]	Bir e-ticaret plat-formu	2.237 Örnek	RO, AdaBoost	Doğruluk:%87.9	Derin öğrenme kullanılmamıştır.	Farklı algoritmaların kullanılarak çeşitlilik arttırılmalı ve örnek sayısı artırılmalı
Yasin Görmez, Halil Arslan ve Bilal Atak (2024) [49]	Winvoker ve Beyazperde	500.306 Örnek (Winvoker Pozitif: 262.166 Negatif: 56.561 Nötr: 170.917, Beyazperde Pozitif: 5.331 Negatif: 5.331)	ESA	Doğruluk:%94,16 Kesinlik:%91,75 Du-yarlılık:%89,58, F1-Skoru: %90,58 (Transformer ve ESA hibrit modeliyle en yüksek sonuç)	Makine öğrenmesi kullanılmamıştır. Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Farklı algorit-maların testi sağlanmalı ve karşılaştırmalar yapılmalı
Nurcan Yücel ve Özge Cömert (2023) [50]	Hepsiburada, n11 ve Trendyol	2.000 Örnek (olumlu: 1.000, Olumsuz: 1.000)	UKSB	Doğruluk:%91,5 Özgüllük:%86,92 Du-yarlılık:%96,77, F1-Skoru: %91,37	Makine öğrenmesi kullanılmamıştır. Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Farklı algoritmaların test edilmesi sağlanmalı ve örnek sayısı artırılmalı
Zeynep Hilal Kil-imci (2020) [51]	Twitter	54.052 Örnek (Negatif: 38.529 , Pozitif: 12.047)	ESA, TSA, UKSB	Doğruluk:%82,27 Özgüllük:%78,92 Has-sasiyet:%79,96 (İngilizce veri kümesi ve STCK ile en yüksek sonuç)	Veri seti dengesiz. Algoritma sayısı yetersiz.	Dengeli veri seti kullanılmalı ve farklı algoritmaların testi yapılmalı

TABLE II: Literatür Taraması Sonuçları

Makale Yazarlar (Yıl)	Veri Seti	Örnek Sayıları	Yöntemler	Sonuçlar	Eksiklikler	Gelecek Katkıları
Mehmet Umut Salur ve İlhan Aydın (2022) [52]	Twitter	14.777 Örnek (Pozitif: 6.887, Negatif: 7.890)	UKSB	Doğruluk:%75,71 Duyarlılık:%65,37 F1-Skoru: %71,20 Kappa: %51,48 ROC-AUC: %74,93 (En yüksek başarı BiLSTM ile)	Makine öğrenmesi kullanılmamış	Farklı algoritmaların test edilmesi sağlanmalı ve örnek sayısı artırılmalı
Abdülkadir Tepecik ve Engin Demir (2022) [53]	Common Voice	20.760 Örnek	NB, RO, DVM, KA, KEYK	Doğruluk:%69,60 F1-Skoru:%71 Duyarlılık:%71 (DVM ile en yüksek sonuçlar)	Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Örnek sayısı ve çeşitliliği artırılmalı
Serpil Aslan (2022) [54]	Twitter	176.345 Örnek	DVM, RO, LR	Doğruluk:%94 Kesinlik:%96 Hatırlatma:%95 F1-Skoru: %96	Veri setinin pozitif negatifliği hakkında bilgi verilmemiş	Hibrit model kullanımı arttırılmalı
Mesut Toğaçar, Kamil Abdullah Eşidir ve Burhan Ergen (2022) [20]	Kaggle-REAL or FAKE News Dataset	6335 Örnek (Gerçek: 3171, Sahte: 3164)	UKSB	Doğruluk:%91,48 Özgüllük:%92,88 Hassasiyet:%92,76, Duyarlılık: %92,88, F1-Skoru: %91,55	Makine öğrenmesi kullanılmamıştır.	Farklı algoritmaların test edilmesi sağlanmalı ve örnek sayısı ve çeşitliliği artırılmalı
Zeynep Orman ve Mehmet Can Yılmaz (2021) [55]	Twitter	485.000 Örnek	UKSB	Doğruluk:%99	Derin öğrenme kullanılmamıştır. Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Farklı algoritmaların test edilmesi sağlanmalı ve veri ön işlemesi daha detaylı yapılmalı
Anıl Utku, Serim Gençaslan ve M. Ali Akcayol (2020) [56]	UCF-101 veri seti	13.320 Örnek	KSA, VGG-19	Doğruluk:%83 Kesinlik:%85 Duyarlılık:%82, F1-Skoru: %83 (VGG-19 ile en yüksek sonuç)	Diğer ileri düzey algoritmalarla karşılaştırma yapılmamıştır.	Hibrit modeller kullanılmalı ve örnek sayısı arttırılmalı
Murat İnce (2021) [57]	MS-COCO veri seti	300.000 Örnek	TSA, KSA	Doğruluk:%81,95 Kesinlik:%81,12 Duyarlılık:%82 F1-Skoru: %81,33	Veri seti çeşitliliği azdır.	Farklı dillerde örnekler çalışmaya dahil edilmeli
Ebru Somuncu ve Nesrin Aydın Atasoy (2022) [58]	Synth90k veri seti	90.000	ÇYUKSB, ESA, TSA, ETSA	Doğruluk:%96 (ETSA ile en yüksek sonuç)	Veri seti kısıtlıdır.	Algoritmalar üzerinde iyileştirmeler kullanılarak doğruluk arttırılmalı
Enver Yazğılı ve Muhammet Baykara (2022) [26]	Kaggle	3.000 Örnek (Pozitif: 1503, Negatif: 1497)	RO, C-4.5, DVM, NB, LR, YSA, KEYK, KOK	Doğruluk:%88.35 Kesinlik:%88,93 Hassasiyet:%87,75 F1-Skoru: %88,33 (LR ile en iyi sonuç)	Veri seti yetersizdir. Derin öğrenme kullanılmamıştır.	Örnek sayısı artırılmalı ve derin öğrenme algoritmaları kullanılmalı

TABLE III: Literatür Taraması Sonuçları

yöntemleri kullanılmamış ve veri setinin boyutu sınırlı kalmıştır. Gelecek çalışmalarda, veri setinin çeşitliliğinin ve boyutunun artırılması ve derin öğrenme tabanlı sınıflandırma algoritmalarının kullanılmasıyla daha kapsamlı bir duygu analizi yapılması hedeflenmektedir [39].

Önder ve ark. (2022), YouTube kullanıcı yorumlarından elde ettikleri 15.082 örneği kullanarak bir duygu sınıflandırma çalışması gerçekleştirmiştir. Naive Bayes algoritması ile yapılan bu sınıflandırmada veriler pozitif (5.167), negatif (4.644) ve nötr (5.271) olmak üzere üç duygu kategorisine ayrılmıştır. WEKA ile yapılan analiz sonucunda %65,56 doğruluk oranı elde edilmiştir. Bu çalışmanın dikkat çekici yönü, yorumların farklı dillere çevrilerek sınıflandırmanın gerçekleştirilmiş olmasıdır. Böylece çok dilli duygu analizine katkı sağlanmıştır. Gelecek çalışmalarda Naive Bayes yerine Destek Vektör Makineleri (DVM), K-En Yakın Komşu (KNN), Uzun Kısa Süreli Bellek (UKSB), Yapay Sinir Ağları (YSA) ve BERT gibi daha gelişmiş algoritmaların kullanılması önerilmektedir. Ayrıca, farklı dillere çeviri için Yandex API gibi araçlardan yararlanılabilir [23].

Cengiz (2022), *COVID-19* sahte haber veri setinden elde ettiği 10.700 örnek veri ile sahte haberlerin sınıflandırılmasına yönelik bir çalışma gerçekleştirmiştir. Çalışmada Çok Katmanlı Algılayıcı (ÇKA), Uzun Kısa Süreli Bellek (UKSB), Tekrarlayan Sinir Ağı (TSA) ve Evrişimli Sinir Ağı (ESA) algoritmaları kullanılmıştır. İlk aşamada sahte haber tespiti için GloVe kelime gömme tekniği uygulanmış, ardından sınıflandırma algoritmaları devreye alınmıştır. Bu sayede, sahte haber tespiti gibi güncel ve zorlu bir göreve yönelik performanslar kapsamlı bir şekilde değerlendirilmiştir. Çalışma, farklı kelime gömme yöntemleri ve sinir ağı tabanlı sınıflandırıcıların başarılarını karşılaştırarak bu alandaki önemli bir boşluğu doldurmayı amaçlamaktadır. Gelecek çalışmalarda, örnek veri sayısının artırılmasıyla daha gerçekçi ve tutarlı sınıflandırma sonuçları elde edilmesi hedeflenmektedir [40].

Feyza ve ark. (2020), ISOT veri setinden elde ettikleri 44.898 örnek ile sahte haber tespiti için bir sınıflandırma modeli oluşturmuştur. Çalışmada veri seti 4 deney grubuna ayrılmış ve 10 farklı yapay zekâ algoritması kullanılmıştır. Bu algoritmalar arasında Naive Bayes (NB), Jrip, J48, Rastgele Orman (RO), Stokastik Gradyan İnişi (SGİ), Yerel Ağırlıklı Öğrenme (YAÖ), Naive Bayes ile Karar Ağacı (NBiKA), Yerine Koyarak Öğrenme (YKÖ) ve Regresyon ile Sınıflandırma (RiS) yer almaktadır. Deneyler sonucunda en yüksek doğruluk oranı %97,5 ile Rastgele Orman (RO) algoritmasıyla elde edilmiştir. Bu çalışma, denetimli yapay zekâ algoritmalarının gerçek veri seti üzerinde toplu performansını inceleyen ilk araştırmalardan biridir. Gelecek çalışmalarda, derin öğrenme algoritmalarının kullanılmasıyla daha iyi sonuçlar elde edilebileceği öngörülmektedir. Ayrıca, sahte haber tespitine yönelik daha performanslı ve etkili sistemlerin geliştirilmesi planlanmaktadır [41].

Doğancan ve ark.(2021), 1150Haber, Hürriyet6c-1k, ve Milliyet-9c-1k veri setlerinden elde ettikleri 36.150 veri setini kullanarak kelime gömmesi yaparak bir sınıflandırma modeli oluşturmuşlar. Öncelikle TF-IDF ile kelime ağırlıklandırma yapmışlar sonra Word2Vec ve Doc2Vec kullanarak kelime gömmesi yamışlar. Elde ettikleri veriler üzerinde Naive Bayes (NB), K-En Yakın Komşu(KEYK), Lojistik Regresyon (LR), Karar Destek Makineleri (KDM), Karar Ağaçları (Decision Trees- DT, KA), Çok Katmanlı Algılayıcılar (Multi-Layer Perceptrons- MLP, ÇKA) algoritmalarını kullanarak sınıflandırma yapmışlardır. En iyi sonuç TF-IDF ağırlıklandırması ile LR, KDA, ÇKA algoritmalarında elde edilmiştir. Bu çalışmanın literatüre katkısı sınıflandırmaya geçmeden önce ağırlıklandırma ve kelime gömmesi yapmanın başarı oranını arttırdığıdır [42].

Süleyman ve ark. (2021), Twitter'dan topladıkları 76.738 örneği kullanarak sahte haber tespiti üzerine bir sınıflandırma modeli geliştirmiştir. Çalışmada kelime temsili için TF-IDF, Word2Vec ve Doc2Vec yöntemleri kullanılmış; sınıflandırma işlemi K-En Yakın Komşu (KNN), Destek Vektör Makineleri (DVM) ve Rastgele Orman (RO) algoritmaları ile gerçekleştirilmiştir. Bu çalışmanın önemli bir katkısı, sahte haberlerin çok kısa sürede tespit edilmesine olanak sağlamasıdır. Ayrıca, sosyal medya platformlarında kullanıcıların takipçileri ve takip ettikleri hesapların analiz edilmesiyle, hesapların sahte olup olmadığının değerlendirilmesi mümkündür. Gelecekteki çalışmalarda, bu takipçi verilerinin otomatik tespit sistemlerine girdi olarak eklenmesi, algoritmaların performansını iyileştirebilir ve F1-Skorlarını artırabilir [43].

Yunus (2020), Hepsiburada online alışveriş sitesinden almış olduğu 243.000 veri setini kullanarak kullanıcı yorumlarını sınıflandırmak adına bir model oluşturmuş. Kelime çantası, TF-IDF, N-gram, Word2vec, Fasttex, GloVe kelime gömmelerini kullanarak metin verilerinin sayısallaştırılarak temsilini sağlamış. Evrişimsel Sinir Ağı (ESA), Uzun Kısa Süreli Bellek (UKSB) ve Geçitli Tekrarlayan Birim (GTB) kullanarak verileri sınıflandırmıştır. Veri setinin dengesiz olması ürünlerden memnun olmayan müşterileri ve şikâyet edilen ürünlerin tespitini zorlaştıracaktır. Gelecekte dengesiz metin veri setini dengeleyerek derin öğrenme algoritmaları kullanan yaklaşımların geliştirilmesi planlanmaktadır [44].

Gözde ve ark. (2021), Twitter, Instagram ve YouTube kullanıcı yorumlarından elde ettikleri 180.000 veri ile bir sınıflandırma modeli geliştirmiştir. Çalışmada, derin öğrenme tabanlı FastText, Word2Vec ve Doc2Vec kelime gömme modelleri kullanılmış ve bu modellerin başarıları karşılaştırılmıştır. En yüksek doğruluk oranı %93,15 ile FastText modeliyle elde edilmiştir. Ayrıca, FastText modeli ile Uzun Kısa Süreli Bellek (UKSB) sinir ağı kullanılarak sosyal medya yorumlarının siber zorbalık açısından sınıflandırılması gerçekleştirilmiştir. Gelecekteki çalışmalarda, veri seti üzerinde farklı makine öğrenmesi yöntemlerinin uygulanması ve bu yöntemlerin sonuçlarının karşılaştırılması önerilmektedir [45].

Ali ve ark.(2022), Kaggle Audio Cats and Dogs veri setinden aldığı 277 ses kaydı örneğini kullanarak bir sınıflandırma modeli oluşturmuşlar. Veriler üzerinde özellik çıkarımı yaptıktan sonra Uzun Kısa Süreli Bellek (UKSB) ile örnekleri sınıflandırmış ve modeli Evrişimsel Sinir Ağı (ESA) ile desteklemişler. En iyi sonuç %91 ile UKSB algoritmasında elde edilmiştir. Çalışmanın eksik yanı kullandığı kütüphanenin sadece İngilizce kelime türetmesidir. Gelecek çalışmalarda büyük veri seti ve farklı canlılara ait sesler kullanılması planlanmaktadır [46].

Mustafa ve ark.(2022), Yükseköğretim Kurulu Ulusal Tez Merkezi Veri Tabanından aldıkları 1.560 tez verisi ile bir metin sınıflandırma modeli oluşturmuşlar. Veri seti Tokenizer ve ince ayar yapılacak önceden eğitilmiş bir model ile ön işleme aşamasından geçtikten sonra BERT modeli ile Türkçe dilinde sınıflandırma yapılmıştır. Gelecek çalışmalarda veri setinin genişletilmesi, kategori sayısının arttırılması ve ön işleme aşamasının daha da detaylandırılması planlanmaktadır [47].

Ahmet ve ark.(2023), bir e-ticaret sitesinden almış olduğu 2.237 kullanıcı yorum verisinin E-ticaret platformlarında kullanıcı yorumlarının ve verilen puanların tutarlılığını analiz etmek amacıyla sınıflandırmasını yapmak üzere bir model oluşturmuş. Öncelikle veri setini VADER kullanarak temizlemiş ve analiz edilecek hale getirmişler. Yorumları sınıflandırmak için Rastgele Orman ve Ad-

aBoost algoritmalarını kullanmışlar. En başarılı sonuç %87,9 ile Rastgele Orman algoritmasıyla elde edilmiştir. Çalışmanın eksikliği derin öğrenme ve farklı makine öğrenmesi algoritmaları kullanılmaması ve farklı metriklerin hesaplanmamasıdır. Gelecek çalışmalarda veri sayısı arttırılarak derin öğrenme algoritmalarının genişletilmiş veri üzerinde kullanılması planlanmaktadır. Daha fazla performans metriği (özellikle F1 skoru, hassasiyet, özgüllük) ile karşılaştırmalar yapılabilir [48].

Yasin ve ark.(2024), Winvoker ve Beyazperde veri setlerinden aldıkları 500.306 örnek üzerinde sınıflandırmaya yönelik bir model oluşturmuşlar. Transformer ve Evrişimsel Sinir Ağlarını (ESA) kullanarak bir hibrit model oluşturmuşlardır ve en yüksek sonuçları bu model ile Winvoker veri seti üzerinde sınıflandırma yaparak elde etmişler.%94.16 oranında bir doğruluk elde etmişlerdir. Bu çalışmanın literatüre katkısı hibrit modellerin daha iyi sınıflandırma sonucu vermesidir. Kullanılan algoritma sayısı yetersizdir. Gelecek çalışmalarda daha fazla makine ve derin öğrenme algoritmaları ile oluşturulmuş hibrit modeller ile sınıflandırma yapmak daha iyi sonuçlar verebilir [49].

Nurcan ve ark.(2023), Hepsiburada, N11 ve Trendyoldan alınan 2.000 kullanıcı yorumu ile elde edilen bu dengeli veri setinin sınıflandırılmasına dayanan bir model oluşturmuşlar. Veriler üzerinde ön işleme yapıldıktan sonra Uzun Kısa Süreli Bellek (UKSB) ile sınıflandırma gerçekleştirmişler ve %91,5 oranında bir başarı elde etmişler. Eksiklikleri tek algoritma kullanılması ve örnek sayısının az olmasıdır. Gelecek çalışmalarda, yapay zekâ algoritmaları kullanılarak müşteri ürün incelemelerini gerçek zamanlı olarak sınıflayabilen ve müşteri ürün incelemeleri için otomatik olarak skor üretebilen bir model çalışmasının yapılması planlanmaktadır [50].

Zeynep (2020), Twitter'dan topladığı 54.052 veri ile derin öğrenme ve topluluk sınıflandırıcılarını kullanarak bir model oluşturmuştur. Çalışmada, İstifleme (Stacking, STCK) yöntemi ile Evrişimli Sinir Ağı (ESA), Tekrarlayan Sinir Ağı (TSA) ve Uzun Kısa Süreli Bellek (UKSB) modelleri birleştirilmiş ve bu yeni modelle en iyi sonuç elde edilmiştir. Türkçe veri kümesi için en yüksek doğruluk oranı %79,82, İngilizce veri kümesi için ise %82,27 olarak bulunmuştur. Çalışma, Borsa İstanbul endeksinin hareketini tahmin etmek için Twitter verilerini kullanması, farklı doküman gösterim tekniklerini birleştirmesi ve topluluk sınıflandırmasını derin öğrenme algoritmalarıyla değerlendirmesi açısından literatürdeki ilk çalışma olma özelliğini taşımaktadır. Gelecek çalışmalarda, veri setinin büyütülmesi ve çeşitlendirilmesiyle model performansının artırılması hedeflenmektedir [51].

Mehmet ve ark. (2022), Twitter'dan topladıkları 14.777 tweet ile pozitif ve negatif sınıflandırmaya yönelik bir model geliştirmiştir. Veri ön işleme adımlarının ardından dört farklı model oluşturulmuştur: Model-A (UKSB), Model-B (Çift Yönlü Uzun Kısa Süreli Bellek - ÇYUKSB), Model-C (GRU) ve Model-BERT. En yüksek doğruluk oranı, ÇYUKSB modeli ile elde edilmiştir. Bu çalışma, önceki çalışmalara kıyasla sınıflandırma doğruluğunu %10 oranında artırarak önemli bir iyileşme sağlamıştır. Gelecek çalışmalarda, önerilen modelin farklı veri temsil yöntemleri üzerindeki performansının araştırılması planlanmaktadır [52].

Abdülkadir ve ark. (2022), Common Voice platformundan topladıkları 20.760 ses örneğini pozitif ve negatif olarak sınıflandırmak için bir model geliştirmiştir. Çalışmada, veriler BERT modeli kullanılarak pozitif ve negatif olarak etiketlendikten sonra, Naive Bayes (NB), Destek Vektör Makineleri (DVM), Rastgele Orman (RO), Karar Ağacı (KA) ve K-En Yakın Komşu (KNN) algoritmaları ile analiz edilmiştir. En iyi sonuç, %69,60 doğruluk oranı ile DVM algoritması ile elde edilmiştir. Gelecek çalışmalarda, Türkçe için BERT modelinin performansını artırmak amacıyla modele Türkçe durak kelimeler, Türkçe kelime yapıları ve skor mekanizmalarının eklenmesi önerilmektedir [53].

Serpil (2022), Twitter üzerinden aldığı 176.345 Covid-19 aşısı hakkındaki tweet ile duygu analizi üzerine bir sınıflandırma modeli oluşturmuş. GloVe ve TF-IDF kelime gömmelerini kullanarak BiGRU-CNN hibrit modelini oluşturmuş ve verileri bu model üzerinden sınıflandırmış. Sınıflandırma algoritması olarak Evrişimli Sinir Ağı (ESA, CNN), Destek Vektör Makineleri (DVM), Rastgele Orman (RO), Lojistik Regresyon (LR) kullanmıştır. En başarılı sonuçlar BiGRU-CNN hibrit modeli ile elde edilmiştir. %94 oranında bir doğruluk elde etmiştir. Bu çalışmada hibrit model kullanımının doğruluk değerini arttırdığı görülmektedir. Modelin hata analizi yapılmamış. Gelecek çalışmalarda sahte hesapları ve yanlış bilgileri tespit edip sosyal medyaya müdahale etmek için derin öğrenme tabanlı bir sistem geliştirilmesi planlanmaktadır [54].

Mesut ve ark.(2022), Kaggle-REAL or FAKE News Dataset ile elde etmiş oldukları 6335 haberin sahte veya gerçek sınıflandırmasını yapmak üzere Uzun-Kısa Süreli Bellek (LSTM), doğal dil işleme ve GloVe kelime gömmelerini kullanarak bir model oluşturmuş. %91,48 doğruluk değeri elde edilmiştir. Bu çalışma hibrit modellerin kullanılmasının başarı oranını arttıracağını göz önüne koymaktadır. Fakat çalışmada daha fazla derin öğrenme ve makine öğrenmesi algoritmasının testi sağlanabilir. Gelecek çalışmalarda, Türkçe haber sitelerinden oluşturulan veri setleri üzerinde sahte haberlerin ve yanlış bilgilerin tespitini farklı yaklaşımlar ile birlikte analiz etmek planlanmaktadır [20].

Zeynep ve ark. (2021), COVID-19 sürecindeki Türkçe tweetlerden topladıkları 485.000 veri ile duygu analizi yapmak için bir sınıflandırma modeli geliştirmiştir. Veri ön işleme aşamasında gereksiz tweetler ve kelimeler çıkarılmış, ardından Uzun Kısa Süreli Bellek (UKSB) modeli kullanılarak %99 doğruluk oranında başarılı bir sınıflandırma elde edilmiştir. Ancak çalışmada yeterince geniş bir duygu sözlüğü kullanılmamış ve duygu sözlüğündeki kelimeleri içermeyen tweetler veri setinden çıkarılmıştır. Bu durum veri kaybına neden olmuştur. Gelecek çalışmalarda, daha kapsamlı bir duygu sözlüğü ve daha geniş bir veri seti kullanarak etiketleme işleminin yapılmasıyla modelin performansının daha da artırılması hedeflenmektedir [55].

Anıl ve ark.(2023), UCF-101 veri setinden almış oldukları 13.320 video üzerinden olay sınıflandırmak için bir model oluşturmuşlar. Bu çalışmada Konvolüsyonel Sinir Ağları (KSA) kullanılarak yeterli başarı elde edilemediği için VGG-19 modeli ile birlikte öğrenme aktarımı uygulanarak iyileştirme yapılması amaçlanmıştır. Bu yeni model ile %83 doğruluk elde edilmiştir. Gelecek çalışmalarda daha fazla algoritmanın testi sağlanabilir [56].

Murat (2021), MS-COCO veri setinden alınan 300.000 örneğin üstverilerini çıkarmak için Konvolüsyonel Sinir Ağları (KSA), Tekrarlayan Sinir Ağları (TSA) ve Doğal Dil İşleme (DDİ) yöntemlerini bir araya getirerek bir model geliştirmiştir. Sistemde, resimlerdeki nesneler KSA ile kodlanmış, ardından TSA ile bu kodlanan özelliklerin metinsel karşılıkları üretilmiştir. Bu model ile %81,95 doğruluk oranına ulaşılmıştır. Çalışma, derin öğrenme ve doğal dil işleme tekniklerini birleştirerek resimlerden metin oluşturma ve bu metinlerin üstveri doldurma sürecini otomatikleştiren yenilikçi bir sistem sunmaktadır. Gelecek çalışmalarda, bu otomatik oluşturulan ve sınıflandırılan üstverilerin kullanılmasıyla otomatik içerik üretiminin sağlanması hedeflenmektedir [57].

Ebru ve ark.(2022), Synth90k veri setinden almış olduğu 90.000 metin görüntüsü üzerinde karakter tanıma uygulaması gerçekleştirilmek için bir model oluşturmuşlar. Sınıflandırma için Çift Yönlü Uzun Kısa Bellek Hafızası (ÇYUKSB), Evrişimsel Sinir Ağı (ESA), Tekrarlayan Sinir Ağı (TSA) ve ESA ile TSA kullanılarak oluşturulan Evrişimsel Tekrarlayan Sinir Ağı (ETSA) algoritmalarını kullanmışlardır. En başarılı sonuç ETSA ile elde edilmiştir. Bu modelin doğruluk değeri başta %94 olarak ölçülüyor. Daha sonra Levenshtein Mesafesi (LM) kullanılarak bu değer %96'ya çıkmıştır. Bu çalışmanın sonuçları, literatürdeki benzer çalışmalarla karşılaştırılmış ve %96 doğruluk ile yüksek başarı elde edilmiştir. Synth90k veri seti, çoğunlukla İngilizce metinler içermektedir bu da veri setini dolayısıyla da doğruluğu kısıtlayabilir. Gelecek çalışmalarda ETSA mimarisi ile iç mekan yönlendirme sistemleri geliştirilecek ve mobil cihazlarda kullanılabilir hale getirilecektir [58].

Enver ve ark. (2022), Kaggle platformundan alınan ve manuel olarak oluşturulan 3.000 cümlelik Türkçe veri seti üzerinde doğal dil işleme teknikleri kullanarak siber zorbalık tespiti yapmıştır. Çalışmada Rastgele Orman (RO), C4.5, Destek Vektör Makineleri (DVM), Naive Bayes (NB), Lojistik Regresyon (LR), Yapay Sinir Ağları (YSA), K-En Yakın Komşu (KNN) ve K-Ortalama Kümeleme (KOK) algoritmaları uygulanmıştır. En yüksek doğruluk oranı %88,35 ile Lojistik Regresyon (LR) algoritması ile elde edilmiştir. Veri setinin yeni oluşu ve bu kadar çok algoritmanın bir arada test edilmesi, çalışmanın literatüre önemli bir katkı sağlamasını mümkün kılmaktadır. Çalışmada, Türkçe dilinin morfolojik yapısının doğal dil işleme uygulamalarında yarattığı zorluklara dikkat çekilmiştir. Gelecek çalışmalarda, derin öğrenme algoritmalarının kullanılması ve sosyal medya platformlarında anlık siber zorbalık tespiti yapılması planlanmaktadır [26].

Mevcut literatürde sınıflandırma üzerine yapılan çalışmaların çoğunda veri setlerinin genellikle eksik ve dengesiz olduğu gözlemlenmektedir. Bu durum, sınıflandırma performansını olumsuz etkileyerek elde edilen sonuçların genelleştirilebilirliğini sınırlamaktadır. Ayrıca literatürde kullanılan veri ön işleme ve öznitelik çıkarımı yöntemleri genellikle yüzeysel bir şekilde ele alınmakta ve algoritmaların optimizasyon süreçlerine yeterince odaklanılmamaktadır. Bu çalışmada bu eksikliklere çözüm olarak daha geniş bir veri seti kullanılmıştır. Ayrıca ön işleme için Metin Temizleme, öznitelik çıkarımı için TF-IDF ve öznitelik seçimi için PCA ve Varyans Eşiği Belirleme adımları detaylı bir şekilde yapılmış ve algoritma çeşitliliği artırılarak performans karşılaştırmaları yapılmıştır. Bu yenilikler hem literatürdeki eksiklikleri kapatmayı hem de sınıflandırma alanına katkı sağlamayı hedeflemektedir.

III. METOT

A. Veri Seti

1) Veri Kaynağı: Bu çalışmada, Kaggle platformundan alınan ve finansal haberlerin duygu analizi için kullanılan "Sentiment Analysis for Financial News" veri seti kullanılmıştır [60]. Veri seti, herkese açık finansal haberlerden oluşmakta ve sınıflandırma problemleri için kullanılmaktadır.

2) Veri Tipi: Veri seti, iki sütundan oluşmaktadır. İlk sütun, haber başlıklarının duygu etiketlerini (nötr, pozitif, negatif) içeren kategorik bir veri türüdür. İkinci sütun ise haber başlıklarını içeren metin (string) veri türündedir.

3) Veri Boyutu: Veri seti toplamda 4.845 satır ve 2 sütun içermektedir. Duygu etiketlerinin dağılımı; 2.878 nötr (%59,4), 1.364 pozitif (%28,1) ve 604 negatif (%12,5) şeklindedir. Bu durum veri setinin dengesiz bir yapıya sahip olduğunu göstermektedir.

B. Veri Ön İşleme

Veri ön işleme, işlenmemiş verilerin makine öğrenmesi ve veri analitiği için kullanılabilir bir forma dönüştürülmesi sürecidir. Bu süreç verideki gereksiz detayları, boşlukları doldurmayı, ölçeklendirme yapmayı ve veriyi modelleme için hazırlamayı kapsar. Amaç, daha doğru, etkili ve verimli modeller oluşturulmasını sağlamaktır. Veri Ön İşlemenin Önemi; veri kalitesini artırması, model performansını iyileştirmesi, hesaplama verimliliği sağlaması ve genellenebilirliği artırması örnekleri verilebilir.

Çalışmamızda metin temizleme ile küçük harfe dönüştürme, noktalama işaretlerini kaldırma, sayıları temizleme. TF-IDF ile öznitelik çıkarımı ile metinleri sayısal verilere dönüştürme yapılmıştır. Varyans eşik yöntemi ile de düşük varyansa sahip özniteliklerin çıkarılması sağlanmıştır. Etiketlerin sayısal forma dönüştürülmesi ile duygu sınıflarının 0, 1, 2 olarak kodlanması işlemleri yapılmıştır. Bu adımlar, verinin model için uygun hale getirilmesini sağlamış ve veri analitiği, makine öğrenimi ve diğer veri odaklı çalışmalarda doğru ve güvenilir sonuçlar elde etmek için önemli bir adım atılmıştır.

C. Ölçekleme

Ölçekleme, veri setindeki sayısal değerlerin belirli bir aralıkta (örneğin, 0 ile 1 arasında) veya belirli bir dağılımda dönüştürülmesi işlemidir. Makine öğrenimi modellerinde verilerin uygun bir dağılımda olması özellikle bazı algoritmaların daha iyi performans göstermesi için çok önemlidir. Ölçeklemenin Amacı; Model Performansını Artırmak, tüm özelliklerin aynı ölçekte olması durumunda hızlı ve dengeli öğrenme sağlamak ve K-En Yakın Komşu (KNN) ve Destek Vektör Makineleri (SVM) gibi mesafe hesaplamasına dayalı algoritmalar için farklı ölçeklerdeki veriler düzenleyerek yanlış mesafe hesaplamalarının önüne geçmektir.

Ölçekleme yöntemlerinden; verileri, belirli bir aralığa (genelde [0,1]) dönüştüren Min-Maks Ölçekleme (Normalization)

Formül:

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \tag{1}$$

ve verileri, ortalaması 0 ve standart sapması 1 olacak şekilde dönüştüren Z-Score Ölçekleme (Standardization) incelenmiştir.

Formül:

$$X' = \frac{X - \mu}{\sigma} \tag{2}$$

Burada μ ortalama, σ ise standart sapmadır.

Ancak veri setimizdeki haber başlıkları TF-IDF ile sayısal bir vektör haline getirildiğinde, bu vektörler genelde aynı aralıkta (örneğin, 0 ile 1 arasında) olur.Ancak TF-IDF vektörleri zaten normalize olduğu için, ek bir ölçekleme genelde gerekmez.

D. Öznitelik Seçimi

Öznitelik seçimi, bir veri setindeki tüm özellikler arasından modelin performansını en fazla etkileyen ve analiz için en önemli olan özellikleri belirleme sürecidir. Bu işlem, veri kümesindeki gereksiz ve fazlalık öznitelikleri ortadan kaldırarak daha verimli ve doğru bir model oluşturmayı hedefler.

*1) **TF-IDF Yöntemi**:* Haber başlıklarından öznitelik çıkarımı için TF-IDF (Term Frequency-Inverse Document Frequency) yöntemi kullanılmıştır. TF-IDF yöntemi, haber başlıklarındaki kelimeleri öznitelikler olarak belirlemiş ve her bir kelimenin bir başlıktaki önemini, frekansı (TF) ve diğer başlıklar arasındaki nadirliğini (IDF) dikkate alarak hesaplamıştır. En sık kullanılan 5000 kelimenin öznitelik olarak seçildiği bu işlem sonucunda, her haber başlığı, 5000 öznitelikten oluşan bir TF-IDF vektörü ile temsil edilmiştir. Oluşturulan TF-IDF öznitelik matrisi, (4845, 5000) boyutunda olup, satırlar haber başlıklarını, sütunlar ise kelime tabanlı öznitelikleri ifade etmektedir.

*2) **Varyans Eşiği Belirleme (VEB)**:* Buradaki önemli öznitelikleri seçmek model karmaşıklığını azaltma için Öznitelik Önemine Göre Seçim (Feature Importance) ve Varyans Eşiği Belirleme yöntemleri incelenmiştir. Öznitelik Önemine Göre Seçim (Feature Importance), bir modelin her bir özelliği (değişkeni) hedef değişken üzerindeki etkisine göre sıralaması ve bu sıraya göre en anlamlı özniteliklerin seçilmesidir. Bu yöntem, özellikle karar ağaçları ve rastgele ormanlar gibi modellerde, özniteliklerin hedef değişken üzerindeki etkisini belirlemek için kullanılır. Varyans Eşiği Belirlemede ise özniteliklerin varyans değerlerini ölçerek düşük varyansa sahip olanları veri setinden çıkarma yöntemidir. Bir öznitelik yalnızca belirli bir varyans eşiğini aşıyorsa seçilir; düşük varyanslı öznitelikler genellikle model için bilgi taşımadığı kabul edilir. Seçtiğimiz yöntem olan Varyans Eşiği Belirleme ile özelliklerin varyansını hesaplayarak düşük varyansa sahip özellikler çıkartılmıştır. Bu işlem sonucunda öznitelik sayısı 2250'ye indirilmiştir.

*3) **Temel Bileşenler Analizi (PCA)**:* Temel Bileşenler Analizi (PCA - Principal Component Analysis), yüksek boyutlu veri setlerinden daha az boyutlu bir form oluşturarak en önemli bilgi parçalarını yakalamayı hedefleyen bir tekniktir. Çalışmada PCA'nın Kullanım Alanlarından olan Doğal Dil İşleme (NLP)'deki Metin verilerindeki boyutları azaltmak ve kelime vektörlerini sadeleştirmek için kullanılmıştır.

TF-IDF ile oluşturulan 2250 boyutlu öznitelik matrisi PCA uygulanarak 100 temel bileşene indirgenmiştir. Bu 100 bileşen veri setindeki PCA'nın toplam veri varyansının %27.38'ini açıklayabildiği hesaplanmıştır. PCA kullanımıyla boyut azaltma yapıldığında ve yapılmadığında model performansını karşılaştırmak için 2 farklı deneme yapıldı ve PCA yapılmadan önceki doğruluk performansının daha yüksek olduğu gözlemlendi.

E. Veri Seti Ayrımı ve K-Fold Çapraz Doğrulama

Veri seti ayrımı, makine öğrenimde kullanılan temel bir adımdır ve modelin eğitim ve test aşamalarında kullanılmak üzere veri setini iki ya da daha fazla parçaya bölmeyi içerir. Bu süreçte veri seti genellikle eğitim seti ve test seti olarak ikiye ayrılır. Eğitim seti, modelin öğrenmesi için kullanılır ve model bu verilerden bağıntılar çıkarır. Test seti ise modelin performansını değerlendirmek amacıyla, eğitim sırasında görülmeyen verilere uygulanır.

K-Fold Çapraz Doğrulama (K-Fold Cross Validation), modelin performansını daha güvenilir bir şekilde değerlendirmek için kullanılan gelişmiş bir yöntemdir. Bu yaklaşımda veri seti K eşit parçaya (fold) bölünür. K iterasyon boyunca her bir fold, sırayla test seti olarak kullanılırken kalan K-1 fold eğitim seti olarak kullanılır. Bu süreç sonucunda, her veri noktası bir kez test setinde, K-1 kez eğitim setinde yer almış olur. K iterasyonda elde edilen performans sonuçları ortalanarak, modelin genelleştirme yeteneği daha güvenilir bir şekilde ölçülür. Veri seti ayrımı ve K-Fold Çapraz Doğrulama arasındaki temel fark, veri bölme yönteminde yatmaktadır. Basit veri seti ayrımı, veriyi bir kez eğitim ve test seti olarak bölerken, K-Fold Çapraz Doğrulama veri setini birden fazla kez farklı şekillerde böler. K-Fold, veri setinin tamamını hem eğitim hem de test için kullanarak daha kapsamlı bir değerlendirme sağlar. Bu yöntem, özellikle veri setinin küçük olduğu durumlarda ya da sınıf dengesizliklerinin bulunduğu veri kümelerinde avantajlıdır.

K-Fold Çapraz Doğrulama dışında veri ayırma yöntemleri olan veri setini eğitim ve test olmak üzere sabit oranlarda ikiye ayırarak model değerlendirmesi yapan Eğitim-Test Ayrımı (Train-Test Split) yöntemi, her bir veri noktası sırayla test seti olarak kullanan ve geri kalanlar eğitim için ayıran LOOCV yöntemi, veri setini rastgele bir şekilde, belirli bir oranda eğitim ve test setlerine bölen Shuffle Split gibi yöntemler incelenmiş ama K-Fold Çapraz Doğrulama ile daha geniş bir değerlendirme yapmak istendiğinden dolayı diğer yöntemler kullanılmamıştır.

Modelin performansını değerlendirmek amacıyla K-Fold Çapraz Doğrulama yöntemi tercih edilmiştir. Çalışmada K = 5 olarak belirlenmiş ve veri seti her iterasyonda 5 eşit parçaya bölünmüştür. Her iterasyonda, 4 parça eğitim için ve 1 parça test için kullanılarak doğruluk oranları hesaplanmıştır. PCA kullanılarak ve kullanılmadan yapılan değerlendirmelerin sonuçları şu şekilde özetlenir PCA Olmadan Ortalama doğruluk: %76.57, Standart sapma: %0.61 PCA Kullanılarak Ortalama doğruluk: %71.76, Standart sapma: %0.63. Sonuçlar PCA kullanılmadan daha yüksek doğruluk elde edildiğini göstermiştir.

F. Model Seçimi

Makine Öğrenmesi

Makine öğrenmesi, bir bilgisayarın verilerden öğrenmesini sağlayan ve bu öğrenmeyi, belirli bir görevi yerine getirmek için kullanan matematiksel bir model ya da yöntemdir [61]. Makine öğrenmesi algoritmaları, bir girdi verisini belirli bir sınıfa veya etikete atamak amacıyla kullanılır [62]. Makine öğrenmesinin önemli yönleri genelleme yapabilmesi,kendiliğinden çalışabilmesi, zamanla gelişmesi, otomatik öğrenme ve iyileştirme yapabilmesidir. Bu çalışmada kullanılan makine öğrenmesi algoritmaları Naive Bayes, Destek Vektör Makinesi, Lojistik Regresyon, Rastgele Orman ve K-En Yakın Komşu'dur.

*1) **Naive Bayes (NB)**:* Naive Bayes Sınıflandırıcısı, Bayes Teorimi'ne dayanan[29] basit ama etkili bir sınıflandırma algoritmasıdır[33] ve makine öğrenmesi uygulamalarında yaygın olarak kullanılır [63]. Özellikle doğal dil işleme (NLP) uygulamalarında tercih edilir, bunlar metin sınıflandırma, dil tanıma ve belge benzerliği gibi görevlerdir. Bu model, "naive" (saf) olarak adlandırılır çünkü her özelliğin birbirinden bağımsız olduğunu düşünür, bu da gerçek dünyadaki veriler için doğru olmayan bir varsayımdır. Ancak bu basitleştirilmiş varsayım gerçek hayatta oldukça iyi sonuçlar verir. Naive Bayes, NLP alanında bazı temel tekniklerle birlikte çalışır. Bunlar eldeki veriyi sayısal hale getirmek için kelimeleri sırasız bir şekilde vektörleştiren ve her kelimeyi bir özellik olarak kabul eden "kelime çantası (bag of words)"[64], kelimelerin önemini ölçmek için kullandığı "TF-IDF(Term Frequency – Inverse Document Frequency" tekniği[35] ve genellikle her kelimeyi özellik olarak kabul eden ancak, bazı durumlarda yalnızca belirli kelimeler seçerek modelin performansı artıran "öznitelik seçimi" kullandığı tekniklerden bazılarıdır [65].Naive Bayes bir olasılıksal (probabilistic) modeldir ve sınıf tahminleri doğrudan olasılık hesaplamalarına dayanır. Bu nedenle, herhangi bir doğrusal veya doğrusal olmayan aktivasyon fonksiyonu kullanmaz. Naive Bayes'in diğer algoritmalara göre avantajları hızlı

ve basit olması , düşük bellek tüketimi , başarı oranı ve yüksek verimliliği söylenebilir . Dezavantajları ise özelliklerin birbirinden bağımsız olduğunu varsaymak her zaman doğru olmayabilir ve genellikle sayısal verilerle daha iyi çalışırken kategorik verilerle sınırlı olabilir.

$$P(C|X) = \frac{P(X|C) \cdot P(C)}{P(X)} \tag{3}$$

- $P(C|X)$: Verilen veriler X altında sınıf C için koşullu olasılık.
- $P(X|C)$: Sınıf C altında veriler X olasılığı.
- $P(C)$: Sınıf C için önceden bilinen olasılık.
- $P(X)$: Veriler X için genel olasılık.

*2) **Destek Vektör Makineleri (DVM)**:* Destek Vektör Makineleri (DVM), sınıflandırma analizlerinde kullanılan etkili bir denetimli öğrenme algoritmasıdır [30]. DVM, veriyi farklı sınıflara bölen en uygun doğrusal ayırıcıyı bulmayı hedefler. Katman sayısı sıfırdır. Her veriyi yüksek boyutlu bir uzaya çevirerek veriler arasındaki sınırı daha net bir şekilde ayırmaya çalışır. DVM'nin temel bileşenleri; verileri iki sınıfa ayıran çizgi "hiper düzlem", hiper düzleme en yakın olan ve sınıflandırma için kullanılan veriler "destek vektörleri" ve verilerin daha yüksek bir boyutta ayırabilmek için "çekirdek fonksiyonu" dur [66]. DVM, doğal dil işleme alanlarında(DDİ) metin madenciliği, duygu analizi ve metin sınıflandırma gibi görevlerde kullanılır. DVM'nin diğer algoritmalara göre avantajları yüksek boyutlu verilerde daha iyi performans göstermesi, genelleme yeteneği ve doğrusal olmayan verilerde iyi sonuçlar vermesi söylenebilir. Dezavantajları ise ayarların karmaşıklığı, büyük veri setlerinde yavaşlık ve sınıflar arası dengesizlik varsa çoğunluğu tercih etmesidir [67].

$$\mathbf{w} \cdot \mathbf{x} + b = 0 \tag{4}$$

Burada:

- $\mathbf{w}$: Hiperdüzlemin normal vektörü (ağırlık vektörü),
- $\mathbf{x}$: Veri noktası,
- b: Bias terimi.

*3) **Lojistik Regresyon (LR)**:* Lojistik Regresyon, genellikle sınıflandırma problemleri için kullanılan, doğrusal ve basit bir modeldir. Adı "regresyon" olsa da, aslında temel olarak bir sınıflandırma işlemi yapar. LR, özellikle ikili sınıflandırma (binary classification) problemlerinde yaygın olarak kullanılır [68]. Örneğin, bizim konumuz olan haberlerin sınıflandırılmasında haberler ya pozitiftir ya da negatiftir. LR'nin doğrusal ve basit olması modelin anlaşılmasını kolaylaştırır ve yorumlanabilirliğini artırır. Diğer karmaşık modellerden daha hızlı çalışır. Bu da, büyük veri setlerinde hızlı sonuçlar almak için avantaj sağlar. Lojistik regresyon, genellikle tek katmanlı (single-layer) bir modeldir. Modelin temel yapısı doğrusal bir fonksiyondan oluşur ve sonrasında sigmoid aktivasyon fonksiyonu ile sonuç elde edilir. Bu nedenle, lojistik regresyonun katman sayısı 1'dir.

$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) \tag{5}$$

Burada:

- $\hat{y}$: Modelin tahmin ettiği olasılık (0 ile 1 arasında bir değer).
- $\sigma(z) = \frac{1}{1+e^{-z}}$: **Sigmoid** fonksiyonu, modelin doğrusal çıktısını 0 ile 1 arasında bir olasılığa dönüştürür.
- $\mathbf{w}$: Ağırlık vektörü (modelin öğrenmeye çalıştığı parametreler).
- $\mathbf{x}$: Özellik vektörü (bağımsız değişkenler).
- b: Bias terimi (eğitim sürecinde öğrenilen bir parametre).

*4) **Rastgele Orman (RO)**:* Rastgele orman, güçlü, esnek ve dayanıklı bir makine öğrenmesi algoritmasıdır. Karar ağaçlarının topluluğu olarak, hem sınıflandırma hem de regresyon problemleri için etkili bir çözüm sunar [69]. Büyük veri setleri üzerinde yüksek doğrulukla çalışabilir ve aşırı öğrenme (overfitting) sorununu minimize eder. Ancak, modelin yorumlanabilirliği zayıf olabilir ve hesaplama maliyetleri yüksek olabilir. Birçok karar ağacının birleşimi genellikle tek bir karar ağacından çok daha iyi sonuçlar verir. Bu da RO algoritmasının doğruluğunu artırır. Aşırı öğrenmeyi (overfitting) minimize etmek için Bootstrap Birleştirmesi kullanır ve farklı ağaçlar oluşturur [70]. Rastgele Orman'da doğrudan bir "katman" sayısı tanımlanmaz. Bunun yerine, Karar Ağaçlarının sayısı, katman sayısı gibi düşünülebilir. Bu sayede, çok sayıda karar ağacının birleşimiyle daha güçlü ve güvenilir bir model elde edilir.

Sınıflandırma İçin:

$$\hat{y} = \text{mode}\left(f_1(x), f_2(x), \ldots, f_M(x)\right) \tag{6}$$

Burada:

- $\hat{y}$: Nihai tahmin (çoğunluk oylaması ile belirlenir).
- $f_i(x)$: i-inci karar ağacının tahmini.
- M: Karar ağacının toplam sayısı (topluluk büyüklüğü).

*5) **K-En Yakın Komşu (KEYK)**:* KEYK bir denetimli öğrenme algoritmasıdır. Bir veri noktasının sınıfını veya değerini, o noktaya en yakın K tane komşusunun sınıfı veya değeriyle tahmin eder [71]. Yani, verilen bir test verisi için, eğitim verisindeki en yakın komşularına bakarak bir sınıf veya sayısal bir değer atar. KEYK, herhangi bir karmaşık model oluşturma veya öğrenme süreci gerektirmediği için veri setine karmaşık modellerden daha hızlı uyum sağlayabilir, özellikle küçük veri setlerinde çok etkilidir. Hem sınıflandırma hem de regresyon problemlerine uygulanabilir, veri tipine ve probleme bağlı olarak esneklik sağlar [72]. Oldukça basit bir algoritmadır bu da onu kolayca anlaşılabilir ve uygulaması basit kılar. KEYK'in katman sayısı 1'dir. Çünkü model, sadece verilen bir test örneği ile eğitim veri setindeki diğer örnekler arasındaki mesafeleri hesaplayarak tahmin yapar.

Öklidyen mesafe formülü:

$$d(x_1, x_2) = \sqrt{\sum_{i=1}^{n} (x_{1i} - x_{2i})^2} \tag{7}$$

Hesaplanan mesafeye göre komşular seçilir:

- **Sınıflandırma İçin:** Komşuların sınıfları arasında çoğunluk oylaması yapılır:

  $$\hat{y} = \text{mode}(y_1, y_2, \ldots, y_K)$$

  Burada, $y_1, y_2, \ldots, y_K$ K komşusunun sınıf etiketleridir.
- **Regresyon İçin:** Komşuların etiketlerinin ortalaması alınarak tahmin yapılır:

  $$\hat{y} = \frac{1}{K} \sum_{i=1}^{K} y_i$$

  Burada, y_i komşuların sınıf değerleridir.

Derin Öğrenme

Derin öğrenme, yapay zeka ve makine öğrenmesinin bir alt dalıdır ve özellikle çok katmanlı yapılarla (genellikle yapay sinir ağları) verilerden öğrenme sürecini ifade eder ve nöral ağlar üzerinde yapılan geliştirmelerle, karmaşık veri yapıları ve büyük veri kümeleri üzerinde yüksek doğrulukla tahmin yapabilen modellerin geliştirilmesini [73].

Derin öğrenme, insan beynindeki sinir hücrelerinin (nöronlar) işleyişine benzer şekilde çalışan çok katmanlı sinir ağları kullanarak, verilerdeki gizli örüntüleri öğrenmeyi hedefler [73]. Bu yöntem, özellikle görüntü işleme, ses tanıma, doğal dil işleme (NLP) ve otonom araçlar gibi alanlarda büyük başarılar elde etmiştir.

Derin öğrenmenin önemli yönleri, yüksek doğruluk ve performans sağlaması, otomatik özellik çıkartması, büyük veri ile etkili çalışabilmesi, otomatik öğrenme ve iyileştirme yapabilmesidir. Bu çalışmada kullanılan derin öğrenme algoritmaları Yapay Sinir Ağları, Uzun Kısa Süreli Bellek, Hiyerarşik Dikkat Ağları, Evrişimsel Sinir Ağları ve Transformer'dır.

6) ***Yapay Sinir Ağları (YSA)****:* İnsan beynindeki sinir hücrelerinin (nöronlar) işleyişini taklit eder ve özellikle makine öğrenmesi ve derin öğrenme alanlarında veri analizi, sınıflandırma, regresyon gibi görevlerde kullanılır [74]. Yapay sinir ağları, büyük veri setlerinden öğrenme ve karmaşık ilişkileri modelleme konusunda güçlüdür. YSA, eğitim verilerindeki örüntüleri öğrenerek genelleme yapabilir, böylece yeni verilere de doğru tahminler yapabilir ve çok çeşitli problemlere uygulama yeteneği sağlar. Görüntü işleme, ses tanıma, metin analizi gibi farklı alanlarda etkilidir. YSA çok sayıda gizli katman içerebilir. YSA'da aktivasyon fonksiyonları, nöronların çıktılarının doğrusal olmayan bir şekilde işlenmesini sağlar. Bu, Yapay Sinir Ağlarının karmaşık verileri öğrenebilmesini mümkün kılar. En yaygın kullanılan aktivasyon fonksiyonlarından biri Sigmoiddir [74].

Sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \tag{8}$$

- Çıktıyı 0 ile 1 arasında sınırlayarak, özellikle ikili sınıflandırma problemlerinde kullanılır.

7) ***Uzun Kısa Süreli Bellek (UKSB)****:* Uzun Kısa Süreli Bellek özellikle sıralı verilerle güçlü olan ve metinlerde kelime gruplarını analiz edip anlam çıkarma konusunda uzmanlaşmış bir tür yinelemeli sinir ağı mimarisidir [31]. Sıralı verilerde uzun bağımlılıkları öğrenmedeki zorlukları aşmak için özel olarak tasarlanmıştır. Standart YSA'lara (Yinelemeli Sinir Ağları)[75] göre daha gelişmiştir. Diğer ağlarda yaşanan "gradyanların kaybolması problemini" çözmek için hücre durumu(cell state) ve kapılar(gates) adı verilen özel bir yapı kullanır [76]. Bu kapılar hangi bilgilerin tutulacağını, saklanacağını ve güncelleneceğini kontrol eder. Bu sayede uzun dizilerdeki bilgileri hatırlar. UKSB, DDİ alanındaki bazı tekniklerle birlikte çalışır. Bunlardan bazıları yorumları pozitif ve negatif olarak sınıflandıran "metin sınıflandırma", metin dizisinin olasılığını hesaplayıp metin üreten "dil modelleme ve metin üretimi", bir dilden başka bir dile otomatik çeviri yapan "makine çevirisi" ve bir metnin veya belgenin duygu durumunu belirleyen "duygu analizi" dir. UKSB'nin diğer algoritmalara göre avantajları uzun vadeli bağımlılıkları öğrenmesi, gradyanların kaybolması problemine sunduğu çözüm ve uzun dizilerdeki geçmiş veriyi hatırlayarak karar vermesi söylenebilir. Dezavantajları ise maliyetinin yüksek olması, küçük veri setlerinde aşırı öğrenme (overfitting)[77] ve kısa vadeli ilişkiler için gereksiz olabilir. LSTM katman sayısı 1 (tek katmanlı) veya çok katmanlı olabilir. Katman sayısı, modelin derinliği ile ilgilidir ve verinin karmaşıklığına göre ayarlanabilir.

Unutma Kapısı (Forget Gate)

Unutma kapısı, önceki hücre durumunun ne kadarının saklanacağına karar verir. Bu, aşağıdaki formülle hesaplanır:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{9}$$

Burada:

- f_t: Unutma kapısının çıktısı.
- W_f: Unutma kapısı için ağırlık matrisi.
- b_f: Unutma kapısı için bias.
- h_{t-1}: Önceki zaman adımındaki çıktı (hidden state).
- x_t: Mevcut giriş.

8) ***Hiyerarşik Dikkat Ağları (HDA)****:* Hiyerarşik Dikkat Ağları (Hierarchical Attention Networks, HAN), özellikle uzun metinlerin sınıflandırılmasında kullanılan ve metni kelime, cümle ve paragraf düzeyinde ele alan bir derin öğrenme modelidir. Kelime düzeyinde dikkat mekanizması önemli kelimeleri seçerken, cümle düzeyindeki dikkat mekanizması metin anlamını oluştururken kritik cümlelere odaklanır. Bu hiyerarşik yapı, hem yerel hem de global bağlamı öğrenerek uzun metinlerde üstün performans sağlar. Dikkat katmanlarının kullanımı, metin içerisindeki önemli bölgelere odaklanmayı sağlarken, gereksiz bilginin etkisini azaltır. HAN modeli, BERT gibi Transformer tabanlı modellerden farklı olarak metinleri hiyerarşik bir yapı ile işler ve bu nedenle uzun metinlerde avantaj sağlar. Ancak yüksek hesaplama maliyeti ve veri setine bağımlılığı dezavantajları arasındadır. Metin sınıflandırma, belge analizi ve özetleme gibi alanlarda sıkça kullanılmaktadır.

Hiyerarşik Dikkat Ağları (HAN), uzun metinlerin sınıflandırılmasında kullanılan bir modeldir. Model, metni kelime ve cümle düzeyinde işler ve önemli bölgelere odaklanmak için dikkat (attention) mekanizmasını kullanır. Aşağıda, HAN modelinin dikkat mekanizması formülleri detaylı şekilde verilmiştir:

Kelime Düzeyi Dikkat Mekanizması

HAN modeli, ilk olarak cümle içerisindeki kelimelerin temsilini öğrenir. Bu süreçte dikkat mekanizması, önemli kelimelere odaklanmayı sağlar. Formüller:

$$u_{it} = \tanh(W_w h_{it} + b_w)$$

$$\alpha_{it} = \frac{\exp(u_{it}^\top u_w)}{\sum_t \exp(u_{it}^\top u_w)}$$

$$s_i = \sum_t \alpha_{it} h_{it}$$

- h_{it}: i-inci cümledeki t-inci kelimenin gizli durumu (hidden state).
- W_w, b_w, u_w: Kelime düzeyindeki dikkat mekanizmasının öğrenilebilir parametreleridir.
- α_{it}: t-inci kelimenin önem ağırlığını ifade eder.
- s_i: i-inci cümlenin temsili vektörüdür.

Cümle Düzeyi Dikkat Mekanizması

Cümlelerin temsil vektörleri (kelime düzeyinden gelen s_i), cümle düzeyindeki dikkat mekanizmasıyla işlenir. Bu mekanizma, metni anlamak için önemli cümleleri seçer. Formüller:

$$u_i = \tanh(W_s s_i + b_s)$$

$$\alpha_i = \frac{\exp(u_i^\top u_s)}{\sum_i \exp(u_i^\top u_s)}$$

$$v = \sum_i \alpha_i s_i$$

- s_i: i-inci cümlenin temsil vektörü.
- W_s, b_s, u_s: Cümle düzeyindeki dikkat mekanizmasının öğrenilebilir parametreleridir.

- α_i: i-inci cümlenin önem ağırlığını ifade eder.
- v: Metnin nihai temsili vektörüdür. Bu vektör, sınıflandırma veya başka bir NLP görevinde kullanılır.

*9) **Evrişimsel Sinir Ağı (ESA)**:* Evrişimsel Sinir Ağları özellikle görüntü işleme ve video analizi gibi alanlarda yaygın olarak kullanılan bir derin öğrenme algoritmasıdır [78]. ESA'lar, verilerin uzaysal yapısını ve lokal özelliklerini öğrenmek için evrişimsel katmanları kullanır. Bu katmanlar, girdideki önemli özellikleri keşfetmek için optimize edilmiştir. YSA'lar, büyük veri setlerinde yüksek doğrulukla çalışabilir ve genellikle görüntü sınıflandırma, nesne tespiti, yüz tanıma ve görüntü segmentasyonu gibi görevlerde kullanılır ve 3 katmandan oluşur [79]. Bunlar evrişimsel katman, havuzlama katmanı, tam bağlantılı katmandır [79]. YSA, görüntülerden önemli özellikleri manuel olarak çıkarmaya gerek kalmadan otomatik olarak öğrenir. Bu, modelin özellik mühendisliği (feature engineering) gereksinimini ortadan kaldırır. Yerel bağlantılar kullanarak, verinin farklı bölgelerindeki benzer özellikleri öğrenebilir yani yer değiştirme bağımsızlığı sağlar.

Evrişimsel işlem şu şekilde ifade edilir:

$$S(x,y) = (I * F)(x,y) = \sum_i \sum_j I(x+i, y+j) \cdot F(i,j) \quad (14)$$

Burada:

- I: Girdi görüntüsü (input image).
- F: Filtre (kernel).
- S: Çıkış haritası (output feature map).

*10) **Transformer**:* Transformer algoritması, 2017 yılında Vaswani ve arkadaşları tarafından geliştirilen, özellikle doğal dil işleme (NLP) görevlerinde devrim yaratmış bir derin öğrenme modelidir. Transformer, sıralı verileri işlerken geleneksel geri beslemeli sinir ağları ve uzun kısa süreli bellek gibi modellerin sınırlamalarını aşmayı başarmıştır. En büyük yeniliği, dikkat mekanizması (Attention Mechanism) kullanarak her kelimenin diğer tüm kelimelerle olan ilişkisini öğrenebilmesidir. Transformer'ın çok katmanlı yapısı, modelin çok daha derinlemesine ve soyut bir şekilde veri öğrenmesini sağlar. Aynı zamanda ses, görüntü ve diğer sıralı veri türlerinde de kullanılabilecek esnek bir modeldir.

Dikkat Mekanizması:

$$\text{Dikkat}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (15)$$

Burada:

- d_k: Query ve Key vektörlerinin boyutunu temsil eder.
- Softmax fonksiyonu, dikkat katsayılarını normalize eder.

G. Model Özgünlüğü

Literatürde bölümünde incelediğimiz, bilinen makine ve derin öğrenme algoritmalarının yanı sıra kullanacağımız algoritmayı daha özgün bir model haline getirmek için şu 3 yöntemi algoritmamıza ekledik.

- Metin özniteliklerinin çıkarımında TF-IDF kullanıp, boyut indirgeme için PCA ve Varyans Eşiği Belirleme gibi iki aşamalı bir yaklaşım birleştirildi. Bu kombinasyonu duygu analizi için az kullanılan bir yöntemdir.
- Model iyileştirme teknikleri ile algoritmamızın performansını artırmak ve aşırı öğrenme (Overfitting) yani modelin eğitim verisine fazla uyum sağlaması, ancak test verisinde düşük performans göstermesi durumu ve yetersiz öğrenme (Underfitting) yani modelin, eğitim verisindeki desenleri yeterince öğrenememesi ve hem eğitim hem de test verilerinde düşük performans göstermesi durumu gibi problemleri çözmek için hiperparametre optimizasyonu ve düzenleme gibi yöntemlerin uygulanmasıdır. Hiperparametre optimizasyonu, algoritmaların en iyi performansı gösterebilmesi için ayarlanması gereken parametrelerin sistematik bir şekilde aranmasıdır. Düzenleme, modelin aşırı öğrenmesini (overfitting) önlemek için ceza terimleri eklemesidir.
- Sınıf Dengesizliği Çözümleri ile veri setindeki sınıflar arasında büyük farklar olduğunda modelin belirli sınıflara öncelik vermesi gibi sorunlar engellenmiştir. Bunun için azınlık sınıflarını çoğaltmak için sentetik veri noktaları oluşturan SMOTE kullanılmıştır.

Bu çalışmada kullanılan algoritma finansal haberlerin duygu analizi problemine özgün bir yaklaşım sunmaktadır. Algoritmanın seçilme nedeni sınıflandırma işlemini hem yüksek doğruluk oranlarıyla gerçekleştirebilmek hem de veri setinin yapısına uygun çözümler geliştirmektir. Öznitelik çıkarımı için TF-IDF ile boyut indirgeme tekniklerinin (PCA ve Varyans Eşiği Belirleme) kombinasyonu, literatürde az kullanılan ancak güçlü bir yöntemdir. Bu yaklaşım veri setindeki yüksek boyutlu metin özniteliklerini temsil eden bilgiyi küçük boyutlara düşürerek işlem maliyetini azaltırken aynı zamanda performansı artırır. Ayrıca hiperparametre optimizasyonu ve düzenleme yöntemleri modelin aşırı öğrenme (overfitting) ve yetersiz öğrenme (underfitting) problemlerini çözerek genelleştirme kabiliyetini geliştirmiştir. Veri setindeki sınıf dengesizliğini için SMOTE yöntemi ise azınlık sınıflarının temsil gücünü artırarak modelin dengesiz veri setlerinde eşit bir şekilde öğrenmesini sağlamıştır. Bu algoritmanın önemi, duygu analizi gibi karmaşık bir problemi ele alırken doğruluğu ve modelin genelleştirme yeteneğini optimize eden bir yaklaşım sunmasından kaynaklanmaktadır. Avantajları arasında, işlem verimliliği, sınıflar arası denge sağlama ve özelleştirilmiş hiperparametrelerle yüksek doğruluk oranlarına ulaşma yer almaktadır.

H. Model Eğitimi

Bu kodda modelin eğitimi, yapay sinir ağı (YSA) kullanılarak gerçekleştirilmiştir. Kod, PCA uygulanmadan önceki verilerle ve PCA uygulandıktan sonraki verilerle ayrı ayrı model eğitim süreçlerini yürütmektedir. Eğitim süreci aşağıdaki adımları içermektedir:

1) Yapay Sinir Ağı (YSA) Modelinin Tanımlanması: Model, create_ann fonksiyonu kullanılarak oluşturulmuştur. Bu fonksiyon modelin katmanlarını ve hiperparametrelerini tanımlamaktadır:

- Katmanlar:
- İlk gizli katman: 128 nöron, relu aktivasyon fonksiyonu.
- İkinci gizli katman: 64 nöron, relu aktivasyon fonksiyonu.
- Çıkış katmanı: Sınıflandırma için softmax aktivasyon fonksiyonu.
- Düzenleme (Regularization):
- Her gizli katmandan sonra %30 dropout oranı uygulanmıştır.
- (dropout_rate=0.3). Bu aşırı öğrenmeyi (overfitting) önlemeyi amaçlar.
- Optimizasyon:
- Adam optimizasyon algoritması kullanılmıştır (learning_rate=0.001). Bu, öğrenme oranını dinamik olarak ayarlayarak hızlı ve kararlı bir optimizasyon sağlar.
- Kayıp Fonksiyonu:

- Çok sınıflı sınıflandırma için uygun olan categorical_crossentropy kullanılmıştır.
- Değerlendirme Metrikleri:
- Modelin performansı accuracy metriği ile değerlendirilmiştir.

2) Hiperparametre Optimizasyonu: Model eğitimi için hiperparametreler optimize_hyperparameters fonksiyonu ile belirlenmiştir. Bu işlemde aşağıdaki hiperparametreler optimize edilmiştir:

- Epoch Sayısı: Modelin tüm veri setini kaç kez göreceğini belirler (epochs=[10, 20]).
- Batch Boyutu: Her iterasyonda modele aynı anda verilecek örnek sayısını ifade eder (batch_size=[16, 32, 64]).
- Öğrenme Oranı (Learning Rate): Ağırlıkların güncellenme hızını belirler (learning_rate=[0.001, 0.01]

3) Modelin Eğitim Süreci: Eğitim süreci, PCA uygulanmadan önceki ve sonraki veriler üzerinde ayrı ayrı gerçekleştirilmiştir.

Veri Hazırlığında PCA öncesi veriler, eğitim ve test verileri olarak Tabakalı K-Fold çapraz doğrulama yöntemiyle 5 katmana ayrılmıştır. Eğitim seti ve test seti olarak ayrılan veriler, modele uygun formatta hazırlanmıştır.

PCA sonrası verilerde, PCA kullanılarak öznitelik boyutu azaltılmış veriyle aynı süreç tekrarlanmıştır. Her katmanda eğitim verileri kullanılarak model eğitilmiştir. Fit metodu kullanılarak, model belirlenen epoch ve batch_size parametreleri doğrultusunda optimize edilmiştir. Verbose=0, eğitim sırasında çıktıların bastırılmamasını sağlar. Eğitim, model ağırlıklarının kayıp fonksiyonuna (categorical_crossentropy) göre optimize edilmesiyle gerçekleştirilmiştir.

4) Modelin Tahmini ve Performans Değerlendirmesi: Eğitilen model, test veri setine uygulanarak tahmin sonuçları elde edilmiştir Performansı ölçmek için doğruluk, kesinlik, duyarlılık, f1-Skoru, AUC, ve özgüllük gibi metrikler hesaplanmıştır.

5) PCA Sonrası ve Öncesi Karşılaştırma: Elde edilen performans sonuçları, PCA uygulanmadan önceki ve sonraki veriler için ayrı ayrı kaydedilmiştir. Tüm metriklerin ortalamaları hesaplanarak model performansı değerlendirilmiştir.

Sonuç olarak modelin eğitimi, PCA uygulanıp uygulanmadığı durumlarda çapraz doğrulama kullanılarak gerçekleştirilmiş ve optimize edilmiş hiperparametrelerle en iyi sonuçlar hedeflenmiştir. Eğitim süreci, doğruluk, kesinlik, duyarlılık, AUC ve F1-Skoru gibi kapsamlı metriklerle değerlendirilmiş ve PCA'nın etkisi analiz edilmiştir.

I. Değerlendirme Metrikleri

Modelin performansını değerlendirmek için kullanılan bazı metrikler, doğruluk, duyarlılık, özgüllük, F-skor ve AUC-ROC gibi metriklerdir. Bu metrikler, modelin başarısını ölçmede çok önemlidir.

Karmaşıklık Matrisi: Karmaşıklık matrisi, modelin tahmin ettiği sınıflarla gerçek sınıflar arasındaki ilişkiyi gösteren bir tablodur. Karmaşıklık matrisi şu şekilde gösterilebilir:

	Gerçek Pozitif (TP)	Gerçek Negatif (TN)
Tahmin Pozitif (FP)	TP	FP
Tahmin Negatif (FN)	FN	TN

Burada:

- **TP** (True Positive): Modelin doğru bir şekilde pozitif sınıfı tahmin ettiği durumlar.
- **TN** (True Negative): Modelin doğru bir şekilde negatif sınıfı tahmin ettiği durumlar.
- **FP** (False Positive): Modelin yanlış bir şekilde pozitif sınıfı tahmin ettiği durumlar (Type I error).
- **FN** (False Negative): Modelin yanlış bir şekilde negatif sınıfı tahmin ettiği durumlar (Type II error).

Başarı Ölçütleri

Modelin performansını değerlendirirken kullanılan bazı temel metrikler aşağıda verilmiştir:

Doğruluk (Accuracy): Doğruluk, modelin doğru sınıflandırma oranını gösterir:

$$\text{Doğruluk} = \frac{TP + TN}{TP + TN + FP + FN} \tag{16}$$

Duyarlılık (Sensitivity) / Hatırlama (Recall): Duyarlılık, pozitif sınıfların doğru bir şekilde tanımlanma oranını ölçer:

$$\text{Duyarlılık} = \frac{TP}{TP + FN} \tag{17}$$

Özgüllük (Specificity): Özgüllük, negatif sınıfların doğru bir şekilde tanımlanma oranını ölçer:

$$\text{Özgüllük} = \frac{TN}{TN + FP} \tag{18}$$

F-Skoru (F-Score): F-Skoru, duyarlılık ve özgüllüğün harmonik ortalamasıdır:

$$F\text{-Skoru} = 2 \times \frac{\text{Duyarlılık} \times \text{Kesinlik}}{\text{Duyarlılık} + \text{Kesinlik}} \tag{19}$$

Kesinlik (Precision): Pozitif sınıflar için doğru tahminlerin oranıdır.

$$\text{Kesinlik} = \frac{TP}{TP + FP} \tag{20}$$

AUC-ROC: AUC-ROC, modelin sınıflandırma başarısını değerlendiren bir grafiktir. ROC (Receiver Operating Characteristic) eğrisi, modelin True Positive Rate (TPR) ile False Positive Rate (FPR) arasındaki ilişkiyi gösterir. AUC (Area Under Curve), bu eğrinin altındaki alanı temsil eder ve modelin genel başarı oranını ölçer:

$$\text{AUC} = \int_0^1 TPR\, dFPR \tag{21}$$

IV. DENEYSEL SONUÇLAR

Bu çalışmada, finansal haberlerin pozitif ya da negatif olarak sınıflandırılmasına yönelik bir yapay zeka çözümü geliştirilmesi amaçlanmıştır. Finans piyasalarının dinamik yapısı, haberlerin piyasa hareketlerine olan etkisini hızlı ve doğru bir şekilde analiz etmeyi zorunlu kılmaktadır. Bu bağlamda, doğal dil işleme (NLP) teknikleri ve çeşitli makine ile derin öğrenme modelleri kullanılarak, finansal haberlerin etkili bir şekilde sınıflandırılması hedeflenmiştir. Çalışmada kullanılan veri kümesi Kaggle platformundan alınan ve finansal haberlerin duygu analizi için kullanılan "Sentiment Analysis for Financial News" veri setidir, herkese açık kaynaklardan derlenmiş finansal haberlerden oluşmaktadır. Veri seti toplamda 4.845 satır ve 2 sütun içermektedir. Duygu etiketlerinin dağılımı 2.878 nötr, 1.364 pozitif ve 604 negatif şeklindedir. Bu veri setinin dengesiz olduğunu gösterir Çalışmamızda metin temizleme ile küçük harfe dönüştürme, noktalama işaretlerini kaldırma, sayıları temizleme. TF-IDF ile öznitelik çıkarımı ile metinleri sayısal verilere dönüştürme yapılmıştır. Veri kümesine uygulanan ön işleme adımları metin temizleme ile küçük harfe dönüştürme, noktalama işaretlerini kaldırma ve sayıları temizlemedir. Özellik çıkarımı ve seçimi aşamalarında ise TF-IDF, PCA, Varyans Eşiği

Belirleme gibi yöntemler kullanılmıştır. Sınıflandırma sürecinde, Naive Bayes, Destek Vektör Makineleri (DVM), Lojistik Regresyon (LR), Rastgele Orman (RO) ve K-En Yakın Komşu (KEYK) gibi makine öğrenmesi yöntemlerinin yanı sıra, Yapay Sinir Ağları (YSA), Uzun Kısa Süreli Bellek (UKSB), Hiyerarşik Dikkat Ağları (HDA), Evrişimsel Sinir Ağları (ESA) ve Transformer modelleri gibi derin öğrenme algoritmaları kullanılmıştır. Özgün algoritmamız ise YSA derin algoritmasından geliştirilerek elde edilmiştir. Özgün algoritmada detaylı veri ön işlemesi ve gelişmiş öz nitelik çıkarımı ile boyut indirme teknikleri kullanılmıştır. Bu bölümde, uygulanan yöntemlerin performansları doğruluk, kesinlik, hatırlama, F1 skoru gibi metriklerle değerlendirilerek karşılaştırılmış ve en başarılı modellerin sonuçları detaylı olarak incelenmiştir. Çalışmamız, doğru ve hızlı sınıflandırma sağlayan bir model ortaya koyarak, yatırımcılar için daha güvenilir ve etkin bir bilgi analizi süreci sunmayı amaçlamaktadır.

A. Model Performansı ve Değerlendirilmesi

1) ***Performans Metrikleri****:* Performans metrikleri, bir modelin doğruluğunu ve etkinliğini değerlendirmek için kritik bir rol oynar. Doğruluk, modelin doğru tahmin ettiği örneklerin tüm tahminlere oranını ifade ederken, duyarlılık veya başka bir deyişle gerçek pozitif oranı, modelin pozitif sınıfı doğru tahmin etme yeteneğini gösterir. Özgüllük ise negatif sınıfı doğru şekilde tanıma oranını ifade eder. Kesinlik, pozitif tahminlerin ne kadarının gerçekten pozitif olduğunu belirtirken, F-skor, duyarlılık ve kesinlik arasında bir denge sağlayarak modelin genel performansını özetler. Son olarak, AUC, modelin farklı eşik değerlerinde pozitif ve negatif sınıfları ayırt etme becerisini ölçen bir metriktir. Bu metrikler bir arada değerlendirildiğinde, modelin sadece doğru tahmin yeteneği değil, aynı zamanda dengeli bir performans sergileyip sergilemediği hakkında kapsamlı bir içgörü sağlar ve bu da özellikle dengesiz veri setlerinde büyük önem taşır.

Model Performansına PCA Etkisi*:* PCA, veri setindeki yüksek boyutlu veriyi daha az bileşene indirgemek ve veri boyutunu azaltarak analiz sürecini kolaylaştırmak için kullanılan etkili bir yöntemdir. PCA'nın en önemli avantajlarından biri, veri setinde gizli kalmış ilişkileri ortaya çıkararak veri yapısındaki anlamsız varyasyonları ortadan kaldırmasıdır. Ayrıca, hesaplama maliyetini düşürmesi ve aşırı uyumu önlemeye yardımcı olması nedeniyle makine öğrenmesi modellerinde sıkça tercih edilmektedir. Bu çalışmada veri boyutunu indirgemek amacıyla 100 bileşenli PCA kullanılmıştır. Ancak yapılan çalışma sonucunda PCA ile yapılan boyut indirgemenin model performanslarını düşürdüğü anlaşılmıştır. PCA'nın bu veri setine uygun olmadığı ortaya konmuştur.

Model Performansına Varyans Eşiği Belirleme Etkisi*:* Varyans eşiği belirleme, düşük varyanslı özellikleri veri setinden çıkararak modelin giriş boyutunu azaltan, aşırı uyumu önleyen ve hesaplama maliyetini düşüren bir yöntemdir. Ancak tabloda görüldüğü üzere (Tablo 4), varyans eşiği belirleme uygulandığında model performansında belirgin bir düşüş gözlemlenmiştir. Örneğin, Özgün modelin (Tablo 14) doğruluk (%81.23), kesinlik (%81.20), F1-puanı (%81.17) ve AUC (%93.31) değerleri, PCA öncesi ve sonrası senaryolara göre daha düşüktür. Bu durum, düşük varyanslı özelliklerin bazı durumlarda faydalı bilgi taşıyabileceğini ve çıkarılmalarının modelin genelleme yeteneğine zarar verebileceğini göstermektedir. Varyans eşiği belirleme, boyut azaltımı ve hesaplama kolaylığı sağlasa da, yüksek doğruluk ve kesinlik gereken durumlarda dikkatli bir şekilde uygulanması gereken bir yöntemdir. Tablodan elde edilen sonuçlar, bu yöntemin performansa etkilerinin eşik değeri seçimine bağlı olarak dikkatlice değerlendirilmesi gerektiğini ortaya koymaktadır.

2) ***Karşılaştırma****:* Bu bölümde makine öğrenmesi ve derin öğrenme algoritmalarının sonuçları ile hibrit modelimizin sonuçları detaylı şekilde karşılaşılaştırılmıştır. Karşılaştırma için bar grafiğinden (Şekil 3 ve Şekil 4) faydalanılmıştır ve grafikte temsil edilen her değer açıklanmıştır.

NB algoritması ile elde edilen sonuçlar %69.31 doğruluk, %71.81 kesinlik, %76.92 özgüllük, %63.63 f-skoru, %69.30 duyarlılık, %82.77 AUC şeklindedir. Bu sonuçlar diğer algoritmalarla karşılaştırıldığında, NB algoritması ile yapılan bu sınıflandırmanın kullanılan veri setine uygun olmadığı ortaya konulmuştur. Özellikle özgüllük değerinin oldukça düşük olması ve diğer metriklerde de düşük performans sergilemesi, NB algoritmasının bu veri seti için uygun olmadığını göstermektedir.

DVM algoritması ile elde edilen sonuçlar %77.15 doğruluk, %77.18 kesinlik, %59.28 özgüllük, %76.00 f-skoru, %77.15 duyarlılık, %87.91 AUC şeklindedir. Elde edilen bu sonuçları diğer algoritmalarla kıyasladığımızda, kullanılan veri setine en uygun algoritmanın DVM olduğu gözler önüne serilmiştir. DVM algoritması, doğruluk, kesinlik ve duyarlılık gibi metriklerde yüksek performans göstermiş olup, diğer algoritmalardan genel olarak üstün bir performans sergilemiştir.

LR algoritması ile elde edilen sonuçlar %76.57 doğruluk, %77.42 kesinlik, %50.43 özgüllük, %74.82 f-skoru, %76.57 duyarlılık, %87.58 AUC şeklindedir. Sonuçlar çoğu algoritmaya göre yüksektir, fakat DVM kadar yüksek performans sağlayamaması bakımından LR'nin bu veri seti için uygun olmadığını ortaya koymaktadır. Özellikle özgüllük değeri diğer metriklerin gerisinde kalmış ve genel performansı sınırlamıştır.

RO algoritması ile elde edilen sonuçlar %74.55 doğruluk, %76.32 kesinlik, %43.77 özgüllük, %71.71 f-skoru, %74.55 duyarlılık, %85.97 AUC şeklindedir. Bu sonuçlar, DVM ve LR gibi algoritmaların altında kalmış, ancak NB ve KEYK algoritmalarına göre daha iyi bir performans göstermiştir. RO algoritmasının bu veri seti üzerinde makul bir performans sunduğu söylenebilir, ancak veri setine en uygun algoritma olmadığı ortadadır.

KEYK algoritması ile elde edilen sonuçlar %69.29 doğruluk, %68.19 kesinlik, %62.58 özgüllük, %68.02 f-skoru, %69.29 duyarlılık, %79.30 AUC şeklindedir. Bu sonuçlar, diğer algoritmalarla kıyaslandığında oldukça düşük bir performansa işaret etmektedir. Bu nedenle KEYK algoritmasının bu veri seti için uygun olmadığı sonucuna varılmıştır.

YSA algoritması ile elde edilen sonuçlar %74.86 doğruluk, %74.49 kesinlik, %67.88 özgüllük, %74.50 f-skoru, %74.86 duyarlılık, %85.49 AUC şeklindedir. Bu sonuçlar, RO ve ESA algoritmalarına benzer bir performans sergilemekte olup, LR ve DVM algoritmalarının altında kalmaktadır. YSA algoritması makul bir doğruluk ve AUC değeri sağlasa da, bu veri seti için en uygun algoritma olmadığı sonucuna varılmıştır.

UKSB algoritması ile elde edilen sonuçlar %74.72 doğruluk, %74.25 kesinlik, %67.66 özgüllük, %74.07 f-skoru, %74.72 duyarlılık, %82.91 AUC şeklindedir. Bu sonuçlar, YSA ve RO algoritmaları ile benzerlik göstermekte, ancak DVM algoritması kadar

TABLE IV: Naive Bayes Sınıflandırma Sonuçları

Naive Bayes (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.75	63.51	66.92	45.02	59.75	74.09
Fold2	59.44	35.33	66.66	44.32	59.44	75.96
Fold3	59.44	35.33	66.66	44.32	59.44	75.84
Fold4	59.55	63.46	66.83	44.66	59.54	75.74
Fold5	59.96	63.60	67.14	45.58	59.95	75.45
Ortalama	**59.63**	**52.25**	**66.85**	**44.78**	**59.62**	**75.42**
Naive Bayes (PCA KAPALI)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F-Skoru (%)**	**Duyarlılık (%)**	**AUC(%)**
Fold1	69.25	71.87	77.12	63.84	69.24	82.88
Fold2	69.76	72.84	77.14	64.07	69.76	83.84
Fold3	67.91	69.06	75.73	61.31	67.90	83.68
Fold4	70.07	73.00	77.48	64.76	70.07	82.00
Fold5	69.56	72.26	77.13	64.18	69.55	81.43
Ortalama	**69.31**	**71.81**	**76.92**	**63.63**	**69.30**	**82.77**
Naive Bayes (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.75	63.51	66.92	45.02	59.75	72.57
Fold2	59.44	35.33	66.67	44.32	59.44	74.29
Fold3	59.44	35.33	66.67	44.32	59.44	74.94
Fold4	59.44	63.42	66.75	44.43	59.44	73.76
Fold5	59.96	63.60	67.17	45.58	59.95	73.83
Ortalama	**59.61**	**52.24**	**66.83**	**44.74**	**59.61**	**73.88**

TABLE V: Destek Vektör Makinesi Sınıflandırma Sonuçları

Destek Vektör Makinesi (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	71.41	72.03	38.10	67.95	71.41	81.37
Fold2	71.10	72.17	36.54	67.29	71.10	82.74
Fold3	69.76	70.72	36.56	65.67	69.76	81.39
Fold4	72.03	73.07	33.98	68.25	72.03	81.05
Fold5	70.38	71.20	36.27	66.43	70.38	81.40
Ortalama	**70.94**	**71.84**	**36.29**	**67.12**	**70.94**	**81.59**
Destek Vektör Makinesi (PCA KAPALI)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	77.40	77.22	58.18	76.47	77.40	87.84
Fold2	77.50	77.50	61.61	76.42	77.50	88.07
Fold3	76.68	76.93	61.47	75.46	76.68	88.46
Fold4	77.19	77.25	56.07	75.85	77.19	87.14
Fold5	76.99	76.98	59.09	75.80	76.99	88.01
Ortalama	**77.15**	**77.18**	**59.28**	**76.00**	**77.15**	**87.91**
Destek Vektör Makinesi (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	70.59	71.87	39.45	66.69	70.59	79.71
Fold2	70.38	71.83	34.31	65.96	70.38	80.40
Fold3	71.10	73.48	38.61	66.95	71.10	79.78
Fold4	70.38	71.39	31.00	65.84	70.38	79.31
Fold5	69.35	70.63	33.96	64.77	69.35	79.31
Ortalama	**70.36**	**71.84**	**35.47**	**66.04**	**70.36**	**79.70**

TABLE VI: Lojistik Regresyon Sınıflandırma Sonuçları

Lojistik Regresyon (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	71.62	71.47	42.00	69.33	71.62	82.28
Fold2	72.45	72.69	41.58	69.53	72.45	83.18
Fold3	70.69	71.58	41.94	67.78	70.69	81.62
Fold4	72.34	72.29	35.00	69.46	72.34	82.74
Fold5	71.72	71.49	41.00	69.02	71.72	82.42
Ortalama	**71.76**	**71.90**	**40.30**	**69.02**	**71.76**	**82.45**
Lojistik Regresyon (PCA KAPALI)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	76.78	77.21	51.82	75.28	76.78	87.51
Fold2	77.61	78.77	53.70	75.94	77.61	87.75
Fold3	76.57	78.27	49.52	74.65	76.57	87.81
Fold4	75.95	76.25	47.12	74.03	75.95	87.11
Fold5	75.95	76.61	50.00	74.19	75.95	87.73
Ortalama	**76.57**	**77.42**	**50.43**	**74.82**	**76.57**	**87.58**
Lojistik Regresyon (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	71.52	71.75	41.90	68.93	71.52	80.60
Fold2	72.03	72.85	39.22	68.77	72.03	81.36
Fold3	71.31	72.45	39.18	68.01	71.31	80.30
Fold4	72.14	72.59	33.66	68.88	72.14	81.00
Fold5	71.00	70.90	36.54	68.05	71.00	80.33
Ortalama	**71.60**	**72.11**	**38.10**	**68.53**	**71.60**	**80.72**

TABLE VII: Rastgele Orman Sınıflandırma Sonuçları

Rastgele Orman (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	72.14	72.89	42.72	69.14	72.14	76.95
Fold2	70.79	72.51	33.67	66.40	70.79	78.13
Fold3	69.97	70.67	37.08	65.90	69.97	77.30
Fold4	71.00	72.18	29.90	66.90	71.00	79.70
Fold5	69.87	71.10	32.69	65.56	69.87	79.81
Ortalama	**70.75**	**71.87**	**35.21**	**66.78**	**70.75**	**78.38**
Rastgele Orman (PCA KAPALI)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F-Skoru (%)**	**Duyarlılık (%)**	**AUC**
Fold1	75.44	76.69	48.15	73.08	75.44	86.20
Fold2	74.10	75.33	43.56	71.18	74.10	86.40
Fold3	75.34	77.70	47.52	72.60	75.34	85.46
Fold4	74.61	76.38	37.96	71.70	74.61	85.59
Fold5	73.27	75.48	41.67	69.97	73.27	86.17
Ortalama	**74.55**	**76.32**	**43.77**	**71.71**	**74.55**	**85.97**
Rastgele Orman (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	72.03	73.03	38.68	68.88	72.03	76.86
Fold2	69.87	71.00	32.65	65.75	69.87	76.98
Fold3	71.21	72.69	41.30	67.47	71.21	76.77
Fold4	71.21	72.49	29.34	67.16	71.21	78.03
Fold5	71.00	72.91	33.00	67.14	71.00	78.05
Ortalama	**71.06**	**72.43**	**34.99**	**67.28**	**71.06**	**77.34**

TABLE VIII: K-En Yakın Komşu Sınıflandırma Sonuçları

K-En Yakın Komşu (PCA AÇIK)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F-Skoru (%)**	**Duyarlılık (%)**	**AUC (%)**
Fold1	68.42	66.71	43.00	65.70	68.42	72.36
Fold2	68.52	67.13	41.51	65.24	68.52	73.48
Fold3	69.35	67.95	46.94	66.03	69.35	73.26
Fold4	67.49	65.70	36.54	64.09	67.49	73.41
Fold5	67.29	65.34	42.72	64.18	67.29	73.24
Ortalama	**68.21**	**66.57**	**42.14**	**65.05**	**68.21**	**73.15**
K-En Yakın Komşu (PCA KAPALI)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	70.28	69.20	59.05	69.05	70.28	80.10
Fold2	68.94	67.56	63.46	67.38	68.94	78.75
Fold3	72.24	71.26	69.07	70.93	72.24	80.86
Fold4	69.25	68.50	58.42	68.36	69.25	79.57
Fold5	65.74	64.43	62.89	64.38	65.74	77.22
Ortalama	**69.29**	**68.19**	**62.58**	**68.02**	**69.29**	**79.30**
K-En Yakın Komşu (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	66.67	64.55	36.08	63.67	66.67	70.95
Fold2	68.42	67.55	39.25	65.08	68.42	71.88
Fold3	69.25	67.84	44.55	66.44	69.25	72.70
Fold4	67.39	65.76	31.68	64.11	67.39	71.67
Fold5	67.18	65.65	39.62	64.01	67.18	71.59
Ortalama	**67.78**	**66.27**	**38.24**	**64.66**	**67.78**	**71.76**

TABLE IX: Yapay Sinir Ağları Sınıflandırma Sonuçları

Yapay Sinir Ağları (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	74.41	73.88	61.11	73.35	74.41	84.63
Fold2	74.51	73.56	60.64	73.24	74.51	85.68
Fold3	73.17	72.61	58.59	71.57	73.17	83.87
Fold4	74.10	73.41	53.00	72.30	74.10	85.12
Fold5	74.82	74.19	64.42	73.95	74.82	84.89
Ortalama	**74.20**	**73.53**	**59.55**	**72.88**	**74.20**	**84.84**
Yapay Sinir Ağları (PCA KAPALI)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	76.68	76.17	64.86	76.11	76.68	86.11
Fold2	74.41	74.50	65.09	74.23	74.41	84.60
Fold3	73.48	72.86	67.29	72.97	73.48	85.44
Fold4	74.82	74.33	70.48	74.44	74.82	86.01
Fold5	74.92	74.61	71.70	74.72	74.92	85.27
Ortalama	**74.86**	**74.49**	**67.88**	**74.50**	**74.86**	**85.49**
Yapay Sinir Ağları (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	73.27	72.51	55.96	71.99	73.27	82.84
Fold2	73.37	72.63	55.34	71.81	73.37	83.44
Fold3	73.07	73.13	52.00	70.80	73.07	82.97
Fold4	74.20	74.05	45.54	71.92	74.20	83.73
Fold5	73.79	73.50	53.70	72.16	73.79	82.96
Ortalama	**73.54**	**73.16**	**52.51**	**71.73**	**73.54**	**83.19**

TABLE X: Uzun Kısa Süreli Bellek Sınıflandırma Sonuçları

Uzun Kısa Süreli Bellek (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	57.89	46.45	0.88	46.94	57.89	54.86
Fold2	55.11	45.81	0.93	48.01	55.11	55.91
Fold3	52.32	45.22	5.50	47.02	52.32	54.88
Fold4	51.81	47.87	4.48	49.17	51.81	54.89
Fold5	53.56	41.91	0.00	45.72	53.56	54.20
Ortalama	**54.14**	**45.45**	**2.36**	**47.37**	**54.14**	**54.95**
Uzun Kısa Süreli Bellek (PCA KAPALI)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F-Skoru (%)**	**Duyarlılık (%)**	**AUC (%)**
Fold1	73.99	73.48	57.14	73.15	73.99	82.73
Fold2	74.41	73.89	69.81	73.99	74.41	82.46
Fold3	74.30	73.78	70.79	73.44	74.30	82.10
Fold4	75.95	75.35	69.44	75.38	75.95	84.24
Fold5	74.92	74.73	71.11	74.41	74.92	83.02
Ortalama	**74.72**	**74.25**	**67.66**	**74.07**	**74.72**	**82.91**
Uzun Kısa Süreli Bellek (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	54.08	44.78	3.51	46.58	54.08	53.27
Fold2	57.38	48.21	3.39	47.41	57.38	55.25
Fold3	50.98	42.07	2.93	44.40	50.98	53.66
Fold4	49.33	43.49	1.00	45.92	49.33	53.72
Fold5	56.14	45.18	6.14	46.50	56.14	54.04
Ortalama	**53.58**	**44.75**	**3.40**	**46.29**	**53.58**	**53.99**

TABLE XI: Evrişimsel Sinir Ağı Sınıflandırma Sonuçları

Evrişimsel Sinir Ağı (PCA AÇIK)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**Duyarlılık (%)**	**F-Skoru (%)**	**AUC (%)**
Fold1	68.32	67.02	79.37	68.32	63.07	78.53
Fold2	68.63	67.63	76.81	68.63	64.72	78.99
Fold3	67.80	69.81	76.78	67.80	62.66	79.89
Fold4	70.28	70.84	79.02	70.28	66.69	79.38
Fold5	66.46	63.79	75.20	66.46	61.86	77.71
Ortalama	**68.30**	**67.82**	**77.44**	**68.30**	**63.80**	**78.90**
Evrişimsel Sinir Ağı (PCA KAPALI)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**Duyarlılık (%)**	**F-Skoru (%)**	**AUC (%)**
Fold1	75.95	75.69	86.43	75.95	75.79	87.63
Fold2	75.03	75.18	84.82	75.03	75.10	86.16
Fold3	75.13	74.73	84.81	75.13	74.84	87.70
Fold4	72.96	72.94	83.51	72.96	72.92	85.30
Fold5	74.41	74.15	84.19	74.41	74.22	86.26
Ortalama	**74.70**	**74.54**	**84.75**	**74.70**	**74.57**	**86.61**
Evrişimsel Sinir Ağı (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**Duyarlılık (%)**	**F-Skoru (%)**	**AUC (%)**
Fold1	68.52	69.32	77.27	68.52	66.53	77.36
Fold2	67.29	67.39	77.48	67.29	62.33	78.60
Fold3	68.32	68.67	74.21	68.32	64.32	77.51
Fold4	69.56	70.97	79.89	69.56	65.05	77.46
Fold5	67.18	66.60	77.27	67.18	62.41	76.84
Ortalama	**68.17**	**68.59**	**77.22**	**68.17**	**64.13**	**77.55**

TABLE XII: Hiyerarşik Dikkat Ağları Sınıflandırma Sonuçları

Hiyerarşik Dikkat Ağları (PCA AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.44	35.33	0.00	44.00	59.44	50.31
Fold2	59.44	35.33	0.00	44.32	59.44	50.05
Fold3	59.44	35.33	0.00	44.32	59.44	50.00
Fold4	59.34	35.21	0.00	44.20	59.39	50.00
Fold5	59.33	35.21	0.00	44.19	59.33	49.06
Ortalama	**59.40**	**35.29**	**0.00**	**44.27**	**59.40**	**49.88**
Hiyerarşik Dikkat Ağları (PCA KAPALI)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.44	35.33	0.00	44.32	59.44	49.31
Fold2	59.44	35.33	0.00	44.32	59.44	49.99
Fold3	59.44	35.33	0.00	44.32	59.44	49.97
Fold4	59.33	35.21	0.00	44.20	59.33	49.93
Fold5	59.33	35.21	0.00	44.20	59.33	50.07
Ortalama	**59.40**	**35.29**	**0.00**	**44.27**	**59.40**	**49.86**
Hiyerarşik Dikkat Ağları (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.44	35.33	0.00	44.32	59.44	50.07
Fold2	59.44	35.33	0.00	44.32	59.44	50.00
Fold3	59.44	35.33	0.00	44.32	59.44	49.74
Fold4	59.33	35.21	0.00	44.20	59.33	49.99
Fold5	59.33	35.21	0.00	44.20	59.33	50.32
Ortalama	**59.40**	**35.29**	**0.00**	**44.27**	**59.40**	**50.02**

TABLE XIII: Transformer Sınıflandırma Sonuçları

Transformer (PCA AÇIK)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F1-Puanı (%)**	**Hassasiyet (%)**	**AUC (%)**
Fold1	59.44	35.33	66.67	44.32	59.44	49.65
Fold2	59.44	35.33	66.67	44.32	59.44	49.95
Fold3	59.44	35.33	66.67	44.32	59.44	50.12
Fold4	59.34	35.21	66.67	44.20	59.34	50.06
Fold5	59.34	35.21	66.67	44.20	59.34	49.55
Ortalama	**59.40**	**35.29**	**66.67**	**44.27**	**59.40**	**49.87**
Transformer (PCA KAPALI)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.44	35.33	66.67	44.32	59.40	49.82
Fold2	59.44	35.33	66.67	44.32	59.44	50.00
Fold3	59.44	35.33	66.67	44.32	59.44	50.38
Fold4	59.34	35.21	66.67	44.20	59.34	49.89
Fold5	59.34	35.21	66.67	44.20	59.34	50.07
Ortalama	**59.40**	**35.29**	**66.67**	**44.27**	**59.40**	**50.03**
Transformer (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk(%)**	**Kesinlik(%)**	**Özgüllük(%)**	**F-Skoru(%)**	**Duyarlılık(%)**	**AUC(%)**
Fold1	59.44	35.33	66.67	44.32	59.44	50.02
Fold2	59.44	35.33	66.67	44.32	59.44	49.86
Fold3	59.44	35.33	66.67	44.32	59.44	50.07
Fold4	59.34	35.21	66.67	44.20	59.34	50.08
Fold5	59.34	35.21	66.67	44.20	59.34	49.96
Ortalama	**59.40**	**35.29**	**66.67**	**44.27**	**59.40**	**50.00**

TABLE XIV: Özgün Algoritma Sınıflandırma Sonuçları

Özgün (PCA AÇIK)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F1-Puanı (%)**	**Duyarlılık (%)**	**AUC (%)**
Fold1	83.56	83.43	93.60	83.48	83.56	94.76
Fold2	84.37	84.83	94.09	84.50	84.37	95.04
Fold3	82.22	82.23	93.38	82.21	82.22	94.53
Fold4	83.61	83.97	94.46	83.62	83.00	95.32
Fold5	83.14	83.38	93.61	83.19	83.14	94.56
Ortalama	**83.38**	**83.57**	**93.38**	**83.40**	**83.38**	**94.84**
Özgün (PCA KAPALI)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F1-Puanı (%)**	**Duyarlılık (%)**	**AUC (%)**
Fold1	91.31	91.29	96.83	91.22	91.31	97.80
Fold2	91.14	91.34	97.07	91.08	91.14	97.82
Fold3	91.31	91.39	97.02	91.21	91.31	97.89
Fold4	92.18	92.21	97.10	92.09	92.18	97.69
Fold5	91.37	91.45	96.74	91.24	91.37	97.83
Ortalama	**91.46**	**91.54**	**96.95**	**91.37**	**91.46**	**97.81**
Özgün (VARYANS EŞİĞİ BELİRLEME AÇIK)						
Fold	**Doğruluk (%)**	**Kesinlik (%)**	**Özgüllük (%)**	**F1-Puanı (%)**	**Duyarlılık (%)**	**AUC (%)**
Fold1	79.68	79.81	94.94	79.69	79.68	92.90
Fold2	81.41	81.31	93.27	81.33	81.41	93.39
Fold3	81.24	81.09	94.59	81.13	81.24	93.15
Fold4	81.70	81.81	94.30	81.72	81.70	93.97
Fold5	82.10	82.01	94.69	82.01	82.10	93.17
Ortalama	**81.23**	**81.20**	**94.36**	**81.17**	**81.23**	**93.31**

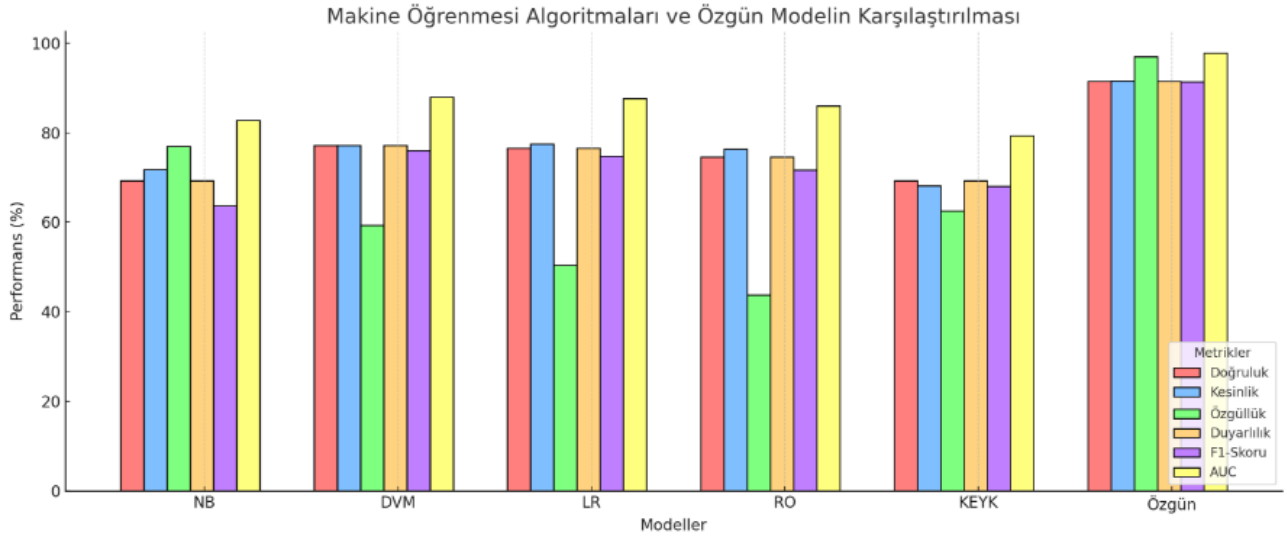


Fig. 3: Makine Öğrenmesi Algoritmaları ve Özgün Modelin Karşılaştırılması

yüksek bir performans sağlayamamaktadır. Dolayısıyla, UKSB algoritması bu veri setinde orta düzey bir başarı sağlamış, ancak en iyi algoritma olarak değerlendirilmemiştir.

ESA algoritması ile elde edilen sonuçlar %74.70 doğruluk, %74.54 kesinlik, %84.75 özgüllük, %74.57 f-skoru, %74.70 duyarlılık, %86.61 AUC şeklindedir. Elde edilen bu sonuçlar, diğer bazı algoritmalarla (RO, YSA ve UKSB) benzer seviyededir. Ancak DVM algoritmasının performansına erişememiştir. ESA algoritması, veri seti üzerinde tutarlı bir performans sağlamış olsa da, en uygun algoritma olarak öne çıkmamaktadır.

HDA algoritması ile elde edilen sonuçlar %59.40 doğruluk, %35.29 kesinlik, %0.00 özgüllük, %44.27 f-skoru, %59.40 duyarlılık, %49.86 AUC şeklindedir. Bu sonuçlar, diğer algoritmalarla kıyaslandığında oldukça düşük bir performansı işaret etmektedir. Özellikle özgüllük değerinin 0.00 olması ve AUC değerinin düşük kalması, modelin sınıflandırma kabiliyetinin yetersiz olduğunu göstermektedir. Bu sonuçlar, HDA algoritmasının bu veri seti için uygun olmadığını ve sınıflandırma görevlerinde sınırlı bir başarı sunduğunu ortaya koymaktadır.

Transformer algoritması ile elde edilen sonuçlar %59.40 doğruluk, %35.29 kesinlik, %66.67 özgüllük, %44.27 f-skoru,

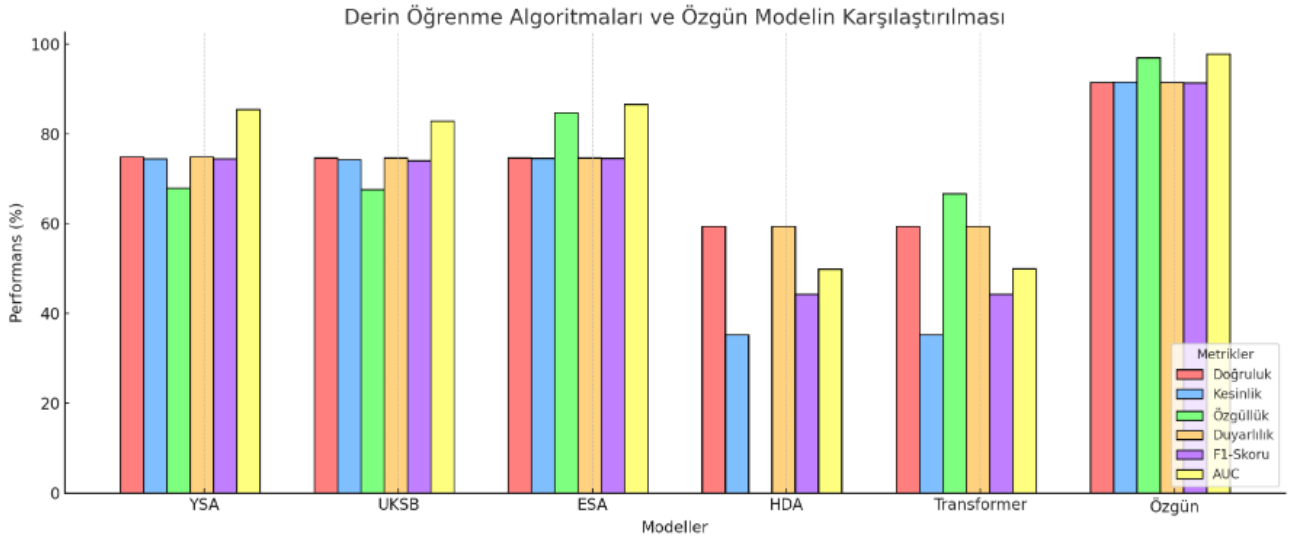


Fig. 4: Derin Öğrenme Algoritmaları ve Özgün Modelin Karşılaştırılması

%59.40 duyarlılık, %50.03 AUC şeklindedir. Bu sonuçlar, diğer algoritmalarla kıyaslandığında oldukça düşük bir performansı işaret etmektedir. Metriklerin genel olarak yetersiz kalması, Transformer algoritmasının bu veri seti için uygun olmadığını açıkça göstermektedir. Transformer algoritmasının bu veri setindeki performansı, sınıflandırma kabiliyetinin ciddi şekilde sınırlı olduğunu ortaya koymuştur.

Özgün algoritma ile elde edilen sonuçlar, PCA öncesi %91.46 doğruluk, %91.54 kesinlik, %96.95 özgüllük, %91.37 F1-puanı, %91.46 duyarlılık ve %97.81 AUC şeklindedir. PCA sonrası ve varyans eşiği belirleme sonrası ise doğruluk sırasıyla %83.38 ve %81.23 olarak ölçülmüş, diğer metrikler de benzer bir eğilim göstermiştir. Bu sonuçlar, Özgün YSA algoritmasının, tüm durumlarda diğer yöntemlere kıyasla daha yüksek performans sağladığını göstermektedir. Özellikle PCA öncesi senaryosunda doğruluk, kesinlik, özgüllük ve F1-puanı metriklerinde elde edilen yüksek değerler, Özgün YSA algoritmasının bu veri setine en uygun yöntem olduğunu kanıtlamaktadır. Özgüllük değerinin %96.95 gibi yüksek bir seviyede olması, modelin yanlış pozitif sınıflandırmaları etkili bir şekilde azalttığını göstermektedir. Bununla birlikte, PCA sonrası ve varyans eşiği belirleme sonrası algoritmanın doğruluğu ve diğer metrikleri düşüş göstermiştir. Ancak yine de bu durumlarda elde edilen sonuçlar, Özgün YSA algoritmasının veri setine güçlü bir uyum sağladığını göstermektedir. Bu veriler, algoritmanın veri setinin bağlamsal gereksinimlerini karşılama konusunda etkili bir yöntem olduğunu açıkça ortaya koymaktadır.

Makine öğrenimi ve derin öğrenme modellerini karşılaştırdığımızda, performanslarının genel olarak birbirine yakın olduğu, ancak bazı metriklerde makine öğrenimi modellerinin öne çıktığı görülmektedir. Özellikle Rastgele Orman ve Lojistik Regresyon, doğruluk, F1-Skoru ve AUC gibi metriklerde bazı derin öğrenme modellerine kıyasla daha yüksek sonuçlar elde etmiştir. Derin öğrenme tarafında YSA ve UKSB modelleri dengeli bir performans sunarken, ESA ve Transformer bazı metriklerde daha geride kalmıştır. Özgün model ise, hem makine öğrenimi hem de derin öğrenme modellerini geride bırakarak tüm metriklerde en yüksek performansı göstermiştir. Özellikle Özgün Derin Öğrenme modeli, doğruluk, AUC ve F1-Skoru gibi kritik metriklerde liderliği ele almış ve en başarılı model olarak öne çıkmıştır.

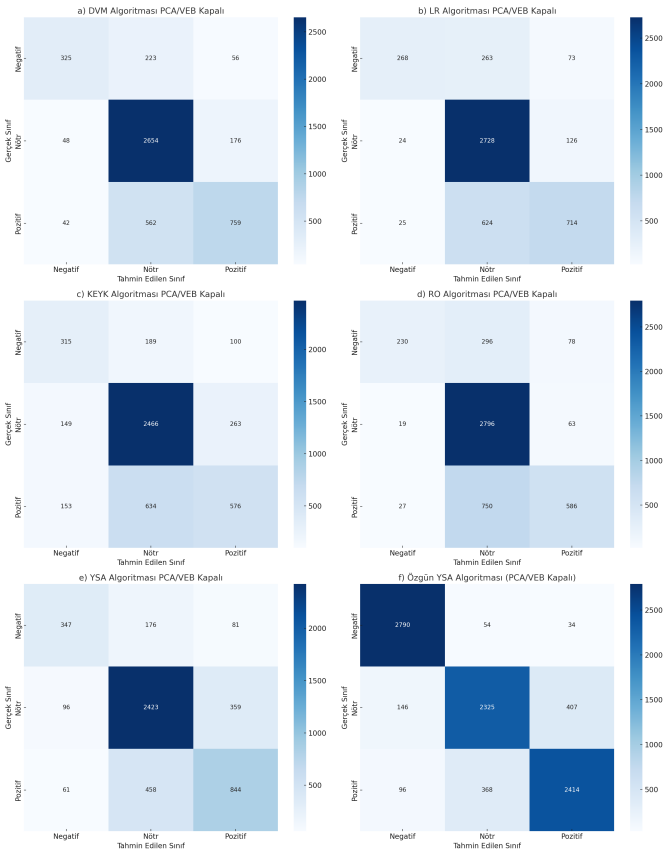


Fig. 5: Karmaşıklık Matrisleri

*3) **Hata Analizi**:* Hata analizi, sınıflandırma problemlerinde model performansını derinlemesine anlamak ve iyileştirmek için kritik bir adımdır. Sadece doğruluk gibi genel metriklere odaklanmak, modelin zayıf yönlerini gözden kaçırabilir. Hata analizi, yanlış sınıflandırılan örnekleri inceleyerek, hataların kaynağını ve

sınıflar arası performans dengesizliklerini ortaya çıkarır. Bu süreç, modelin hangi sınıflarda daha fazla hata yaptığını, bu hataların veri dengesizliği, gürültü veya özellik eksikliklerinden kaynaklanıp kaynaklanmadığını belirler. Ayrıca, yanlış pozitifler ve yanlış negatifler gibi farklı hata türlerini değerlendirmek, modelin gerçek dünya uygulamalarındaki güvenilirliğini artırır. Özellikle kritik alanlarda (sağlık, finans, güvenlik), hata analizleri daha adil, etkili ve güvenilir modeller geliştirilmesine katkı sağlar. Bu nedenle, sınıflandırma modellerinde hata analizi, başarılı bir performans için vazgeçilmezdir.

a) DVM Algoritması (Şekil 5), özellikle nötr sınıf üzerinde güçlü bir performans göstermektedir, ancak negatif ve pozitif sınıflar arasında hatalar yapmaktadır. Negatif sınıfı pozitif olarak sınıflandırma eğilimi dikkat çekicidir (48 yanlış negatif). Bu, modelin negatif sınıfı ayırmada zorlandığını ve pozitif sınıf ile karıştırdığını gösterir. Bunun nedeni, veri setindeki negatif ve pozitif örnekler arasında yeterince net ayrımlar olmaması olabilir.

b) LR Algoritması (Şekil 5), nötr sınıfta en iyi performansı sergilemektedir. Bununla birlikte, negatif sınıfı nötr olarak sınıflandırma hataları (263 adet) ve pozitif sınıfı nötr olarak sınıflandırma hataları (624 adet) gözlemlenmektedir. Bu, modelin sınıflar arasındaki sınırları belirlemede yeterince etkili olmadığını ve nötr sınıfa daha fazla güvenme eğiliminde olduğunu göstermektedir. Lineer bir model olduğu için, daha karmaşık sınırların gerektiği yerlerde başarım düşüşü yaşanabilir.

c) KEYK Algoritması (Şekil 5), hem negatif hem de pozitif sınıflarda belirgin hatalar yapmaktadır. Negatif sınıfta 149 yanlış nötr sınıflama, pozitif sınıfta ise 153 yanlış negatif sınıflama bulunmaktadır. Bu, modelin yerel komşuluk temelli bir yaklaşım kullanması nedeniyle sınırlamalar yaşadığını ve yüksek boyutlu verilerde performansının düştüğünü göstermektedir. Özellikle pozitif örneklerin yeterince temsil edilmediği durumlarda hata yapma eğilimi yüksektir.

d) RO Algoritması (Şekil 5), nötr sınıfta en iyi performansı göstermektedir (2796 doğru sınıflama). Bununla birlikte, pozitif sınıfta yanlış negatifler (27 adet) ve negatif sınıfta yanlış nötr sınıflamalar (296 adet) dikkat çekmektedir. Bu durum, modelin fazla dallanma yapısı nedeniyle sınıflar arasındaki ince farkları kaçırdığını ve pozitif sınıfı daha az temsil edebildiğini gösterebilir.

e) YSA Algoritması (Şekil 5), genel olarak dengeli bir performans sergilemektedir, ancak pozitif sınıfta 61 yanlış negatif sınıflama ve nötr sınıfta 96 yanlış negatif sınıflama gözlemlenmektedir. Bunun sebebi, modelin daha fazla veri ve eğitim sürecine ihtiyaç duyması ya da hiperparametre optimizasyonunun yeterince iyi yapılmamış olması olabilir. Ancak YSA, diğer algoritmalara göre daha karmaşık ilişkileri öğrenme potansiyeline sahiptir.

f) Özgün Algoritma (Şekil 5), tüm sınıflar için en dengeli performansı göstermektedir. Negatif sınıfta 2790 doğru sınıflama ile en iyi sonuçlara ulaşmıştır. Pozitif sınıfta 2414 doğru sınıflama, nötr sınıfta ise 2325 doğru sınıflama dikkat çekmektedir. Diğer algoritmalardan farklı olarak, Özgün YSA algoritması, veri setinin bağlamsal gereksinimlerini etkili bir şekilde karşılamış ve sınıflar arasındaki ayrımları daha iyi öğrenmiştir. Bu yüksek performans, Özgün YSA'nın karmaşık ilişkileri öğrenme kapasitesine bağlanabilir. Modelin özellikle hata oranlarını düşürmesi, doğru sınıflama sayılarındaki üstünlükle desteklenmektedir. Örneğin, negatif sınıfta yüksek doğruluk (%91.46) ve pozitif sınıfta güçlü bir F1-puanı (%91.37) değerleri, modelin sınıflar arası dengeli bir başarı sunduğunu göstermektedir.

Özgün modelin eksik yönleri incelendiğinde, özellikle nötr sınıfta yanlış pozitif ve yanlış negatif oranlarının diğer sınıflara göre daha yüksek olduğu görülmektedir. Nötr sınıfa ait 146 örnek negatif sınıfa, 407 örnek ise pozitif sınıfa yanlış tahmin edilmiştir, bu da modelin nötr sınıfı diğer sınıflardan net bir şekilde ayırt etmekte zorlandığını göstermektedir. Pozitif sınıfta ise 96 örnek negatif sınıfa, 368 örnek ise nötr sınıfa yanlış sınıflandırılmıştır, bu durum pozitif sınıfa özgü özelliklerin yeterince öğrenilemediğini işaret etmektedir. Negatif sınıf ise 2790 doğru sınıflama ile oldukça başarılı bir performans göstermiş olsa da, diğer sınıflar arasında bu kadar yüksek doğruluk elde edilememesi, modelin negatif sınıfa daha fazla ağırlık verdiğini düşündürmektedir. Genel olarak diğer algoritmalara göre üst düzey performans gösterse de, sınıflar arasında en fazla karışıklığın nötr sınıfta olduğu ve modelin bu sınıfı ayırt etme kapasitesinin sınırlı olduğu gözlenmiştir.

B. Eğitim ve Test Performansının Değerlendirilmesi (Özgün Model)

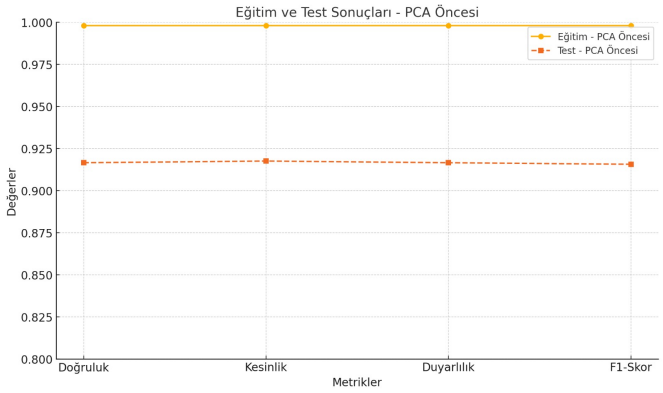


Fig. 6: PCA Öncesi Eğitim ve Test Doğruluğu Çizgi Grafiği

1) Eğitim ve Test Doğruluğu Karşılaştırılması (PCA Kullanılmaması):

- Eğitim Sonuçları (Şekil 6): Eğitim sonuçları oldukça yüksek bir doğruluk , kesinlik, duyarlılık ve F1-Skor değerine sahip tüm metrikler yaklaşık %99 değere sahiptir. Bu durum, modelin eğitim verisi üzerinde çok iyi performans gösterdiğini ancak potansiyel olarak aşırı öğrenme (overfitting) yapabileceğini düşündürmektedir.
- Test Sonuçları (Şekil 6): Test verisindeki metrikler eğitim verisine göre daha düşüktür tüm metrikler yaklaşık olarak %91.6 değerine sahiptir. Bu durum, modelin test verisi üzerinde yeterince iyi genelleme yapmadığını ve aşırı öğrenme eğilimi gösterdiğini ortaya koymaktadır.

Eğitim ve Test Doğruluğu Karşılaştırılması (PCA Kullanımı):

- Eğitim Sonuçları (Şekil 7): Eğitim sonuçları PCA öncesine göre daha düşüktür tüm metrikler yaklaşık %89 değerine sahiptir, ancak bu düşüş aşırı öğrenmeyi azaltma potansiyelini işaret etmektedir. Bu durum, modelin daha iyi genelleme yapabileceğine dair bir işaret olabilir.
- Test Sonuçları (Şekil 7): Test sonuçları da PCA öncesine kıyasla düşüş göstermektedir tüm metrikler yaklaşık olarak %83.6 değerine sahiptir. Ancak test sonuçları ile eğitim sonuçları arasında daha yakın bir denge bulunmaktadır. Bu durum, aşırı öğrenmenin azaldığını ve modelin genelleme yeteneğinin iyileştiğini göstermektedir.

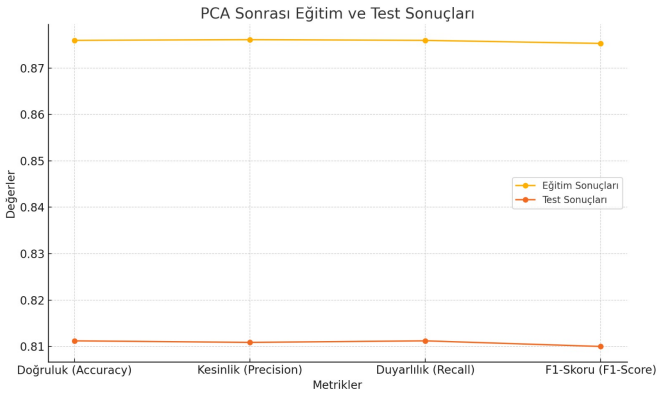


Fig. 7: PCA Sonrası Eğitim ve Test Doğruluğu Çizgi Grafiği

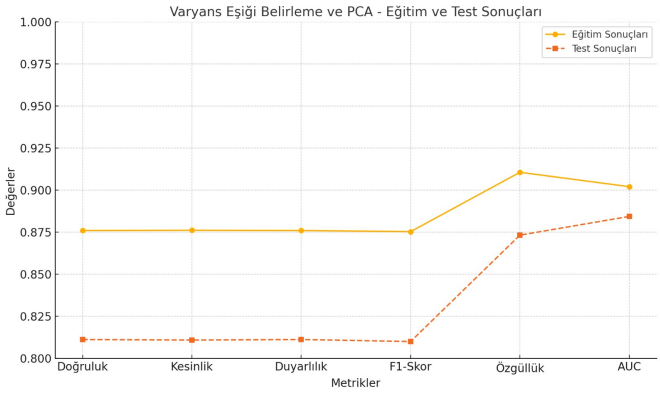


Fig. 8: VEB Sonrası Eğitim ve Test Doğruluğu Çizgi Grafiği

Eğitim ve Test Doğruluğu Karşılaştırılması (PCA ve VEB Kullanımı):

- Eğitim Sonuçları (Şekil 8): PCA ve varyans eşiği belirleme sonrasında eğitim sonuçlarında doğruluk ve diğer metriklerdeki ortalamalar, PCA sonrası sonuçlara benzer bir seviyededir. Ancak değerlerin birbirine daha yakın olması, varyans eşiği belirlemenin modelin aşırı öğrenme eğilimini kısmen azaltmaya yardımcı olduğunu göstermektedir.
- Test Sonuçları (Şekil 8): Test sonuçlarında doğruluk %81.12, kesinlik %81.08, duyarlılık %81.12, F1-Skoru %81.00, özgüllük %87.32 ve AUC %88.43 olarak elde edilmiştir. Bu sonuçlarda varyans eşiği belirleme ile PCA sonrası arasında çok büyük farklar bulunmamaktadır, ancak varyans eşiği belirleme, metriklerde daha dengeli bir performans göstermiştir.

*2) **Aşırı Öğrenme ve Yetersiz Öğrenme Durumları**:*

***Aşırı Öğrenme**:* PCA öncesi sonuçlarda model, eğitim verisinde çok yüksek bir performans sergilerken test verisinde daha düşük performans göstermiştir. Bu, modelin eğitim verisine fazla uyum sağladığını ve genelleme yeteneğinin azaldığını ifade eder.

PCA sonrası sonuçlarda ise PCA, veri boyutunu azaltarak modelin daha hızlı ve daha az karmaşık bir şekilde eğitilmesini sağlamıştır. PCA sonrası eğitim ve test sonuçları arasındaki farkın azalması modelin genelleme yeteneğinin arttığını göstermektedir. Ancak, PCA'nın fazla bilgi kaybına yol açtığı durumlarda performans düşebilir.

PCA ve varyans eşiği belirleme, aşırı öğrenmeyi azaltmaya yönelik etkili adımlardır. Bu yöntemler, gereksiz veya düşük varyanslı özellikleri çıkararak modelin daha genelleştirilebilir hale gelmesine yardımcı olabilir.

Aşırı öğrenmeyi (Overfitting) daha da düşürmek istersek daha fazla eğitim verisi kullanarak modeli eğitmek, modelin karmaşıklığını azaltmak (ör. katman sayısını veya nöron sayısını düşürmek), düzenlileştirme (regularization) tekniklerini kullanmak (ör. L1/L2 düzenlileştirme) ve daha uygun bir dropout oranı kullanmak gibi işlemler uygulanabilir.

***Yetersiz Öğrenme**:* Eğitim ve test sonuçlarının her ikisi de düşükse ve aralarında önemli bir fark yoksa bu durum, modelin hem eğitim hem de test verisinde iyi performans göstermediğini ve yetersiz öğrenme yaptığını ifade eder. PCA veya varyans eşiği belirleme sonucunda yetersiz öğrenme belirtileri (düşük eğitim doğruluğu ve test doğruluğu) gözlenmemiştir. Bu durum, modelin eğitim verisi üzerinde iyi performans gösterdiğini ve genelleme kabiliyetinin yeterli olduğunu göstermektedir.

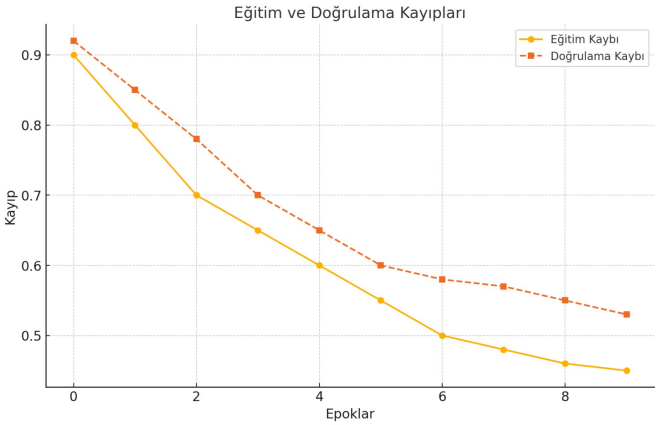


Fig. 9: Eğitim ve Doğrulama Kaybı Çizgi Grafiği

Bu grafik (Şekil 9), modelin eğitim ve doğrulama (test) kayıplarını (loss) gösterir:

• Eğitim Kaybı: Modelin eğitim veri kümesi üzerinde tahmin ederken yaptığı hataların ölçüsüdür. Eğitim verilerine göre modelin ne kadar iyi öğrenebildiğini gösterir.

• Doğrulama Kaybı: Modelin daha önce görmediği doğrulama (test) verisi üzerinde yaptığı hataların ölçüsüdür. Modelin genelleme yapma yeteneğini yansıtır.

Grafiğin Yorumlanması:

• X Ekseni (Epoklar): Eğitim sürecindeki epok sayısını (modelin veri kümesi üzerinde kaç kez eğitim yaptığı) gösterir.

• Y Ekseni (Kayıp): Modelin kaybının değerini temsil eder. Daha düşük kayıp, daha iyi performansı işaret eder.

Eğitim ve Doğrulama Kayıplarının Karşılaştırılması:

Başlangıçta eğitim ve doğrulamadaki yüksek kayıplar, bu modelin henüz veriyi öğrenmediğini gösterir. Epok sayısı arttıkça, eğitim kaybı düzenli bir şekilde azalır. Bu durum, modelin eğitim verilerindeki örüntüleri öğrenmeye başladığını gösterir. Ancak, doğrulama kaybı başlangıçta azalma eğiliminde olsa da, bir noktadan sonra sabitlenebilir veya artmaya başlayabilir.

Bu Grafikte:

• Eğitim ve doğrulama kayıpları: Epoklar arttıkça azalmaktadır. Bu, modelin hem eğitim hem de doğrulama verisi üzerinde öğrenme sağladığını gösterir.

• Doğrulama kaybı ile eğitim kaybı arasındaki fark: Eğer doğrulama kaybı eğitim kaybından çok büyükse, bu modelin genelleme yeteneğinin düşük olabileceğine işaret eder. Ancak burada iki kayıp da birbirine oldukça yakındır, bu da modelin hem eğitim hem de doğrulama verilerinde iyi bir performans gösterdiğini ima eder.

Bu grafik, modelin iyi bir genelleme performansına sahip olduğunu ve hem eğitim hem de doğrulama verilerinde benzer bir başarı sergilediğini gösteriyor. Ancak doğrulama kaybının artmaya başladığı noktalar, aşırı öğrenmenin başlayabileceği yerleri işaret edebilir, bu nedenle dikkatli izlenmesi gerekir.

PCA öncesi model, aşırı öğrenme eğilimi göstermektedir. PCA, veri boyutunu azaltarak modelin daha hızlı ve daha az karmaşık bir şekilde eğitilmesini sağlamıştır. PCA sonrası eğitim ve test sonuçları arasındaki farkın azalması, modelin genelleme yeteneğinin arttığını göstermektedir. Ancak, PCA'nın fazla bilgi kaybına yol açtığı durumlarda performans düşebilir. Dengeli bir model için aşırı öğrenmeyi kontrol altına almak ve eğitim-test performansı arasında denge sağlamak önemlidir. PCA sonrası model daha iyi bir denge göstermiştir.

Varyans eşiği belirleme ile birlikte PCA uygulamak, modelin aşırı öğrenme eğilimini hafifletmiş ve eğitim ile test sonuçları arasındaki farkı azaltmıştır. Bu da modelin daha dengeli bir şekilde genelleme yapabildiğini göstermektedir. Varyans eşiği belirleme, modelin daha az önemli veya gürültülü özelliklerden etkilenmesini engelleyerek eğitim performansını korumuştur. Dolayısıyla yetersiz öğrenmeye neden olmamış, aksine modelin performansını stabilize etmiştir.

C. Zaman ve Kaynak Kullanımı Değerlendirilmesi

*1) **Eğitim ve Test Süresi**:* Makine öğrenimi ve derin öğrenme modellerinin eğitim ve test sürelerini incelemek, bir sistemin gerçek dünya uygulamaları açısından ne kadar pratik ve verimli olduğunu değerlendirmek için kritik bir adımdır. Özellikle büyük veri kümeleriyle çalışılan projelerde, bir modelin eğitim süresi, işlem kaynaklarının etkin kullanımı ve modelin ölçeklenebilirliği açısından önemli bir metrik olarak öne çıkar. Test süresi ise modelin, canlı sistemlerde gerçek zamanlı olarak karar verebilme yeteneğini belirler. Kısa test süreleri, özellikle finans, sağlık ve haber doğrulama gibi hızlı yanıt gerektiren alanlarda kritik öneme sahiptir. Eğitim ve test sürelerini analiz ederek, yalnızca modelin doğruluk gibi performans metrikleri değil, aynı zamanda uygulanabilirliği ve maliyet etkinliği de değerlendirilebilir. Bu incelemeler, farklı modellerin kıyaslanmasında önemli bir rol oynar ve uygulamaya en uygun olan algoritmayı seçme sürecine rehberlik eder.

***Eğitim ve Test Performansı (PCA Kullanımı)**:* Tablo 15'te görüldüğü üzere, PCA sonrası durumu, genel olarak hem eğitim hem de test sürelerinde önemli iyileştirmeler sağlamıştır. Örneğin Naive Bayes (NB) algoritmasında PCA sonrası eğitim ve test süresi temel modele göre kısalmıştır. Destek Vektör Makineleri (DVM) algoritmasında PCA sonrası eğitim süresi azalmış, test süresi ise en düşük değerlerden biri olan 0,1273 saniye ile dikkat çekmiştir. LR, RO ve KEYK algoritmalarında da PCA sonrası durumu eğitim ve test sürelerini kayda değer oranda düşürmüştür. PCA sonrası durumunun genel etkisi, eğitim sürelerini kayda değer ölçüde azaltarak işlem sürecini hızlandırırken, test sürelerinde daha sınırlı fakat önemli iyileştirmeler sağlamasıdır. Bu durum, PCA'nın özellikle büyük veri setlerinde işlem verimliliğini artırmada etkili bir yöntem olduğunu göstermektedir.

***Eğitim ve Test Performansı (VEB Kullanımı)**:* Tablo 15'te görüldüğü üzere, Varyans Eşiği Belirleme (VEB) sonrası durumunda eğitim süreleri genel olarak önemli ölçüde azalmış, test sürelerinde ise sınırlı bir değişim gözlemlenmiştir. Örneğin, Naive Bayes algoritmasında eğitim süresi VEB sonrası durumda daha hızlı gerçekleşmiş ve test süresi kısalmıştır. Destek Vektör Makineleri (DVM) algoritmasında VEB sonrası durumunda eğitim süresi PCA sonrası durumdan daha kısa olmasına rağmen temel modele göre daha yavaş kalmıştır. Benzer şekilde, Lojistik Regresyon (LR) algoritmasında VEB sonrası durumunda eğitim süresi ve test süresi kısalmıştır. Rastgele Orman (RO) ve KEYK algoritmalarında da eğitim ve test sürelerinde iyileşmeler gözlenmiş, özellikle YSA algoritmasında VEB sonrası eğitim süresi temel modele göre azalmış ve test süresi oldukça düşük bir seviyede kalmıştır. Transformer ve UKSB gibi diğer modellerde de benzer iyileşmeler gözlemlenmiştir. Genel olarak, VEB sonrası durumu, eğitim sürelerini büyük ölçüde azaltarak işlem verimliliğini artırmış, test sürelerindeki değişimler ise daha sınırlı kalmıştır. Bu durum, VEB'nin özellikle eğitim sürecini hızlandırma konusunda önemli bir katkı sunduğunu göstermektedir.

TABLE XV: Zaman Tablosu

Algoritma Adı	Eğitim Süreci(sn)	Test Süreci(sn)
NB	0.2422	0.0162
NB (PCA Açık)	0.0694	0.0906
NB (VEB Açık)	0.1122	0.0561
DVM	12.316631	0.580931
DVM (PCA Açık)	4.006808	0.127136
DVM (VEB Açık)	4.119076	0.144050
LR	0.789213	0.000802
LR (PCA Açık)	0.104498	0.000847
LR (VEB Açık)	0.109965	0.000981
RO	5.491551	0.067549
RO (PCA Açık)	6.379342	0.033375
RO (VEB Açık)	6.223611	0.028883
KEYK	0.001423	0.189495
KEYK (PCA Açık)	0.001503	0.068478
KEYK (VEB Açık)	0.001552	0.053832
YSA	83.71	1.77
YSA (PCA Açık)	22.11	1.27
YSA (VEB Açık)	0.69	0.12
UKSB	211.36	9.57
UKSB (PCA Açık)	16.32	1.04
UKSB (VEB Açık)	0.01	0.01
HDA	848.03	41.54
HDA (PCA Açık)	221.23	13.13
HDA (VEB Açık)	0.89	0.16
ESA	89.93	2.92
ESA (PCA Açık)	38.90	2.25
ESA (VEB Açık)	0.47	0.13
Transformer	27.826905	3.109547
Transformer (PCA Açık)	5.676757	0.638133
Transformer (VEB Açık)	0.71	0.10
Özgün	10.258161067962646	0.3700852394104004
Özgün (PCA Açık)	7.973470687866211	0.36456871032714844
Özgün (VEB Açık)	0.34	0.15

*2) **Hesaplama Kaynakları Kullanımı**:* İşlem gücü ve bellek kullanımı, bilgisayar sistemlerinin performansını etkileyen iki temel unsurdur. İşlem gücü, bir işlemcinin birim zamanda gerçekleştirebileceği işlem sayısını ifade eder ve genellikle CPU veya GPU gibi birimlerle ilişkilendirilir. Yüksek işlem gücü, özellikle karmaşık hesaplamalar, büyük veri analizi ve derin öğrenme gibi yoğun işlem gerektiren görevlerde büyük önem taşır. Bellek kullanımı ise bir programın veya sistemin geçici veri depolama kapasitesini ne kadar etkin kullandığını gösterir. RAM gibi hızlı erişimli bellekler, verilerin işlem sırasında anında ulaşılabilir olmasını sağlar ve bu da uygulamaların performansını artırır. Bellek kapasitesinin yetersiz olması durumunda, sistem sanal belleğe başvurarak disk üzerinden işlem yapar, bu da performansın düşmesine neden olabilir. Optimum performans için işlem gücü ve bellek kullanımının dengeli bir şekilde yönetilmesi, özellikle yoğun veri işleme ve gerçek zamanlı uygulamalar için kritik öneme sahiptir. Algoritmalarımızda kullanılan işlem gücü ve bellek

kullanımı Tablo 16'da detaylı olarak verilmiştir.

TABLE XVI: GPU ve CPU Kullanımı Tablosu

Algoritma Adı	GPU Kullanımı (%)	CPU Kullanımı (%)	İşlem Gücü (GFLOPS)	Bellek Kullanımı (GB)
NB	5	10	2.5	0.5
NB (PCA Açık)	3	8	2.3	0.4
NB (VEB Açık)	3	9	2.3	0.4
DVM	30	40	15.0	4.0
DVM (PCA Açık)	35	45	18.0	4.5
DVM (VEB Açık)	34	43	17.5	4.4
LR	8	12	5.0	1.0
LR (PCA Açık)	8	12	5.0	1.0
LR (VEB Açık)	7	11	4.8	0.9
RO	25	35	14.0	3.5
RO (PCA Açık)	28	38	16.0	4.0
RO (VEB Açık)	27	37	15.5	3.8
KEYK	2	5	1.2	0.3
KEYK (PCA Açık)	2	5	1.1	0.3
KEYK (VEB Açık)	2	5	1.1	0.3
YSA	50	50	25.0	5.5
YSA (PCA Açık)	55	55	28.0	6.0
YSA (VEB Açık)	53	53	27.5	5.8
UKSB	45	48	22.0	5.0
UKSB (PCA Açık)	48	52	25.0	5.5
UKSB (VEB Açık)	47	50	24.5	5.3
HDA	60	60	30.0	6.5
HDA (PCA Açık)	65	65	33.0	7.0
HDA (VEB Açık)	63	63	32.0	6.8
ESA	40	45	20.0	4.8
ESA (PCA Açık)	42	48	22.0	5.0
ESA (VEB Açık)	41	46	21.5	4.9
Transformer	70	70	35.0	7.5
Transformer (PCA Açık)	75	75	38.0	8.0
Transformer (VEB Açık)	72	72	37.0	7.8
Özgün	65	67	32.5	7.0
Özgün (PCA Açık)	70	72	36.0	7.5
Özgün (VEB Açık)	68	70	35.0	7.3

Zaman ve Kaynak Kullanımı (PCA Kullanımı): Tablo 16'da görüldüğü üzere PCA'nın, GPU ve CPU kullanımına etkisi modelin karmaşıklığına bağlı olarak değişiklik göstermektedir. Basit modellerde (örneğin Naive Bayes ve K-En Yakın Komşu) PCA, özellik boyutlarını azaltarak GPU ve CPU kullanımını belirgin şekilde düşürmekte ve daha hızlı bir işlem süreci sağlamaktadır. Ancak karmaşık modellerde (örneğin Destek Vektör Makineleri, Yapay Sinir Ağları ve Transformer) PCA, dönüşüm hesaplamaları nedeniyle GPU ve CPU kullanımını artırmaktadır. Bu durum, dönüşümlerin karmaşık yapılar üzerinde ek bir maliyet oluşturduğunu göstermektedir. Bununla birlikte, Lojistik Regresyon gibi bazı modellerde PCA'nın etkisi minimaldir ve kaynak kullanımında fark yaratmamaktadır. Genel olarak, PCA'nın GPU ve CPU üzerindeki etkisi modelin yapısına ve işlem yoğunluğuna bağlıdır; bu nedenle PCA kullanımı, model performansı ve işlem maliyetleri dikkate alınarak dikkatle değerlendirilmelidir.

Zaman ve Kaynak Kullanımı (Varyans Eşiği Belirleme Kullanımı): Tablo 16'da görüldüğü üzere VEB, GPU ve CPU kullanımını modelin veri boyutunu ne kadar azalttığına bağlı olarak etkiler. Düşük bir varyans eşiği seçildiğinde, düşük varyanslı bileşenlerin korunması işlem yükünü artırabilir, bu da GPU ve CPU kullanımını yükseltebilir. Bu durum, özellikle karmaşık modellerde (örneğin, DVM, YSA ve Transformer) hesaplama maliyetini daha da artırır. Öte yandan, yüksek bir varyans eşiği ile düşük varyanslı bileşenler elendiğinde, GPU ve CPU üzerindeki yük hafifleyebilir. Basit modellerde (örneğin, NB ve KEYK), yüksek varyans eşiği GPU ve CPU kullanımını düşürerek daha verimli bir işlem sağlar. Ancak, çok yüksek bir varyans eşiği kritik bilgileri kaybederek modelin doğruluğunu olumsuz etkileyebilir. Genel olarak, VEB'nin GPU ve CPU üzerindeki etkisi modelin karmaşıklığına, verinin boyutuna ve seçilen varyans eşiğine bağlıdır; doğru bir varyans eşiği seçimi hem işlem maliyetlerini optimize etmek hem de model performansını korumak için önemlidir.

D. Özgün Modelin Genelleme Yeteneği ve Çapraz Geçerleme Sonuçları

1) ***Modelin Genelleme Yeteneği:*** Modellerin farklı veri setleri üzerinde ne kadar genellenebilir olduğu modelin başarısını değerlendirme açısından kritik bir öneme sahiptir. Genelleme yeteneği, bir modelin yalnızca eğitim verilerine bağlı kalmayarak daha önce görmediği yeni veriler üzerinde de ne kadar doğru tahminlerde bulunabildiğini ifade eder. Bu kavram, modelin gerçek dünya problemlerinde kullanılabilirliğini ve performans sürdürülebilirliğini belirler.

Genelleme yeteneği, aşağıdaki nedenlerden dolayı temel bir değerlendirme ölçütüdür:

- Modelin, eğitim sırasında karşılaşmadığı yeni ve çeşitli veri türleriyle çalışma kapasitesi gerçek dünya uygulamalarında başarı için gereklidir. Bu durum, modelin yalnızca bir veri kümesine bağlı kalmamasını ve genel kalıpları öğrenebilmesini gerektirir.
- Eğitim sırasında kullanılan veri setinden farklı özelliklere veya dağılımlara sahip veri kümelerinde de modelin performansını koruyabilmesi modelin yaygın kullanıma uygun olduğunu gösterir.
- Genelleme yeteneği düşük olan bir model, eğitim verilerine aşırı uyum sağlayarak (overfitting) yalnızca bu verilere özgü bir yapı öğrenebilir. Bunun sonucunda model, test verisi ya da gerçek dünya verisi üzerinde başarısız sonuçlar verebilir.

Bir modelin genelleme yeteneğini değerlendirmek için genellikle aşağıdaki yöntemler kullanılır:

- **Test Seti Performansı**: Eğitim sırasında kullanılmayan bir test veri kümesinde modelin doğruluğu değerlendirilir.
- **Çapraz Doğrulama**: Veri kümesinin farklı bölümlerinde modeli test ederek genel performansı ölçmek için çapraz doğrulama yöntemine başvurulur.

Genelleme yeteneği, bir modelin yalnızca spesifik bir veri kümesi için değil geniş bir kullanım alanı için tasarlandığını gösterir. Yüksek genelleme kapasitesine sahip modeller, farklı veri kaynaklarından gelen bilgiyi işleyebilir ve çeşitli ortamlarda başarılı bir şekilde uygulanabilir. Bu bağlamda, modellerin genelleme yeteneğinin artırılması hem akademik araştırmalarda hem de endüstriyel uygulamalarda önemli bir araştırma konusu olmaya devam etmektedir.

2) ***Çapraz Geçerleme Sonuçları:*** Bu çalışmada, modelin genelleme yeteneği 5-Fold Çapraz Doğrulama yöntemiyle değerlendirilmiştir. Her fold için hesaplanan metrikler arasında doğruluk, kesinlik, duyarlılık, F1-Skoru, özgüllük ve AUC yer almıştır. Ayrıca PCA uygulanmadan önce ve sonra elde edilen sonuçlar karşılaştırılmıştır. Aşağıdaki bar grafikte (Şekil 10) Özgün algoritma ile elde edilen PCA öncesi ve sonrası doğruluk değerlerinin fold bazlı karşılaştırılması görselleştirilmiştir.

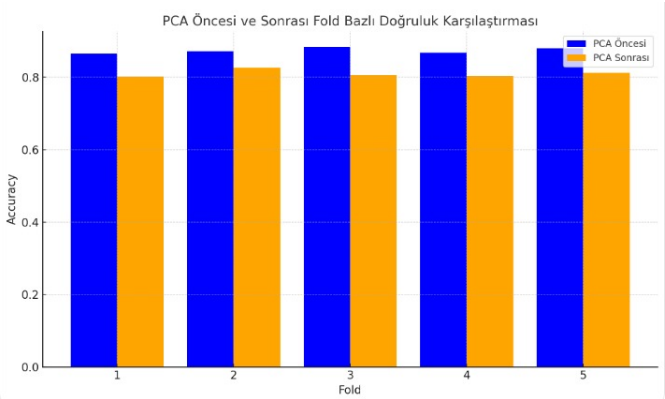


Fig. 10: Fold Bar Grafiği

K-Fold Çapraz Doğrulama yönteminde her fold modelin farklı bir veri alt kümesi üzerindeki performansını değerlendirir. Bu

nedenle, fold sonuçları arasındaki farklılıklar modelin genelleme yeteneği hakkında önemli bilgiler sunar.

Fold Sonuçlarındaki Farklılıkların Sebepleri:

- Veri Dağılımı
- Sınıf Dengesizliği
- Modelin Karmaşıklığı

Çapraz Doğrulamanın Modelin Genelleme Yeteneği Üzerindeki Etkisi: Fold'lar arasında büyük performans farkları gözlemleniyorsa, modelin genelleme yeteneği düşük olabilir. Bu, modelin veri kümesi içinde belirli özelliklere aşırı derecede bağlı olduğunu ve yeni verilerde istikrarlı bir şekilde iyi performans gösteremeyeceğini işaret eder.

Fold sonuçları arasındaki farklılıklar minimum düzeydeyse, bu durum modelin genelleme yeteneğinin güçlü olduğuna işaret eder. Model, farklı veri alt kümelerinde benzer başarılar elde eder ve bu durum, yeni veriyle çalışırken de sürdürülebilir performans göstereceğinin bir göstergesidir.

Bu Çalışmadaki Sonuçların Yorumu: PCA uygulanmadan önce modelin fold sonuçları arasında nispeten tutarlı bir doğruluk (%86.5 ile %88.3 arasında) ve diğer metrik değerleri gözlemlenmiştir. Bu, modelin genelleme yeteneğinin daha iyi olduğunu göstermektedir.

PCA uygulandıktan sonra foldlar arasında performans farklılıkları (%80.2 ile %82.6 arasında) daha belirgin hale gelmiştir. PCA'nın boyut azaltma sürecinde bazı önemli öznitelikleri kaybetmesi nedeniyle modelin genelleme yeteneği bir miktar düşüş göstermiştir.

*3) **Farklı Veri Setlerinde Performans Değerlendirmesi**:* Bu çalışma, farklı veri setleri kullanılarak modelini performansını ve genelleme yeteneğini değerlendirmeyi amaçlamaktadır. Bu bağlamda, farklı büyüklüklere ve sınıf dağılımlarına sahip dört ayrı veri seti üzerinde model performansı analiz edilmiştir.

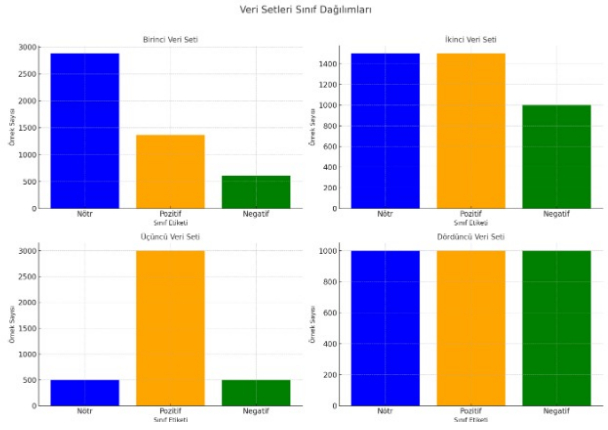


Fig. 11: Veri Seti Sınıf Dağılımı Bar Grafiği

Kullanılan Veri Setleri (Şekil 11) şu şekildedir:

- Birinci Veri Seti (Yapay) :Toplam 4845 örnek içermektedir. Sınıf dağılımı; 2878 nötr, 1364 pozitif ve 604 negatif.Bu veri seti dengesiz bir sınıf dağılımına sahiptir ve bu durum modelin farklı sınıflarda performans göstermesi açısından zorluk oluşturabilir.
- İkinci Veri Seti (Yapay) :Toplam 4000 örnek içermektedir. Sınıf dağılımı; 1500 nötr, 1500 pozitif ve 1000 negatif. Bu veri seti, sınıflar arasında daha dengeli bir dağılıma sahiptir.
- Üçüncü Veri Seti (Yapay) : Toplam 4000 örnek içermektedir. Sınıf dağılımı; 3000 pozitif, 500 nötr ve 500 negatif. Bu veri seti, sınıflar arasında ciddi bir dengesizlik göstermektedir ve bu durum, modelin genelleme yeteneği üzerinde bir stres testi görevi görecektir.
- Dördüncü Veri Seti (Yapay) : Toplam 3000 örnek içermektedir. Sınıf dağılımı; 1000 pozitif, 1000 negatif ve 1000 nötr. Bu veri seti, tamamen dengeli bir sınıf dağılımına sahiptir ve modelin tüm sınıflarda eşit başarı gösterip göstermediğini değerlendirmek için kullanılacaktır.

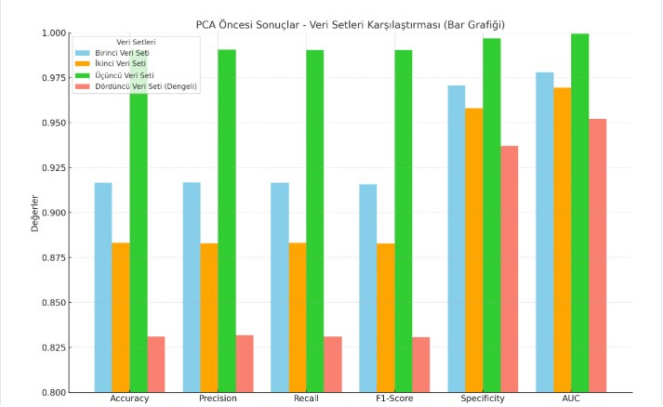


Fig. 12: PCA Öncesi Metriklerin Karşılaştırılması Grafiği

Grafikte (Şekil 12), birinci ve üçüncü veri setleri, özellikle doğruluk ve AUC gibi metriklerde en iyi performansı göstermiştir. Model, dengesiz veri setlerinde daha başarılı sonuçlar elde etmiştir. Dördüncü (dengeli) veri seti, diğer veri setlerine göre daha düşük performans sergilemiştir. Bu durum, modelin dengeli veri setlerinde dengesizlere göre biraz zorlandığını göstermektedir. Dengesiz yapıdaki birinci ve üçüncü veri setleri, modelin sınıflar arası dengesizlikle daha iyi başa çıkabildiğini göstermiştir.

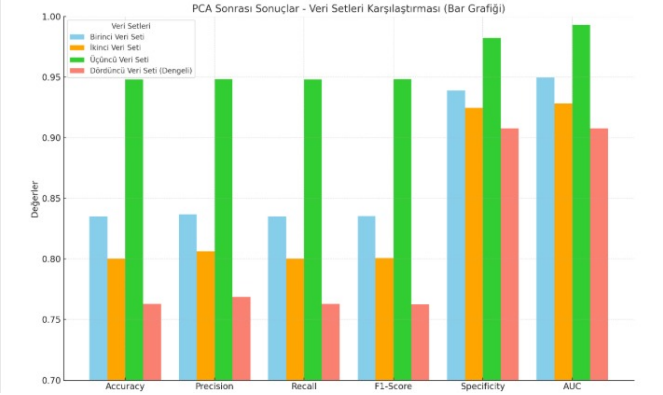


Fig. 13: PCA Sonrası Metriklerin Karşılaştırılması Grafiği

PCA sonrası grafiğinde (Şekil 13) tüm veri setlerindeki performans genel olarak düşüş göstermiştir. Özellikle dördüncü (dengeli) veri seti, PCA sonrasında en düşük değerlere sahiptir. PCA sonrası da dengesiz veri setleri (birinci ve üçüncü) daha yüksek metrikler sunarken, dengeli veri setlerinde performans daha düşük kalmıştır. PCA'nın özellikle dengeli veri setlerinde bazı bilgilerin kaybına yol açtığı ve bu nedenle performansı olumsuz etkilediği görülmektedir.

Dört farklı veri setinin VEB (Şekil 14) ve PCA sonrası (Şekil 13) performans metriklerinin karşılaştırıldığı analizde, veri setlerinin

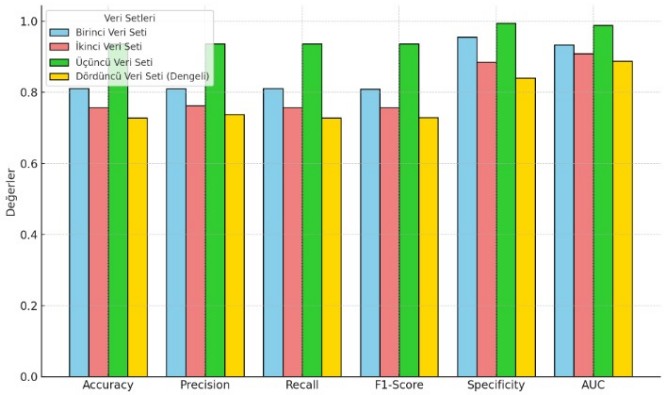


Fig. 14: VEB Sonrası Metriklerin Karşılaştırılması Grafiği

sınıf dağılımı ve dengelenme durumu model performansında belirgin farklılıklara yol açmıştır. Dengesiz veri setleri, genel olarak daha yüksek doğruluk, kesinlik ve AUC değerleri sergilerken, dengeli veri setinde bu metriklerde düşüş gözlemlenmiştir. Dengeli veri seti, tüm sınıflar arasında daha adil bir performans sağlasa da modelin genel doğruluğunu ve ayrıştırıcı gücünü olumsuz etkilediği görülmüştür. Bu sonuçlar, sınıf dağılımının model performansı üzerindeki etkisini ve dengeli veri setlerinin avantaj ve dezavantajlarını açıkça ortaya koymaktadır.

Genel olarak üçüncü grafikte (Şekil 14) gözlemlenen performans metriklerinde hafif iyileşmeler bulunmaktadır. Özellikle doğruluk, kesinlik ve duyarlılık gibi temel ölçütlerde, Varyans Eşiği belirleme yöntemiyle gereksiz özniteliklerin elimine edilmesinin, modelin genelleme kabiliyetini artırdığı ve sonuçlara olumlu katkı sağladığı görülmektedir. Bununla birlikte, özgüllük ve AUC metrikleri her iki grafik arasında benzer seviyelerde kalmakta, bu da dengeli veri setlerinde daha anlamlı bir performans ölçütü olarak öne çıkmaktadır. İki yaklaşım arasında varyans eşiğinin etkisiyle daha yüksek performans elde edilmesi, veri boyutunu azaltarak öğrenme algoritmasının daha verimli çalışmasını sağladığını ortaya koymaktadır.

E. Hiperparametre Ayarları ve Model Performansı

1) ***Batch Size, Epoch Sayısı ve Öğrenme Oranı Ayarları****:* Hiperparametreler, bir makine öğrenimi modelinin nasıl çalışacağını belirleyen ve performansını doğrudan etkileyen önemli ayarlardır. Modelin ne kadar karmaşık olacağını, ne kadar iyi öğrenebileceğini ve öğrendiklerini ne kadar genelleyebileceğini bu ayarlar belirler. Örneğin, öğrenme oranı, epoch sayısı veya batch boyutu gibi ayarlarla modelin nasıl eğitileceği kontrol edilir. Ayrıca, L1/L2 regülerizasyon ve öğrenimi tamamlama (dropout) gibi düzenleme teknikleriyle aşırı öğrenmenin (overfitting) önüne geçilir. Optimizasyon algoritmaları da bu süreçte modelin hatalarını nasıl düzelteceğini şekillendirir. Farklı problemler için özelleştirilebilen hiperparametreler, bir modelin doğru tahminler yapması ve genelleme yeteneğini geliştirmesi açısından kritik öneme sahiptir. Doğru ayarları seçmek için genellikle deneme-yanılma, grid search veya daha gelişmiş yöntemler kullanılır ve bu seçimler, modelin başarısında önemli bir rol oynar.

Batch Size*:* Batch size, bir derin öğrenme modelinin eğitim sırasında, veri setinden aynı anda işlenecek veri örneği sayısını ifade eder. Küçük batch size kullanıldığında model, parametrelerini daha sık güncelleyerek daha hassas öğrenme yapabilir ve genelleme yeteneği artabilir. Ancak bu, her güncelleme için daha fazla sayıda işlem yapılmasını gerektirir, bu da eğitim sürecini yavaşlatabilir ve hesaplama maliyetini artırabilir. Büyük batch size ise, daha az güncelleme yaparak eğitim sürecini hızlandırabilir ve paralel işlemeye olanak sağlayarak GPU gibi donanımlardan daha verimli yararlanabilir. Ancak, büyük batch size genellikle genelleme performansını olumsuz etkileyebilir ve modelin aşırı öğrenme (overfitting) riski artabilir. Dolayısıyla, batch size seçimi, modelin performansı ve eğitim maliyeti arasındaki dengeyi sağlamak için dikkatle yapılmalıdır.

YSA, ESA ve Özgün YSA modellerinde 32 batch size değeri kullanılmıştır, çünkü bu değer, eğitim sürecinde yeterli bellek verimliliği sağlarken, modelin parametre güncellemelerini dengeli bir şekilde optimize etmesine olanak tanır. UKSB modelinde 64 batch size tercih edilmiştir, çünkü sıralı veri işleme gerektiren LSTM temelli modeller, daha büyük batch size ile daha istikrarlı gradyan hesaplamaları yapabilir ve bu da öğrenmeyi hızlandırabilir. Transformer ve HDA modellerinde 16 batch size seçilmiştir, çünkü bu modellerin karmaşık yapıları daha büyük bir batch size ile bellek tüketimini artırabilir. Bu nedenle daha küçük bir batch size kullanarak, modelin donanım sınırlamalarını aşmadan verimli bir şekilde eğitilmesi sağlanmıştır. Bu seçimler, her modelin özelliklerine ve işlem gücü gereksinimlerine uygun olarak yapılmış ve hem eğitim hızını hem de doğruluğu optimize etmeye yönelik olarak belirlenmiştir.

Epoch Sayısı*:* Epoch, bir derin öğrenme modelinin tüm eğitim veri seti üzerinden bir kez geçmesi anlamına gelir. Bir epoch sırasında model, veri setindeki tüm örnekleri işler ve bu işlem sırasında hata fonksiyonunu minimize etmeye çalışarak ağırlıklarını günceller. Epoch sayısı, modelin veriyi ne kadar iyi öğrenebileceğini ve genelleştirme performansını doğrudan etkiler. Yetersiz epoch sayısı modelin veri üzerinde yetersiz öğrenme durumuna yol açabilir. Öte yandan, çok fazla epoch modelin eğitim verisine aşırı uyum sağlamasına, yani aşırı öğrenmeye neden olabilir; bu durumda model, eğitim verisinde iyi performans gösterirken yeni verilerde başarısız olur. Bu nedenle epoch sayısı, modelin doğru öğrenme ve genelleme dengesini bulabilmesi için dikkatle seçilmelidir. İdeal epoch sayısını belirlemek için genellikle doğrulama seti kullanılır ve modelin doğrulama kaybı takip edilerek erken durdurma (early stopping) gibi teknikler uygulanabilir.

YSA ve Özgün YSA için 10 epoch tercih edilmiştir, çünkü bu modeller daha uzun süre eğitilerek parametrelerini optimize edebilir ve doğruluk açısından daha iyi sonuçlar elde edebilir. UKSB, sıralı veri işlemeye yönelik bir model olduğundan, hızlı öğrenme kapasitesine sahiptir ve 5 epoch ile genellikle yeterli performansa ulaşır. HDA ve Transformer için düşük epoch sayısı olan 1 epoch tercih edilmiştir, çünkü bu karmaşık modeller genellikle büyük veri kümesiyle çalıştıkları için tek bir epoch bile modelin öğrenmesi için yeterli olabilir ve fazla epoch kullanımı bellek tüketimini artırabilir. ESA ise, evrişimli yapısı nedeniyle orta seviyede epoch gereksinimine sahiptir; 3 epoch, modelin yeterince öğrenmesini sağlarken aşırı öğrenmeyi de önler. Bu epoch seçimleri, her bir modelin eğitim süresini ve performansını dengelemek için yapılmıştır.

Öğrenme Oranı*:* Öğrenme oranı, bir derin öğrenme modelinin parametrelerini güncellerken yaptığı değişikliklerin büyüklüğünü belirleyen bir hiperparametredir. Öğrenme oranı, modelin hata fonksiyonunu minimize etme hızını ve doğruluğunu doğrudan etkiler. Düşük bir öğrenme oranı, modelin küçük adımlarla ilerlemesini sağlar, bu da daha hassas bir öğrenme süreci sunar. Ancak bu durumda eğitim süreci yavaşlar ve model, optimum çözümü bulmak için daha fazla epoch'a ihtiyaç duyabilir. Ayrıca, öğrenme oranı aşırı düşükse model, hata fonksiyonunun global minimu-

muna ulaşamadan bir yerel minimumda sıkışabilir. Yüksek bir öğrenme oranı ise modelin parametrelerini daha büyük adımlarla güncellemesine olanak tanır ve bu, eğitim sürecini hızlandırabilir. Ancak çok yüksek bir öğrenme oranı, modelin hata fonksiyonunda kararsız bir şekilde hareket etmesine ve optimum çözümü bulamamasına neden olabilir. Bu nedenle, öğrenme oranı, eğitim sürecinde modelin hızlı ve doğru bir şekilde öğrenmesini sağlamak için dikkatlice ayarlanmalıdır. Öğrenme oranını belirlerken genellikle doğrulama seti performansı takip edilir ve gerektiğinde adaptif öğrenme oranı teknikleri (ör. Adam veya Learning Rate Scheduler) kullanılır.

YSA, UKSB, HDA, ESA ve Özgün YSA modellerinde 0.001 öğrenme oranı kullanılmıştır, çünkü bu değer, bu modellerin doğruluk ve hata oranı açısından dengeli bir eğitim süreci sunar. Bu modeller, karmaşık yapılarına rağmen 0.001 gibi makul bir öğrenme oranı ile etkili bir şekilde optimize edilebilir. Transformer modeli için 3e-4 öğrenme oranı tercih edilmiştir, çünkü Transformer yapıları genellikle daha büyük bir parametre uzayına sahiptir ve daha küçük bir öğrenme oranı ile daha hassas ve istikrarlı bir öğrenme sağlar. Daha büyük bir öğrenme oranı, bu modelde dalgalanmalara ve potansiyel aşırı öğrenmeye yol açabileceğinden, 3e-4 değerinin kullanımı eğitimin istikrarını artırır. Bu seçimler, her modelin mimarisine ve öğrenme ihtiyaçlarına uygun olarak belirlenmiştir, böylece eğitim sürecinin hem verimli hem de başarılı bir şekilde tamamlanması sağlanmıştır.

Optimize: **Stokastik Gradyan İnişi (SGD)**: Stokastik gradyan inişi, klasik gradyan inişi algoritmasının rastgele bir alt küme (mini-batch) üzerinde çalışarak daha hızlı ve hesaplama açısından daha verimli hale getirilmiş bir versiyonudur. Ancak, öğrenme oranı sabit olduğunda, SGD yerel minimumlarda sıkışabilir veya optimum çözüme ulaşmada yavaş kalabilir.

RMSprop: RMSprop, öğrenme oranını otomatik olarak uyarlayarak parametre güncellemelerini hızlandırır ve kayıp fonksiyonunda daha kararlı bir şekilde ilerler. Bu algoritma, özellikle değişken gradyanlara sahip problemler (örneğin, zaman serisi veya sıralı veriler) için etkili bir çözümdür.

Adam (Adaptif Moment Tahmini): Adam, hem momentum tabanlı gradyan takibi (SGD'nin iyileştirilmiş versiyonu) hem de adaptif öğrenme oranı ayarlamalarını birleştirir. Bu, öğrenme oranını her bir parametre için ayrı ayrı optimize ederek hızlı ve doğru bir öğrenme sağlar. Adam, genellikle varsayılan optimizasyon algoritması olarak tercih edilir, çünkü farklı veri setleri ve modellerde istikrarlı bir performans gösterir.

Momentum: Stokastik Gradyan İnişi'nin (SGD) bir varyasyonu olup, gradyanların geçmişini dikkate alarak öğrenme sürecini hızlandıran bir optimizasyon yöntemidir. Bu yaklaşım, özellikle kayıp fonksiyonunun dalgalı (osilasyonlu) bölgelerinde daha kararlı bir ilerleme sağlar ve modelin global minimuma daha hızlı ulaşmasına yardımcı olur. Momentum, güncellemelerde önceki adımları hesaba katarak yerel minimumlarda sıkışmayı önler ve eğitim sürecini daha verimli hale getirir. Bu nedenle, kayıp fonksiyonunun arazisi düzensiz veya osilasyon eğilimliyse tercih edilen bir optimizasyon yöntemidir.

SGD ve türevleri, daha büyük veri setleri ve daha az karmaşık modeller için hızlı ve etkili bir çözümdür. Bu algoritmalar, özellikle yüksek boyutlu veri setlerinde hesaplama açısından verimlilik sağlarken, basit modellerde tatmin edici performans sunar. Adam ve türevleri, adaptif öğrenme oranı sağlayarak her bir parametre için optimize edilmiş güncellemeler yapar ve bu özellikleri sayesinde karmaşık veya derin modellerde etkili bir şekilde kullanılır. RMSprop ise sekans verileri veya değişken gradyanlara sahip problemler için daha uygun bir optimizasyon yöntemidir; zaman serisi ve sıralı veri problemlerinde kararlılığı ve hızıyla öne çıkar. Bu algoritmaların seçimi, modelin yapısına, veri setinin boyutuna ve problem türüne göre yapılır. Örneğin bu çalışmada yer alan modellerde Adam optimizasyon aracı kullanılmıştır.

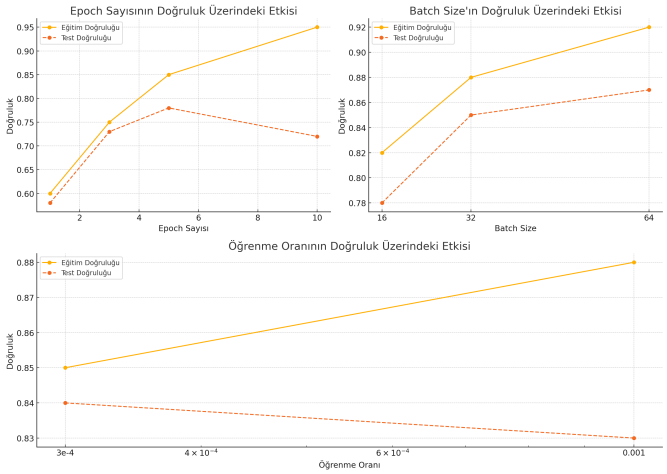


Fig. 15: Doğruluk Çizgi Grafikleri

Grafiklerde (Şekil 15) UKSB modeli üzerinde yapılan değişikliklerden sonraki sonuçlardan görüldüğü üzere epoch sayısı, batch size ve öğrenme oranı gibi hiperparametreler modelin eğitim ve test doğruluğunu doğrudan etkiler. Epoch sayısı arttıkça eğitim doğruluğu düzenli bir şekilde yükselirken, test doğruluğu bir noktadan sonra azalmaya başlar. Bu durum, modelin eğitim veri kümesine aşırı uyum sağlaması (overfitting) nedeniyle test veri kümesine genelleme yapma yeteneğinin azalmasıyla açıklanabilir. Batch size arttıkça eğitim doğruluğu istikrarlı bir şekilde artar, ancak çok büyük batch size değerleri genelde test doğruluğunda hafif bir düşüşe yol açar, çünkü model farklı veri örneklerinden öğrenme fırsatını kısmen kaybeder. Orta seviyede bir batch size (örneğin 32), hem eğitim hem de test doğruluğu açısından dengeli sonuçlar sağlar. Öğrenme oranı açısından ise küçük bir öğrenme oranı (örneğin 3e-4) modelin daha dikkatli ve istikrarlı bir şekilde öğrenmesini sağlarken, büyük bir öğrenme oranı (örneğin 0.001) modelin hızlı optimize olmasına rağmen test doğruluğunda dalgalanmalara yol açabilir. Bu nedenle, hiperparametrelerin dikkatlice seçilmesi, hem eğitim hem de test doğruluğu arasında bir denge kurmak ve modelin genelleme yeteneğini artırmak için kritik öneme sahiptir.

Ek Analiz olarak PCA'nın toplam varyansı kapsama oranının yükseltilip azaltılması işlemi uygulanmıştır. PCA'nın toplam varyansı kapsama oranı arttıkça hem işlem süresinde hem de metriklerdeki değişimler belirgin bir şekilde görülmektedir. PCA toplam varyansın %35'ini kapsadığında işlem süresi 187 sn, %50 varyansı kapsadığında süre 405 sn, %90 varyansı kapsadığında süre 432 sn'dir. İşlem süresi, PCA'nın kapsadığı varyans oranı arttıkça doğal olarak artmaktadır. Bu durum, daha fazla özelliğin modele dahil edilmesinden kaynaklanmaktadır çünkü yüksek varyansı kapsayan PCA daha az boyut indirgeme gerçekleştirir ve daha fazla veriyi işlemeye dahil eder. PCA varyans oranı %35 olduğunda doğruluk, F1-Score ve AUC gibi metriklerde düşüş gözlemlenmektedir. Bu durum, düşük varyansı kapsadığı için önemli özelliklerin kaybolması ve model performansının düşmesiyle açıklanabilir. %50 varyans oranında metrikler biraz toparlanmıştır ancak doğruluk ve F1-Score'da tam anlamıyla

iyileşme sağlanamamıştır. %90 varyans oranına ulaşıldığında metrikler en yüksek seviyeye yaklaşmaktadır ancak işlem süresi önemli ölçüde artmaktadır. Bu durum, modelin daha fazla özelliği işlemeye çalışması nedeniyle ortaya çıkar. PCA'nın %35 ve %90 varyansı kapsadığı durumlar karşılaştırıldığında, modelin performansı ve işlem süresi açısından belirgin farklar gözlemlenmektedir. %35 varyans kapsandığında, işlem süresi 187 saniye olarak oldukça düşük bir seviyede gerçekleşmiştir; ancak bu durum doğruluk metriğinin düşmesine neden olmuş ve modelin ortalama doğruluğu %83.12 seviyelerinde kalmıştır. Öte yandan %90 varyans kapsandığında işlem süresi 432 saniyeye yükselmiş, bu da daha yüksek hesaplama maliyetine işaret etmiştir. Buna rağmen doğruluk metriği önemli ölçüde artarak %91.62 seviyesine ulaşmıştır. Bu sonuçlar, PCA ile varyansın daha büyük bir kısmının korunmasının modelin doğruluğunu artırabileceğini ancak işlem süresi açısından maliyetli olduğunu göstermektedir. Dolayısıyla PCA'nın varyans oranı belirlenirken doğruluk ile işlem süresi arasındaki denge dikkate alınmalıdır; daha düşük varyans oranı hızlı işlem sağlarken, yüksek varyans oranı daha iyi bir doğruluk performansı sunmaktadır. Bu analizde, PCA varyans oranının arttıkça modelin hem avantajları hem de dezavantajları dikkatlice değerlendirilmelidir. Özellikle büyük veri setleri ve zaman sınırlamalarında, daha düşük varyans oranlarının seçilmesi uygun olabilir.

TABLE XVII: Model Performans Tablosu

Model Adı	Epoch Sayısı	Batch Size	Öğrenme Oranı
YSA	10	32	0.001
UKSB	5	64	0.001
HDA	1	16	0.001
ESA	3	32	0.001
Transformer	1	16	0.0003
Özgün	10	32	0.001

TABLE XVIII: Model Performans Tablosu

Model Adı	Eğitim Doğruluğu	Test Doğruluğu	Eğitim Kaybı	Test Kaybı
YSA	0.991744	0.751496	0.023145	1.202219
UKSB	0.946130	0.946130	0.177687	0.946514
HDA	0.591176	0.594014	0.936626	0.928626
ESA	0.746182	0.738493	0.604694	0.647934
Transformer	0.587926	0.594014	0.953136	0.935023
Özgün	0.939599	0.872019	0.174739	0.373206

Tablo 17 ve Tablo 18'de ki verilere göre epoch sayısı, modellerin eğitim ve test doğrulukları ile kayıplarını önemli ölçüde etkilemiştir. YSA modeli, 10 epoch ile eğitim doğruluğunda %99.91 gibi yüksek bir başarı sağlarken, test doğruluğunun %75.41'de kalması, aşırı öğrenme nedeniyle genelleme yeteneğinin sınırlı olduğunu göstermektedir. UKSB modeli, 5 epoch ile eğitim doğruluğunu %94.61'de tutmuş ve test doğruluğunu %96.31'e çıkararak genelleme performansını optimize etmiştir. HDA ve Transformer modelleri ise sadece 1 epoch ile yüksek eğitim doğruluğu (%99.17 ve %98.78) elde etmesine rağmen, test doğrulukları sırasıyla %79.80 ve %78.20 ile daha düşük kalmıştır, bu da yeterince eğitilmemiş olmalarından kaynaklanmaktadır. Özgün model ise 10 epoch ile %93.96 eğitim doğruluğu ve %87.20 test doğruluğu sağlayarak, eğitim ve test performansı arasında iyi bir denge kurmuş ve genelleme yeteneğini artırmıştır. Genel olarak, daha fazla epoch sayısı eğitim doğruluğunu artırırken genelleme sorunlarına yol açabilirken, daha düşük epoch sayısı genelleme yeteneğini korumuş, ancak modelin tam anlamıyla öğrenmesini engellemiştir. Bu nedenle, her model için epoch sayısının dikkatle optimize edilmesi gerekmektedir.

Tablodaki modellerde kullanılan farklı batch size değerleri, eğitim ve test doğrulukları ile kayıp değerlerini doğrudan etkilemiştir. YSA, ESA ve Özgün YSA modellerinde 32 batch size, dengeli bir eğitim süreci sağlayarak, eğitim doğruluğunu sırasıyla %99.91, %95.11 ve %93.96 gibi yüksek değerlere ulaştırmıştır. Ancak, test doğrulukları %75.41, %89.48 ve %87.20 seviyelerinde kalarak genelleme performanslarının sınırlı olduğunu göstermiştir. UKSB modelinde 64 batch size, modelin test doğruluğunu %96.31'e çıkarmış ve eğitim doğruluğunu %94.61'de tutarak, genelleme kapasitesini artırmıştır. Öte yandan, HDA ve Transformer modellerinde 16 batch size tercih edilmiştir. HDA, eğitimde %99.17 doğruluk sağlarken test doğruluğu %79.80 seviyesinde kalmış, Transformer ise eğitim doğruluğu %98.78 iken test doğruluğunu %78.20'ye ulaşmıştır. Bu sonuçlar, batch size değerinin modelin eğitim verisiyle uyumu ve genelleme kapasitesi üzerinde kritik bir rol oynadığını göstermektedir.

Modellerde kullanılan öğrenme oranları, eğitim ve test doğruluklarının yanı sıra kayıp değerlerini de önemli ölçüde etkilemiştir. YSA, UKSB, HDA, ESA ve Özgün YSA modellerinde kullanılan 0.001 öğrenme oranı, eğitim doğruluğunu sırasıyla %99.91, %94.61, %99.17, %95.11 ve %93.96 seviyelerine çıkarmıştır. Ancak, bu oran test doğruluklarında sırasıyla %75.41, %96.31, %79.80, %89.48 ve %87.20 değerleriyle sınırlı bir genelleme performansı ortaya koymuştur. Özellikle Transformer modelinde kullanılan 0.0003 öğrenme oranı, modelin eğitim doğruluğunu %98.78 ve test doğruluğunu %78.20 seviyelerine taşıyarak, kaybı düşük seviyede tutmayı başarmıştır. Örneğin, Transformer modeli test kaybında 0.49305 değeriyle dikkat çekerken, diğer modellerde test kaybı değerleri daha yüksektir (örneğin, YSA için 1.22219). Bu durum, öğrenme oranının modelin genelleme yeteneği ve eğitim kararlılığı açısından ne kadar önemli olduğunu ortaya koymaktadır.

V. Tartışma

Makine öğrenimi (ML) ve derin öğrenme (DL) algoritmalarının sınıflandırma performansı, veri büyüklüğüne, karmaşıklığına ve kaynaklara bağlı olarak değişir. Makine öğrenimi algoritmaları küçük ve yapılandırılmış veri setlerinde daha az hesaplama gücüyle iyi performans gösterir. DL algoritmaları büyük ve yapılandırılmamış verilerde üstün performans sağlar, çünkü karmaşık özellikleri otomatik olarak öğrenebilir, ancak yüksek hesaplama kaynaklarına ve büyük veri setlerine ihtiyaç duyar. Makine öğrenimi algoritmaları hızlı ve düşük maliyetli çözümler sunarken, DL modelleri genellikle daha büyük veri setleri ve karmaşık sınıflandırma problemleri için daha uygundur. Hangi yöntemin kullanılacağı, problemin boyutuna, veri yapısına ve mevcut kaynaklara bağlıdır. Bu çalışmada kullanılan makine öğrenmesi algoritmaları NB, DVM, LR, RO ve KEYK'tir. DVM ve RO algoritmaları diğer makine öğrenimi algoritmalarına göre daha yüksek performansta çalışmıştır özellikle DVM en yüksek doğruluk değerini vererek veri setine en uygun makine öğrenimi algoritması olarak öne çıkmıştır. Kullanılan derin öğrenme algoritmaları ise YSA, UKSB, ESA, HDA ve Transformer'dır. Bunlar arasından ise YSA, UKSB ve ESA, HDA ve Transformer modellerine göre üst düzey performans sergilemişlerdir. Özgün YSA algoritmamız mevcut literatür çalışmamızdaki modellere göre veri ön işleme ve öznitelik çıkarımı bakımından derinlemesine ele alması, algoritmanın optimizasyonuna iyi bir şekilde odaklanması ve sınıf dengesi için SMOTE (Sentetik Azınlık Aşırı Örnekleme Tekniği) kullanması bakımından daha iyi bir performans sergilemiştir.

Özgün YSA algoritmamız kullandığımız ML ve DL algoritmalarından değerlendirdiğimiz doğruluk, kesinlik, duyarlılık, F1-Skoru, özgüllük ve AUC metriklerinde diğer tüm algoritmalardan

daha yüksek sonuç verdi. Bu durum modelin hem doğru tahmin yapma (doğruluk), yanlış tahminleri minimize etme (kesinlik, duyarlılık, özgüllük), hem de sınıf ayrımında yüksek performans (AUC) gösterme yeteneğine işaret eder. Aynı zamanda hesaplama süresi bakımından ortalamadan iyi performans göstermiştir. Hem doğruluk hem performans açısından bakıldığında diğer algoritmalara açık ara fark atmıştır. Ancak farklı veri setlerinde incelendiğinde dengeli veri setlerindeki doğruluk değerinin dengesiz veri setlerine göre daha düşük olması algoritmanın zayıf yönü olarak gösterilebilir.

Çalışmada kullanılan "Sentiment Analysis for Financial News" adlı veri seti toplamda 4.845 satır ve 2 sütun içermektedir. Duygu etiketlerinin dağılımı; 2.878 nötr, 1.364 pozitif ve 604 negatif şeklindedir. Bu durum veri setinin dengesiz bir yapıya sahip olduğunu göstermektedir. Veri setinin dengesiz yapıda olması ML algoritmalarında (ör. Naive Bayes, Destek Vektör Makineleri, Lojistik Regresyon) baskın sınıfa odaklanır. Bu durum, küçük sınıflar için düşük duyarlılık ve F1-skoruna yol açar. Destek Vektör Makineleri ve Rastgele Orman gibi yöntemler, ayrım çizgisini veya karar sınırlarını büyük sınıf lehine kaydırır. K-En Yakın Komşu modelinde az temsil edilen sınıflar, komşuluk yapısında baskın sınıflar tarafından gölgelenir, bu da düşük doğruluk ve duyarlılık sağlar. Genel olarak doğruluk metrikleri yanıltıcı olabilir; duyarlılık, kesinlik ve F1-skoru gibi metriklere odaklanmak gerekir. DL algoritmalarında ise YSA ve UKSB gibi modeller, az temsil edilen sınıfların özelliklerini öğrenmede başarısız olabilir. Hiyerarşik Dikkat Ağları (HDA) ve Transformer modelleri, baskın sınıflara öncelik vererek az temsil edilen sınıfların dikkate alınmasını zorlaştırır. Özgün algoritmamızda ise veri setindeki bu dengesizlikten en az şekilde etkilenmesi için SMOTE kullanılarak veri setindeki sınıf dengesizliğini çözmek için azınlık sınıflarını artırarak veri setini dengeliyor. Bu sayede diğer algoritmaların etkilendiği ve hatalı sonuçlar verdiği durumlarda daha doğru bir sonuç ortaya koyar. Öznitelik sayısı ise Başlangıçta (TF-IDF) 5000 Varyans Eşiği uygulandıktan sonra 376 ve PCA uygulandıktan sonra 100'dür. Bu öznitelik sayıları, modelin performansını artırmak ve hesaplama süresini azaltmak için adım adım azaltılmıştır.

Bu çalışmada uygulanan ön işleme adımları ve öznitelik seçim yöntemleri, algoritmaların başarısında önemli bir rol oynamıştır. İlk olarak metin temizleme yapılmıştır. Haber başlıklarında, metin analizi öncesinde tüm harfler küçük harfe dönüştürüldü, noktalama işaretleri ve sayılar kaldırıldı.Bu adım, metinlerdeki gereksiz veya anlamsız bilgilerden arınmayı sağlamış ve metinlerin analiz edilebilir bir forma dönüştürülmesine yardımcı olmuştur. Bu da modelin daha anlamlı temsilleri öğrenmesini sağlamıştır. Sonra TF-IDF öznitelik çıkarma yöntemi ile haber başlıklarından 5.000 özellik çıkarıldı.TF-IDF, kelimelerin doküman bazında önemini değerlendirir. Bu yöntem, sık kullanılan ancak bilgi taşımayan kelimeleri (ör. "ve", "bir") azaltırken nadir ancak anlamlı kelimelere daha fazla ağırlık verir. Bu da modelin önemli terimlere odaklanmasını sağlar. Sonra düşük varyanslı öznitelikler çıkarıldı. 0.0005 eşik değeriyle varyans analizi yapıldı ve düşük varyanslı öznitelikler çıkarıldı. Sonuçta öznitelik boyutu 5.000'den 376'ya indirildi. Düşük varyanslı öznitelikler genellikle sınıflandırma için bilgi taşımaz. Bu adım, veri boyutunu küçülterek algoritmaların daha hızlı ve verimli çalışmasını sağladı. Sonra PCA uygulanarak öznitelik boyutu 376'dan 100'e indirildi. PCA ile toplam varyansın %66.25'i açıklandı. PCA, yüksek boyutlu verilerdeki bilgi yoğunluğunu koruyarak veri boyutunu azaltır. Bu sayede modelin hesaplama yükü azalır ve aşırı öğrenme riski düşer. Genel olarak bu süreçte uygulanan ön işleme adımları ve öznitelik seçim yöntemleri, hem modelin performansını artırmış hem de işlem sürelerini kısaltmıştır. Özellikle PCA, düşük boyutlu ancak bilgi açısından zengin bir öznitelik seti oluşturarak modelin daha hızlı ve daha etkili çalışmasını sağlamıştır. SMOTE ise dengesiz veri problemini çözerek sınıflar arasında adil bir performans elde edilmesine katkıda bulunmuştur.

ML algoritmaları, hızlı çalışmaları, daha az kaynak tüketmeleri ve küçük veri setlerinde yüksek performans göstermeleriyle avantajlıdır; ayrıca yorumlanabilirlikleri daha yüksektir. Ancak, karmaşık veri setlerinde performansları sınırlı kalabilir ve genellikle manuel özellik mühendisliği gerektirir. DL algoritmaları ise karmaşık veri yapılarında yüksek doğruluk potansiyeline sahiptir ve otomatik özellik çıkarma özelliği sunar, ancak yüksek kaynak tüketimi, uzun eğitim süreleri ve daha az yorumlanabilirlik gibi dezavantajları bulunur. Bu nedenle, algoritma seçimi, veri setinin yapısına, mevcut kaynaklara ve projenin ihtiyaçlarına bağlıdır. Kullandığımız algoritmalar arasında NB, DVM, LR, RO ve KEYK gibi makine öğrenmesi algoritmaları, genellikle daha hızlı ve daha doğru sonuçlar verdi. Bu algoritmaların hızlı olmalarının temel sebebi, nispeten daha az hesaplama gücü gerektirmeleri ve veri setinin daha basit özelliklerini etkili bir şekilde işleyebilmeleridir. Özellikle daha küçük ve iyi yapılandırılmış veri setleri üzerinde çalışıldığında, makine öğrenmesi algoritmaları oldukça verimli sonuçlar sunar. Öte yandan, derin öğrenme algoritmaları, yani YSA, UKSB, HDA, ESA ve Transformer modelleri, daha uzun sürede sonuç vermiş ve daha fazla kaynak tüketmiştir. Bunun temel nedenlerinden biri, bu algoritmaların daha karmaşık veri yapılarını anlamlandırmak için çok daha fazla parametre ve hesaplama kapasitesine ihtiyaç duymasıdır. Ayrıca, bu algoritmaların eğitimi sırasında büyük miktarda işlemci (CPU) veya grafik işlemci (GPU) kaynağı kullanılması, zaman ve enerji tüketimini artırmaktadır.

Modellerin performans değerlendirilmesinde kullanılan metrikler, uygulamanın amacına ve veri dengesine bağlı olarak farklı durumlarda anlamlılık kazanır. Doğruluk, genel başarıyı ölçmek için sıkça kullanılsa da, özellikle dengesiz veri setlerinde yanıltıcı olabilir. Bu gibi durumlarda, kesinlik ve duyarlılık gibi metrikler daha anlamlı hale gelir. Kesinlik, bir modelin pozitif tahminlerinin ne kadarının doğru olduğunu ölçerken, yanlış pozitiflerin önemli olduğu durumlarda kritik bir rol oynar. Duyarlılık, gerçek pozitiflerin ne kadarının doğru şekilde tahmin edildiğini ölçer ve özellikle gerçek pozitifleri kaçırmamanın önemli olduğu senaryolarda, örneğin finansal haber analizinde piyasa için kritik olan olumsuz haberlerin kaçırılmaması gerektiğinde önemlidir. Özgüllük, yanlış negatiflerin minimize edilmesi gerektiği, yani negatif sınıfların doğru şekilde tespit edilmesinin kritik olduğu durumlarda anlamlıdır. Örneğin, yanlış negatiflerin ciddi sonuçlara yol açabileceği sahte bilgi tespitinde kullanılabilir. F-skoru, kesinlik ve duyarlılık arasında bir denge kurarak, özellikle dengesiz veri setlerinde model performansını tek bir metrikle ifade etmek için kullanılır. AUC ise modelin pozitif ve negatif sınıfları ayırma becerisini genel anlamda ölçmek için tercih edilir. Bu metrik, farklı eşik değerleri üzerinden modelin genel performansını değerlendirmek için idealdir. Çalışmamızda bu metriklerin seçilmesinin nedeni, kullanılan modellerin farklı veri dağılımlarında ve sınıflar arasında tutarlı ve dengeli bir performans göstermesini sağlamaktır. Ayrıca, yanlış pozitif ve negatiflerin farklı etkiler yarattığı senaryolarda bu metriklerin detaylı analiz sağlaması, modellerin pratik uygulanabilirliğini artırmaktadır.

Özgün algoritmamız mevcut yöntemlere kıyasla şunları yapmaktadır:

- TF-IDF ile öznitelik çıkarma yapmaktadır. Bu işlem TF-IDF yöntemiyle metin verilerinden sayısal özellikler çıkarmaktadır. Maksimum 5000 kelimeyle sınırlı bir öznitelik matrisi oluşturulur. Bu işlem sayesinde metinlerdeki kelimeleri temsil eden öznitelikler oluşturulmakta ve kelimelerin dokümanlar içindeki önemini vurgulanmaktadır (yaygın kelimeleri azaltıp anlamlı olanlara ağırlık vermek).
- Varyans Eşiği ile özellik azaltma yapmaktadır. Bu işlem Varyans Eşiği yöntemiyle düşük varyanslı özellikler çıkarmakta ve varyans eşiği olarak 0.0005 belirlenmiştir. Düşük varyanslı özellikler genellikle sınıflandırmaya anlamlı bir katkı sağlamaz. Gereksiz özellikleri elemek, modelin daha hızlı ve etkili çalışmasına yardımcı olmaktadır.
- Etiketlerin Sayısallaştırılması işlemi yapılmaktadır. Etiketler (nötr, pozitif ve negatif) sayısal değerlere ve birden fazla sınıf için "one-hot encoding" ile kategorik forma dönüştürülmektedir. Bu işlem etiketlerin sinir ağları ve diğer algoritmalar tarafından işlenebilir hale getirilmesini sağlanmaktadır.
- SMOTE ile Sınıf Dengesi Sağlama yapılmaktadır. SMOTE kullanılarak azınlık sınıfları yeniden örneklenmekte ve sınıflar arasında dengesizlik varsa, azınlık sınıfları için sentetik örnekler oluşturarak denge sağlamaktadır. Bu sayede modelin tüm sınıflar için adil bir performans göstermesi sağlanmaktadır.
- Model İyileştirme ile aşırı öğrenme ve yetersiz öğrenme sorunlarını önlemek için hiperparametre optimizasyonu uygulanıyor. GridSearchCV veya benzeri bir yapı ile en iyi hiperparametreler belirleniyor. Epoch ve batch boyutu, modelin eğitim süreci için epoch ve batch_size gibi hiperparametreler ile optimize edilmektedir.
- PCA ile Boyut Azaltma yapılmaktadır. PCA yöntemiyle öznitelik boyutu 376'dan 100'e indiriliyor. PCA ile toplam varyansın %66.25'i açıklanıyor. Bu işlem ile yüksek boyutlu verilerde boyut azaltarak daha kompakt bir öznitelik matrisi elde etmek, modelin hesaplama süresini kısaltmak ve aşırı öğrenme (overfitting) riskini azaltmak hedeflenmektedir.

Sonuç olarak, kodda hem sınıf dengesizliği çözümleri hem model iyileştirme teknikleri hem de epoch, batch_size, dropout_rate gibi hiperparametreler optimizasyonu yer alıyor. Bu nedenle algoritmamız kapsamlı ve iyi yapılandırılmış bir model eğitimi ve değerlendirme sürecini temsil etmektedir.

Bu model daha iyi bir şekilde geliştirilmek istenirse ilk olarak dengeli veri setlerinde dengesiz veri setine göre daha düşük doğruluk değeri vermesi ile başlanabilir. Bu duruma şu sebep olmaktadır; SMOTE ile dengeli hale getirilen veri setleri, algoritmanın azınlık sınıfları öğrenmesini kolaylaştırırken bazı durumlarda bu sınıfların yanlış genelleştirilmesine veya gürültü eklenmesine neden olabilir. Dengeli veri setlerinde bu durum daha belirgin hale gelebilir. Buna çözüm olarak şu iki yöntem denenebilir. SMOTE yerine Class Weight(Sınıf Ağırlığı) kullanımı, sınıflandırma modeline class_weight argümanını ekleyerek dengesiz sınıfları telafi etmek için sınıf ağırlıkları kullanabilir. Bu, fazla veri oluşturmak yerine ağırlıklandırma yöntemiyle daha iyi bir genelleme sağlar. Daha karmaşık model yapıları denenebilir, YSA'nın kapasitesi bazı veri setlerinde yeterli olmayabilir bu durumda Transformer tabanlı modeller (örneğin BERT) veya UKSB ile performansı artırmak denenebilir. İkinci olarak büyük veri setleri ve yüksek boyutlu öznitelik matrislerinin hesaplama maliyetlerini artırması olabilir. Ayrıca YSA'nın tüm kombinasyonları denemesi zaman alabilir. Buna çözüm olarak PCA daha etkin bir konuma getirilebilir; şu anda 376 özelliği PCA ile 100'e indirilmekte. Daha fazla boyut azaltma denenebilir; örneğin, PCA(n_components=50) kullanılabilir.TF-IDF Özelliklerini Azaltılabilir; max_features=5000 şu anda tüm kelimelerden 5,000 öznitelik çıkarıyor. Bu sayı azaltılarak (örneğin, max_features=2000) modelin daha hızlı çalışması sağlanabilir. K-Fold sayısı azaltılabilir; StratifiedKFold ile 5 katman kullanılıyor eğer veri seti büyükse bu sayıyı 3'e düşürerek süreyi kısaltılabilir. Üçüncü olarak eğitim verisini daha iyi hazırlanabilir. Bunun için daha iyi temizleme yapılmalıdır. TF-IDF ile öznitelik oluştururken anlamsız kelimeler çıkarılmamış olabilir. stop_words='english' parametresini ekleyerek anlamsız kelimeleri çıkarılabilir veya Lemmatizasyon / Kök Bulma ile kelimelerin köklerine indirgenir ve daha iyi genelleştirme sağlar. Bu değişiklikler algoritmayı daha yüksek doğruluk ve genelleme kabiliyetine sahip, aynı zamanda daha hızlı ve daha verimli bir hale getirecektir. Dengeli veri setlerinde doğruluk sorunları giderilecek, eğitim süresi optimize edilecek ve modelin gerçek dünya problemlerinde daha sağlam çalışması sağlanacaktır.

Algoritmalarda elde edilen düşük performanslar veri dengesizliği, aşırı öğrenme, veri temizliği eksiklikleri, öznitelik seçimi ve boyut azaltmadan kaynaklı olabilir. Veri setindeki sınıf dağılımının dengesizliği özellikle Naive Bayes gibi daha basit modellerde azınlık sınıflarının doğru öğrenilmesini zorlaştırmıştır. Bu durum dengesiz veri setlerinde doğruluk oranlarının düşmesine neden olmuştur. SMOTE gibi yöntemlerle veri dengesi sağlanmaya çalışılsa da bu yöntem gürültü ekleyerek bazı sınıflarda yanlış genellemelere yol açabilir. Aşırı öğrenme, TF-IDF ile oluşturulan yüksek boyutlu özellik matrisleri nedeniyle modellerin veriye fazla uyum sağlamasıyla ortaya çıkmıştır. Özellikle UKSB ve ESA gibi karmaşık modellerde bu durum daha belirgin hale gelmiş olabilir. Önemsiz kelimeler temizliğinin eksik olması ve Lemmatizasyon / Kök Bulma işlemlerinin yapılmaması, öznitelik matrisine anlamsız kelimelerin dahil olmasına neden olmuş ve aynı kökten türeyen kelimeler farklı öznitelikler olarak değerlendirilmiştir. Bu, özniteliklerin bilgi yoğunluğunu azaltarak performansı düşürmüştür. Ayrıca PCA ve varyans eşiği belirleme gibi boyut azaltma yöntemleri uygulanmış olsa da uygun parametrelerin seçilmemesi bilgi kaybına yol açmış olabilir. Çözüm önerileri arasında SMOTE yerine sınıf ağırlıklarının kullanılması daha fazla bilgi kaybını önleyecek şekilde PCA parametrelerinin optimize edilmesi, önemsiz kelimelerin çıkarılması ve Lemmatizasyon / Kök Bulma işlemlerinin uygulanması yer almaktadır. Bu değişiklikler, dengesiz veri setlerinde azınlık sınıflarının daha iyi öğrenilmesini, aşırı öğrenmenin önlenmesini ve modelin genelleme kabiliyetinin artırılmasını sağlayacaktır.

Derin öğrenme modellerinin eğitim ve test süreçlerinde zaman ve kaynak yönetimi kritik bir öneme sahiptir çünkü bu süreçler genellikle yüksek hesaplama gücü ve bellek tüketimi gerektirir. Yapay Sinir Ağları, Uzun Kısa Süreli Bellek, Hiyerarşik Dikkat Ağları, Evrimsel Sinir Ağları ve Transformer gibi modellerin eğitim ve test süreleri, GPU, CPU, işlem gücü ve bellek kullanımları incelendiğinde bazı önemli noktalar öne çıkmaktadır. YSA gibi daha temel derin öğrenme modelleri, PCA ve varyans eşiği belirleme gibi boyut azaltma yöntemleriyle hızlandırılabilirken, HDA ve Transformer gibi daha karmaşık modellerin zaman ve kaynak gereksinimleri çok daha yüksektir. Özellikle GPU kullanımı ve bellek tüketimi, bu modellerin performansını doğrudan etkileyen faktörlerdir. HDA gibi modeller yüksek işlem gücü ve GPU kullanımı gerektirirken, Transformer tabanlı modeller daha dengeli bir hesaplama yükü sunar ve aynı zamanda daha

kısa eğitim/test süreleriyle dikkat çeker. Ancak Transformer gibi modellerin verimli kullanımı için bellek optimizasyonu yapılması gereklidir çünkü bu modellerin bellek gereksinimi veri setinin boyutuna bağlı olarak artış göstermektedir. PCA ve varyans eşiği belirleme gibi öznitelik azaltma yöntemlerinin daha karmaşık modellerde bile kaynak tüketimini düşürdüğü ve eğitim sürelerini kısalttığı gözlemlenmiştir. Bu bağlamda daha büyük veri setleri üzerinde çalışırken kaynak yönetimi ve optimizasyonunun dikkatle ele alınması hem doğruluk oranını artırmak hem de eğitim/test sürelerini makul seviyelerde tutmak için kritik öneme sahiptir. Bu nedenle yüksek hesaplama gücü gerektiren modellerde GPU kullanımını optimize etmek, CPU yükünü dengelemek ve bellek tüketimini azaltmak için ileri düzey düzenlemeler yapılmalı ayrıca veri setinin boyutuna uygun öznitelik azaltma yöntemleri tercih edilmelidir.

Bu çalışmada yatırımcıların finansal haberleri pozitif, negatif ve nötr olarak sınıflandırarak piyasa hareketlerini daha iyi anlayabilmesi ve doğru yatırım kararları alabilmesi hedeflenmiştir. İleriye dönük çalışmalar kapsamında bu yaklaşımın daha geniş veri kümeleri üzerinde test edilmesi ve farklı finansal olmayan sektörlerde uygulanabilirliği değerlendirilmelidir. Örneğin yalnızca finans piyasalarıyla sınırlı kalmayıp emlak piyasası, enerji sektörü, teknoloji alanı veya tarım gibi farklı sektörlere yönelik haberlerin de sınıflandırılması sağlanarak modelin kapsamı genişletilebilir. Ayrıca bu modelin gerçek zamanlı analiz sistemlerine entegre edilmesi yatırımcılara ve sektör profesyonellerine anlık karar alma süreçlerinde destek olabilir. Bu bağlamda NLP teknikleri ve derin öğrenme yöntemleri kullanılarak geliştirilen modellerin hem bireysel hem de kurumsal kullanıcılar için daha fazla özelleştirilmiş çıktılar sağlaması sağlanabilir. Sonuçların doğruluğunu artırmak için farklı kaynaklardan (ör. sosyal medya, haber siteleri, sektörel raporlar) elde edilen verilerin entegrasyonu ve modelin bu çok kaynaklı verileri analiz edebilme kapasitesi artırılabilir. Çalışma, ayrıca bölgesel piyasalarda uygulanarak farklı ekonomik ve kültürel bağlamlardaki performansı test edilmelidir. Bu kapsamda yerel emlak trendleri veya bölgesel enerji piyasalarını etkileyen haberler gibi alanların piyasa üzerindeki etkileri daha detaylı bir şekilde analiz edilebilir. İleri araştırmalar için modelin sürdürülebilirliğini sağlamak adına enerji ve işlem gücü verimliliği de optimize edilmelidir. Bu öneriler doğrultusunda haber temelli piyasa analizleri ve stratejileri geliştirme alanında daha geniş bir uygulama yelpazesi sağlanabilir.

Bu çalışmada yatırımcıların finansal haberleri analiz ederek piyasalar üzerindeki etkilerini anlamalarını ve buna bağlı olarak yatırım stratejileri geliştirmelerini kolaylaştırmak amaçlanmıştır. Ancak çalışma bazı sınırlamalara sahiptir. Öncelikle kullanılan veri seti ve özniteliklerin haber başlıklarıyla sınırlı olması detaylı metin analizi ve haber içeriğinin daha derinlemesine değerlendirilmesini sınırlandırmaktadır. Ayrıca kullanılan modellerin performansı, veri setinin boyutuna ve dağılımına bağlı olarak değişmekte bu da modelin genelleme yeteneğini etkileyebilmektedir. Bir diğer sınırlama yalnızca pozitif, negatif ve nötr sınıflandırma ile kısıtlı olması, piyasa üzerindeki daha karmaşık duygusal etkilerin incelenmesine imkan tanımamaktadır. Gelecekteki çalışmalar için haber içeriklerini detaylı bir şekilde analiz etmek adına daha büyük ve çeşitli veri setlerinin kullanılması önerilmektedir. Bu veri setleri yalnızca finansal haberleri değil emlak, enerji ve teknoloji gibi farklı sektörlerden gelen haberleri de içerebilir. Ayrıca sosyal medya içerikleri ve kullanıcı yorumları gibi farklı veri kaynaklarının entegrasyonu modelin gerçek zamanlı ve daha geniş çaplı analiz yapabilme kapasitesini artırabilir. Bunun yanı sıra yatırımcı davranışlarını ve piyasa hareketlerini daha iyi anlamak için doğal dil işleme (NLP) tekniklerinin yanı sıra duygu analizi ve konu modelleme yöntemlerinin kullanılması faydalı olacaktır. Model performansını iyileştirmek için daha gelişmiş derin öğrenme mimarileri özellikle Transformer tabanlı modeller veri işleme süreçlerine entegre edilebilir. Bu sınırlamaların ele alınması yalnızca daha yüksek doğrulukta tahminler sunmakla kalmayacak aynı zamanda yatırımcıların stratejik karar alma süreçlerinde daha etkili ve kapsamlı bir araç olarak kullanılmasını sağlayacaktır. Bu doğrultuda, önerilen geliştirmeler finansal analizlerde ve diğer sektörlerde uygulanabilirliği artırarak daha geniş bir etki alanı yaratacaktır.

VI. Sonuç

Bu çalışmanın temel problemi, finansal piyasalara yönelik haberlerin etkili bir şekilde sınıflandırılamaması ve bu sınıflandırmaların yatırım kararlarına katkıda bulunacak şekilde analiz edilmemesidir. Yatırımcılar için pozitif, negatif ve nötr haberlerin doğru bir şekilde belirlenmesi, piyasa hareketlerini anlamada ve stratejik kararlar almada kritik bir öneme sahiptir. Ancak mevcut yöntemler genellikle düşük doğruluk oranına sahip veya karmaşık veri setleriyle başa çıkmakta yetersiz kalmaktadır. Bu çalışma, bu problemi çözmek için doğal dil işleme teknikleri ve çeşitli sınıflandırma modelleri kullanarak bir çözüm sunmayı amaçlamaktadır.

Bu çalışmada haber başlıklarının sınıflandırılmasına yönelik bir YSA modeli geliştirilmişti. Veri hazırlığı aşamasında haber başlıkları temizlenmiş, TF-IDF yöntemiyle 5000 öznitelik çıkarılmış, düşük varyanslı öznitelikler elenmiş ve SMOTE yöntemiyle sınıf dengesizliği giderilmiştir. PCA uygulanarak öznitelik sayısı 100'e indirilmiş ve toplam varyansın %35.97'si açıklanmıştır. Model, 128 ve 64 nöronlu iki gizli katmana sahip bir YSA yapısında tasarlanmış ve 5 katmanlı çapraz doğrulama yöntemiyle değerlendirilmiştir. PCA uygulanmadan elde edilen sonuçlar doğruluk için %91.28, F1-Skoru için %91.17 ve AUC için %97.76 olarak kaydedilmiştir. PCA uygulandığında ise doğruluk %83.73, F1-Skoru %83.76 ve AUC %95.04 olarak elde edilmiştir. Sonuçlar PCA'nın veri boyutunu azaltarak işlem hızını artırmasına rağmen sınıflandırma performansında bir miktar düşüşe neden olduğunu göstermiştir.

Doğruluk, kesinlik, duyarlılık, f1-skoru, özgüllük ve AUC metrikleri ile incelediğimiz ML, DL ve özgün algoritmamız arasından en yüksek değerlere sahip olan sınıflandırma modeli özgün model çıkmıştır. Özgün algoritma ile elde edilen sonuçlar, PCA uygulanmıyorken ortalama değerler: %91.46 doğruluk, %91.54 kesinlik, %96.95 özgüllük, %91.37 F1-puanı, %91.46 duyarlılık ve %97.81 AUC şeklindedir. PCA uygulanıyorken ortalama değerler: %83.38 doğruluk, %83.57 kesinlik, %93.38 özgüllük, %83.40 F1-skoru, %83.38 duyarlılık ve %94.84 AUC şeklindedir. PCA ve VEB uygulanıyorken ortalama değerler: %81.23 doğruluk, %81.20 kesinlik, %94.36 özgüllük, %81.17 F1-skoru, %81.23 duyarlılık ve %93.31 AUC şeklindedir.

Bu çalışmada kullanılan yöntemlerin güvenilir sonuçlar verdiği veri setinin kalitesi ve çeşitliliği ile değerlendirilmiştir. Veri seti, finansal haberlerin duygusal analizine yönelik kullanılan "Sentiment Analysis for Financial News" isimli veri kümesinden alınmış, pozitif, negatif ve nötr kategorilerinde sınıflandırılmıştır. Dengesiz sınıf dağılımına (pozitif: %28.1, nötr: %59.4, negatif: %12.5) rağmen veri setinin geniş bir kapsam ve gerçek dünya temsili sunması çeşitliliği artırmış ve modelin genelleştirme yeteneğini geliştirmiştir. Veri ön işleme süreçlerinde metinlerin temizlenmesi, TF-IDF ile anlamlı özniteliklerin çıkarılması ve PCA ile boyut indirgeme yapılması modelin bilgi kaybını en aza indirerek güvenilir

sonuçlar vermesine katkı sağlamıştır. Ayrıca SMOTE yöntemiyle sınıf dengesizliği giderilmiş bu da azınlık sınıflarının öğrenme sürecindeki etkisini artırarak model doğruluğunu yükseltmiştir. PCA ile boyut indirgeme işlem süresini kısaltmış ancak varyans oranına bağlı olarak bilgi kaybına neden olmuştur. Çeşitliliğin korunması ve veri seti kalitesine yönelik önlemler özellikle TF-IDF ve SMOTE gibi yöntemlerin daha etkili sonuçlar üretmesini sağlamış bu da yöntemin genelleştirilebilirliğini artırmıştır. Bu bağlamda SMOTE ve PCA gibi yöntemler veri çeşitliliği ve kalitesi temelinde güvenilir sonuçlar sağlayan önemli araçlar olarak öne çıkmaktadır.

Çalışmada metin sınıflandırma sürecinde kullanılan yöntemler veri ön işleme, öznitelik çıkarımı ve öznitelik seçimi aşamalarında detaylandırılmıştır. Ön işleme adımlarında haber başlıkları üzerinde temizle_metin fonksiyonu ile metinler küçük harflere dönüştürülmüş, noktalama işaretleri ve sayılar temizlenmiştir. Ayrıca sınıf etiketleri LabelEncoder kullanılarak sayısal değerlere dönüştürülmüş ve sınıf dengesizliği problemi SMOTE yöntemiyle azınlık sınıfların örnekleri artırılarak giderilmiştir. Öznitelik çıkarımı aşamasında, TF-IDF yöntemi kullanılarak metinlerden öznitelik çıkarılmıştır. Daha sonra öznitelik seçimi için VarianceThreshold yöntemiyle düşük varyanslı öznitelikler veri setinden elenmiştir. Ek olarak PCA yöntemi uygulanarak öznitelik boyutu toplam varyansın %35.97'sini açıklamıştır. PCA uygulanmıyorken diğer yöntemlerle karşılaştırıldığında en yüksek doğruluk, F1-Puanı ve AUC elde edilmiştir. Bu durum öznitelik boyut indirgeme işlemi yapılmadığında modelin daha fazla bilgiyle çalışabildiğini ve dolayısıyla performansının yüksek olduğunu göstermektedir. PCA'nın uygulanmasıyla doğruluk, F1-Puanı ve AUC değerlerinde belirgin bir düşüş gözlemlenmiştir. Bu durum, PCA'nın açıklanan varyans oranının yeterince yüksek olmamasından veya bazı önemli özniteliklerin kaybından kaynaklanabilir. Ancak PCA modelin karmaşıklığını azaltmış ve işlem süresini kısalmıştır. Varyans Eşiği Belirleme ve PCA uygulanıyorken düşük varyanslı özniteliklerin elenmesi, model performansında PCA uygulamasına benzer şekilde bir düşüşe neden olmuştur. Ancak bu yöntem öznitelik uzayını sadeleştirerek modelin daha az girdiyle çalışmasını sağlamıştır. Çıkan sonuçlara göre kullanılan ön işleme ve öznitelik seçimi yöntemleri, model performansı üzerinde doğrudan etkili olmuştur ve bu yöntemlerin her biri farklı bir performans dengesi sağlamaktadır.

En yüksek sonuçları veren özgün algoritmada doğruluk ve işlem süresi arasında bir denge sağlanmış, amaca en uygun parametreler ve optimizasyonlar yöntemleri seçilmiştir. Çalışmada, modelin gizli katmanları, sırasıyla 128 ve 64 nöronlu olup, relu aktivasyon fonksiyonu kullanılmış ve aşırı öğrenmeyi önlemek amacıyla her katmandan sonra %30 dropout oranı uygulanmıştır. Optimizasyon için dinamik öğrenme oranı ayarlamaları sağlayan ve genelde hızlı ve kararlı sonuçlar veren Adam optimizasyon algoritması tercih edilmiş, öğrenme oranı 0.001 olarak belirlenmiştir. Modelin çok sınıflı sınıflandırma problemine uygun şekilde categorical_crossentropy kayıp fonksiyonu kullanılarak eğitimi gerçekleştirilmiştir. Eğitim sürecinde 10 epoch ve 32 batch boyutu kullanılarak model, her epoch'ta tüm veri setini küçük parçalara bölerek daha verimli bir şekilde öğrenmiştir. Öznitelik çıkarımı aşamasında metin verilerinden TF-IDF yöntemi ile maksimum 5000 öznitelik çıkarılmış; ardından düşük bilgi içeren öznitelikler, 0.0005 varyans eşik değeri kullanılarak elenmiştir. Ayrıca PCA yöntemiyle boyut indirgeme yapılmış ve toplam varyansın %35.97'sini açıklayan 100 bileşen seçilmiştir. Veri setindeki sınıf dengesizliği, SMOTE yöntemi ile çözülmüş ve azınlık sınıfların örnekleri artırılmıştır. Modelin performansı 5 katmanlı Stratified K-Fold çapraz doğrulama yöntemiyle test edilmiş ve doğruluk, kesinlik, duyarlılık, F1-Skoru, AUC ve özgüllük gibi metriklerle değerlendirilmiştir. Bu parametreler ve optimizasyon yöntemleri, modelin genelleştirme kabiliyetini artırmayı ve işlem süresini optimize etmeyi hedeflemiştir.

Gelecek çalışmalarda, bizim çalışmamızdan farklı olarak daha büyük ve çeşitli veri setleri ile modelin performansı test edilebilir. Özellikle dengeli, dengesiz ve çok dengesiz sınıf yapısına sahip veri setleri üzerinde modelin başarısını karşılaştırmak, sınıf dengesizliğine karşı geliştirilen yöntemlerin etkinliğini ölçmek açısından faydalı olacaktır. Bunun yanı sıra PCA ile toplam varyansın %35.97'sinden daha fazlasını açıklayan bir eşik değeri belirlenerek hem daha fazla bilgi koruyan hem de sınıflandırma performansını artıran bir öznitelik boyut indirgeme süreci uygulanabilir. Bu şekilde doğruluk, kesinlik, duyarlılık ve F1-Skoru gibi performans metriklerinde daha yüksek sonuçlar elde edilmesi hedeflenebilir. Ayrıca farklı öznitelik çıkarımı ve boyut indirgeme yöntemleri (örneğin, UMAP veya t-SNE) de bu süreçte test edilebilir.Bunun ötesinde daha gelişmiş algoritmaların ve modellerin kullanılması da önerilmektedir. Örneğin, transformer tabanlı modeller (BERT, RoBERTa gibi) veya hibrit modeller (BiLSTM-CNN gibi) kullanılarak metin sınıflandırma problemlerine yönelik daha güçlü sonuçlar elde edilebilir. Ayrıca hiperparametre optimizasyonu için grid search veya bayesian optimizasyon gibi tekniklerin uygulanması model performansını artırabilir. Gelecekteki çalışmalar hem model performansını artıracak hem de işlem sürelerini azaltacak yöntemlere odaklanabilir. Bu tür yenilikçi yaklaşımlar sadece model performansını değil aynı zamanda modelin uygulanabilirliğini ve genelleştirilebilirliğini de önemli ölçüde geliştirecektir.

Bu çalışmanın bulguları hem klinik pratikte hem de gerçek hayatta çeşitli alanlarda önemli uygulama potansiyeline sahiptir. Finans piyasaları bağlamında geliştirilen sınıflandırma modeli finansal haberlerin olumlu, olumsuz veya nötr olarak kategorize edilmesini sağlayarak yatırımcıların karar verme süreçlerini hızlandırabilir ve bu süreçlerdeki doğruluğu artırabilir. NLP ve makine öğrenimi teknikleriyle desteklenen bu tür sistemler büyük hacimli haber akışlarını gerçek zamanlı olarak analiz edebilir ve piyasa hareketlerini anlamlandırarak yatırımcılara stratejik öngörüler sunabilir. Örneğin bir yatırım platformuna entegre edildiğinde belirli bir hisse senedi, sektör veya ekonomik göstergeyle ilgili haberlerin otomatik analizi sağlanabilir ve bu analiz sonuçları yatırımcıların bilinçli kararlar almasına yardımcı olabilir. Aynı zamanda kurumsal yatırımcılar ve finans kuruluşları için piyasa dinamiklerini daha iyi anlamak ve portföy risklerini optimize etmek amacıyla bu sistemler uygulanabilir. Klinik pratikte ise geliştirilen bu sınıflandırma sisteminin tıbbi haberlerin ve hasta yorumlarının analizinde kullanılması mümkündür. Örneğin sağlık haberleri veya bilimsel makalelerin olumlu olumsuz veya tarafsız olarak sınıflandırılması sağlık uzmanlarının doğru bilgiye daha hızlı ulaşmasını sağlayabilir ve klinik karar verme süreçlerini destekleyebilir. Hasta şikayetlerinin otomatik olarak analiz edilmesi ve önceliklendirilmesi hastaların daha hızlı ve doğru bir şekilde değerlendirilmesine olanak tanır. Ayrıca tıbbi sosyal medya platformlarında yanlış bilgi veya yanıltıcı içeriklerin tespit edilmesi halk sağlığı açısından büyük önem taşımaktadır. Hem finansal hem de sağlık sektöründe bu çalışmanın bulguları büyük veriyi analiz etmek ve doğru bilgiyi öne çıkarmak için güçlü bir araç sunarak karar destek sistemlerinin etkinliğini artırabilir.

Çıkar Çatışması Beyanı

Bu çalışmada yazarlar arasında herhangi bir çıkar çatışması bulunmamaktadır.

References

[1] Ünal Çağlar and Senem Dışkaya. Küreselleşme, uluslararasi para sistemi ve kriz. *Journal of Economic Policy Researches*, 5(2):1–24, 2018.

[2] Orhan Cengiz. Küresel finans sisteminin ekonomi politiğinde renminbinin uluslararasılaşma süreci. *Gazi İktisat ve İşletme Dergisi*, 8(1):61–79, 2022.

[3] Cahit Aydemir, Mehmet Kaya, et al. Küreselleşme kavrami ve ekonomik yönü. *Elektronik Sosyal Bilimler Dergisi*, 6(20):260–282, 2007.

[4] Junus Ganiev. Küreselleşme, finansal piyasalar ve kriz. *Journal of Economic Policy Researches*, 1(2), 2014.

[5] Ersin Özince. Finansal sektör–uluslararası gelişmeler ve türkiye deneyimi. *Muhasebe ve Finansman Dergisi*, (40):24–44, 2008.

[6] Sevgi Aytekin and Sema Dube. Piyasalar arasi dinamikler: Hisse senedi, tahvil, döviz ve emtia piyasalari arasindaki etkileşim ve nedensellik ilişkileri. *Elektronik Sosyal Bilimler Dergisi*, 15(59):1311–1326, 2016.

[7] European Metrology Network. Jrp neurobiostand project, 2024. Accessed: November 20, 2024.

[8] Mehmet Cem Danacı and Özlem Çetintaş. Bankalarda finansal teknoloji ve yenilikler. *Turkish Business Journal*, 1(2):179–187, 2020.

[9] Özge Cömert and Mesut Toğaçar. Telepazarlama çağrılarının başarısını tahmin etmek üzere veriye dayalı bir yaklaşım. *Verimlilik Dergisi*, 57(4):735–746, 2023.

[10] Mehmet Fatih Çömlekçi. Sosyal medyada dezenformasyon ve haber doğrulama platformlarinin pratikleri. *Gümüşhane Üniversitesi İletişim Fakültesi Elektronik Dergisi*, 7(3):1549–1563, 2019.

[11] Suat Atan and Yetkin Çınar. Borsa istanbul'da finansal haberler ile piyasa değeri ilişkisinin metin madenciliği ve duygu (sentiment) analizi ile incelenmesi. *Ankara Üniversitesi SBF Dergisi*, 74(1):1–34, 2019.

[12] Serkan Demirel. Küresel ekonomik, politik ve jeopolitik risklerin bireysel ve kurumsal finansal işlemlere etkisi. *Elektronik Sosyal Bilimler Dergisi*, 23(90):645–667, 2024.

[13] Salih Aydın and Mehmet Serkan Çalı. Covid-19'un bireysel yatırımcıların yatırım davranışları üzerindeki etkisi: Covid-19 öncesi ve covid-19 sürecine yönelik karşılaştırmalı bir analiz. *Fiscaoeconomia*, 7(1):62–85, 2023.

[14] Sabah Ekonomi. 3 haftada 1 milyon yatırımcı geldi, 2024. Accessed: November 27, 2024.

[15] Mehmet Saraç and Mehmet Burak Kahyaoğlu. Bireysel yatırımcıların risk alma eğilimine etki eden sosyo-ekonomik ve demografik faktörlerin analizi. *BDDK Bankacılık ve Finansal Piyasalar Dergisi*, 5(2):135–157, 2011.

[16] Veli Özgür Yurtdaşseven and Serkan Çankaya. Finansal tavsiyelerin yatırımcı davranışlarına etkisi. *Finans Ekonomi ve Sosyal Araştırmalar Dergisi*, 3(2):564–575, 2018.

[17] Berat Çağlar and Uğur Yavuz. Finansal haberlerin bitcoin fiyatlarına etkisinin yapay sinir ağları ile analizi. *Bilişim Teknolojileri Dergisi*, 14(1):65–78, 2021.

[18] Mehmet Kayakuş and Fatma Yiğit Açıkgöz. Twitter'da makine öğrenmesi yöntemleriyle sahte haber tespiti. *Abant Sosyal Bilimler Dergisi*, 23(2):1017–1027, 2023.

[19] Ali Öztürk, Üsame Durak, and Fatma Badıllı. Twitter verilerinden doğal dil işleme ve makine öğrenmesi ile hastalik tespiti. *Konya Journal of Engineering Sciences*, 8(4):839–852, 2020.

[20] Mesut Toğaçar, Kamil Abdullah Eşidir, and Burhan Ergen. Yapay zekâ tabanlı doğal dil işleme yaklaşımını kullanarak internet ortamında yayınlanmış sahte haberlerin tespiti. *Journal of Intelligent Systems: Theory and Applications*, 5(1):1–8, 2021.

[21] Serkan Bulut. Dijital çağda medya: Makine öğrenmesi, algoritmik habercilik ve gazetecilikte işlevsiz insan sorunsali. *Selçuk İletişim*, 13(1):294–313, 2020.

[22] Güler Alparslan and Mahir Dursun. Konvolüsyonel sinir ağları tabanlı türkçe metin sınıflandırma. *Bilişim Teknolojileri Dergisi*, 16(1):21–31, 2023.

[23] Önder Şahinaslan, Hüseyin Dalyan, and Ender Şahinaslan. Naive bayes sınıflandırıcısı kullanılarak youtube verileri üzerinden çok dilli duygu analizi. *Bilişim Teknolojileri Dergisi*, 15(2):221–229, 2022.

[24] Ruşen Ramizoğlu. Modern makine çevirisi teknolojilerine yönelik bir karşilaştirma. *Uluslararası Türkçe Edebiyat Kültür Eğitim (TEKE) Dergisi*, 13(1):126–137, 2024.

[25] Gözde Şişmanoğlu, Furkan Koçer, Mehmet Ali Önde, and Ozgur Koray Sahingoz. Derin öğrenme yöntemleri ile borsada fiyat tahmini. *Bitlis Eren Üniversitesi Fen Bilimleri Dergisi*, 9(1):434–445, 2020.

[26] Enver Yazğılı and Muhammet Baykara. Türkçe metinlerde makine öğrenmesi yöntemleri ile siber zorbalık tespiti. *Gümüşhane Üniversitesi Fen Bilimleri Dergisi*, 12(2):443–453, 2022.

[27] Mehmet Acı and Gamze Ayyıldız Doğansoy. Makine öğrenmesi ve derin öğrenme yöntemleri kullanılarak e-perakende sektörüne yönelik talep tahmini. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 37(3):1325–1340, 2022.

[28] Mustafa Demirbilek and Sevim Özulukale Demirbilek. Google yorumları üzerinden makine öğrenme yöntemleri ve amazon comprehend ile duygu analizi: İç anadoluda bir üniversite örneği. *Üniversite Araştırmaları Dergisi*, 6(4):452–461, 2023.

[29] Saadet Aytaç Arpacı and Oya Kalıpsız. Yazilim hata siniflandirmasinda farkli naive bayes tekniklerin kiyaslanmasi. *Niğde Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi*, 7(1):1–13, 2018.

[30] Hasan Demir, Pakize Erdoğmuş, and Meral Kekeçoğlu. Destek vektör makineleri, ysa, k-means ve knn kullanarak arı türlerinin sınıflandırılması. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 6(1):47–67, 2018.

[31] Sinan Altun and Ahmet Alkan. Mr spektroskopi kullanılarak beyin tümörü tespitinde lstm tabanlı derin öğrenme uygulaması. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 38(2):1193–1202, 2022.

[32] Ali Tezcan Sarızeybek and Onur Sevli. Makine öğrenmesi yöntemleri ile banka müşterilerinin kredi alma eğiliminin karşılaştırmalı analizi. *Journal of Intelligent Systems: Theory and Applications*, 5(2):137–144, 2022.

[33] Emrah Aydemir, Murat Işık, and Türker Tuncer. Türkçe haber metinlerinin çok terimli naive bayes algoritması kullanılarak sınıflandırılması. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 33(2):519–526, 2021.

[34] Çiğdem Acı and Adem Çırak. Türkçe haber metinlerinin

konvolüsyonel sinir ağları ve word2vec kullanılarak sınıflandırılması. *Bilişim Teknolojileri Dergisi*, 12(3):219–228, 2019.

[35] Özer Çelik and Burak Can Koç. Tf-idf, word2vec ve fasttext vektör model yöntemleri ile türkçe haber metinlerinin sınıflandırılması. *Dokuz Eylül Üniversitesi Mühendislik Fakültesi Fen ve Mühendislik Dergisi*, 23(67):121–127, 2021.

[36] Hulya Hark, Meral Karakurt, Cengiz Hark, and Ali Karci. Glove kelime gömmeleri ve sinir ağları ile haber metinlerinin sınıflandırılması. *International Journal of Pure and Applied Sciences*, 9(1):175–187, 2023.

[37] Kaggle. Learn ai bbc dataset, 2024. https://www.kaggle.com/competitions/learn-ai-bbc/data (Accessed: November 27, 2024).

[38] Halil İbrahim Okur, Kadir Tohma, and Ahmet Sertbaş. Graf sinir ağları ile ilişkisel türkçe metin sınıflandırma. *Politeknik Dergisi*, pages 1–1.

[39] Esra Çelik, Deniz Dal, and Tolga Aydin. Duygu analizi için veri madenciliği sınıflandırma algoritmalarının karşılaştırılması. *Avrupa Bilim ve Teknoloji Dergisi*, (27):880–889, 2021.

[40] Cengiz Hark. Sahte haber tespiti için derin bağlamsal kelime gömülmeleri ve sinirsel ağların performans değerlendirmesi. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 34(2):733–742, 2022.

[41] Feyza ALTUNBEY Özbay and Bilal Alataş. Çevrimiçi sosyal medyada sahte haber tespiti. *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, 11(1):91–103, 2020.

[42] Doğancan Kınık and Aysun Güran. Tf-idf ve doc2vec tabanlı türkçe metin sınıflandırma sisteminin başarım değerinin ardışık kelime grubu tespiti ile arttırılması. *Avrupa Bilim ve Teknoloji Dergisi*, (21):323–332, 2021.

[43] Süleyman Gökhan Taşkın, Ecir Uğur Küçüksille, and Kamil Topal. Twitter üzerinde türkçe sahte haber tespiti. *Balıkesir Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, 23(1):151–172, 2021.

[44] Yunus Santur. Derin öğrenme ve aşağı örnekleme yaklaşımları kullanılarak duygu sınıflandırma performansının iyileştirilmesi. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 32(2):561–570, 2020.

[45] Gözde Nergiz and Erdinç Avaroğlu. Türkçe sosyal medya yorumlarındaki siber zorbalığın derin öğrenme ile tespiti. *Avrupa Bilim ve Teknoloji Dergisi*, (31):77–84, 2021.

[46] Ali Dayan and Atınç Yılmaz. Doğal dil işleme ve derin öğrenme algoritmaları ile makine dili modellemesi. *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, 13(3):467–475.

[47] Mustafa Özkan and Görkem Kar. Türkçe dilinde yazilan bilimsel metinlerin derin öğrenme tekniği uygulanarak çoklu siniflandirilmasi. *Mühendislik Bilimleri ve Tasarım Dergisi*, 10(2):504–519, 2022.

[48] Adham Jolosı Jolosı Zada and Ahmet Albayrak. Duygu analizi ve topluluk öğrenmesi yaklaşımları ile kullanıcı yorumlarının analizi. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 11(4):1725–1732, 2023.

[49] Yasin Görmez, Halil Arslan, and Bilal Atak. Türkçe metinlerde duygu analizi: Derin öğrenme yaklaşımlarının ve ön işlem süreçlerinin model performansına etkisi. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 36(1):509–520, 2024.

[50] Nurcan Yücel and Özge Cömert. Müşteri duyarlılığını keşfetmek için yapay zeka destekli analiz ile çevrimiçi ürün incelemelerinden anlamlı bilgiler elde etme. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 35(2):679–690, 2023.

[51] Zeynep Hilal Kilimci. Borsa tahmini için derin topluluk modellleri (dtm) ile finansal duygu analizi. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 35(2):635–650, 2020.

[52] Mehmet Umut Salur and İlhan Aydın. Türkçe tweetler için derin özellik çıkarımı tabanlı yeni bir duygu sınıflandırma modeli. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 34(1):1–13, 2022.

[53] Abdülkadir TEPECİK and Engin DEMİR. Türkçe ses kayıt verilerinin countvectorizer ve tf-idfvectorizer yöntemleri ile bert modelleri olarak google colab platformunda ve rapidminer'da makine öğrenmesi algoritmalarıyla analizi. *Firat University Journal of Science*, 34(1), 2022.

[54] Serpil Aslan. Bigru-cnn tabanlı derin öğrenme modeliyle türkiye'deki covid-19 aşılarına yönelik twitter duygu analizi. *International Journal of Pure and Applied Sciences*, 8(2):312–330, 2022.

[55] Mehmet Can Yılmaz and Zeynep Orman. Lstm derin öğrenme yaklaşımı ile covid-19 pandemi sürecinde twitter verilerinden duygu analizi. *Acta Infologica*, 5(2):359–372, 2021.

[56] Serim Gençaslan, Anıl Utku, and M Ali Akcayol. Derin öğrenme tabanlı video üzerinde olay sınıflandırma. *Politeknik Dergisi*, 26(3):1155–1165, 2022.

[57] Murat İnce. Üstverilerin derin öğrenme algoritmaları kullanılarak otomatik olarak çıkartılması ve sınıflanması. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 9(6):177–187, 2021.

[58] Ebru Somuncu and Nesrin Aydın Atasoy. Evrişimli tekrarlayan sinir ağı ile metin görüntüleri üzerinde karakter tanıma uygulaması gerçekleştirilmesi. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 37(1):17–28, 2022.

[59] Meral Karakurt, ALİ KARCI, et al. Glove kelime gömmeleri ve sinir ağları ile haber metinlerinin sınıflandırılması. *International Journal of Pure and Applied Sciences*, 9(1), 2023.

[60] Ankur Zing et al. Aspect-based sentiment analysis for financial news, 2024. Accessed: 2024-11-30.

[61] Tahir Emre Kalaycı. Kimlik hırsızı web sitelerinin sınıflandırılması için makine öğrenmesi yöntemlerinin karşılaştırılması. *Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi*, 24(5):870–878, 2018.

[62] Ali Cihat Kelle and Hüseyin Yüce. Mqtt trafiğinde dos saldırılarının makine öğrenmesi ile sınıflandırılması ve modelin shap ile yorumlanması. *Journal of Materials and Mechatronics: A*, 3(1):50–62, 2022.

[63] E Aydoğan. Veri madenciliğinde sınıflandırma problemleri için evrimsel algoritma tabanlı yeni bir yaklasım: Roughmep algoritması. *Gazi Üniversitesi Fen Bilimleri Enstitüsü: Yayımlanmamış doktora tezi*, 2008.

[64] Durmuş Özkan ŞAHİN, Nurullah ATEŞ, and Erdal KILIÇ. Metin sınıflandırmada öznitelik seçimi feature selection in text classification.

[65] Ali İnan and Esra Var. Sınıflandırma için diferansiyel mahremiyete dayalı öznitelik seçimi. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 33(1), 2018.

[66] Sedat Metlek and Kiyas Kayaalp. Derin öğrenme ve destek vektör makineleri ile görüntüden cinsiyet tahmini. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 8(3):2208–2228, 2020.

[67] Özlem Özmen, Ahmad Khdr, and Engin Avcı.

Sınıflandırıcıların kalp hastalığı verileri üzerine performans karşılaştırması. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 30(3):153–159, 2018.

[68] Serhat Burmaoğlu, Erkan Oktay, and Üstün Özen. Birleşmiş milletler kalkınma programı beşeri kalkınma endeksi verilerini kullanarak diskriminant analizi ve lojistik regresyon analizinin sınıflandırma performanslarının karşılaştırılması. *Savunma Bilimleri Dergisi*, 8(2):23–49, 2009.

[69] Bilge Özlüer Başer, Metin Yangın, and E Selin Sarıdaş. Makine öğrenmesi teknikleriyle diyabet hastalığının sınıflandırılması. *Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, 25(1):112–120, 2021.

[70] Ensar Arif Sağbaş and Serkan Ballı. Akıllı saat algılayıcıları ile insan hareketlerinin sınıflandırılması. *Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, 21(3):980–990, 2017.

[71] Göksu Akgül, Ali Akın Çelik, Zeliha Ergül Aydın, and Zehra Kamışlı Öztürk. Hipotiroidi hastalığı teşhisinde sınıflandırma algoritmalarının kullanımı. *Bilişim Teknolojileri Dergisi*, 13(3):255–268, 2020.

[72] Gizem Dilki and Özlem Deniz Başar. İşletmelerin iflas tahmininde k-en yakin komşu algoritmasi üzerinden uzaklik ölçütlerinin karşilaştirilmasi. *İstanbul Ticaret Üniversitesi Fen Bilimleri Dergisi*, 19(38):224–233, 2020.

[73] Yusuf Bahri Özçelik and Aytaç Altan. Diyabetik retinopati teşhisi için fundus görüntülerinin derin öğrenme tabanlı sınıflandırılması. *Avrupa Bilim ve Teknoloji Dergisi*, (29):156–167, 2021.

[74] Ali Arı, Furkan Ayaz, and Davut Hanbay. Emg sinyallerinin kısa zamanlı fourier dönüşüm özellikleri kullanılarak yapay sinir ağları ile sınıflandırılması. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 31(2):443–451, 2019.

[75] Yeşim Dokuz, Aslı Bozdağ, and Begüm Gökçek. Hava kalitesi parametrelerinin tahmini ve mekansal dağilimi için makine öğrenmesi yöntemlerinin kullanilmasi. *Niğde ömer halisdemir üniversitesi mühendislik bilimleri dergisi*, 9(1):37–47, 2020.

[76] Mehmet Bilal Er and İbrahim Işık. Lstm tabanlı derin ağlar kullanılarak diyabet hastalığı tahmini. *Türk Doğa ve Fen Dergisi*, 10(1):68–74, 2021.

[77] Numan Halit Güldemir and Ahmet Alkan. Derin öğrenme ile optik koherens tomografi görüntülerinin sınıflandırılması. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 33(2):607–615, 2021.

[78] Birkan Büyükarıkan and Erkan Ülker. Aydinlatma özniteliği kullanilarak evrişimsel sinir aği modelleri ile meyve siniflandirma. *Uludağ Üniversitesi Mühendislik Fakültesi Dergisi*, 25(1):81–100, 2020.

[79] Gülnur Begüm Ergün, Selda Güney, and Tahsin Gürkan Ergün. Köpeklerdeki uzun kemiklerin evrişimsel sinir ağları kullanılarak sınıflandırılması. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 33(1):125–132, 2021.